
PADDLEOCR-VL-CIRCUIT: BUILT FOR SCHEMATIC DIAGRAM UNDERSTANDING

张健宁
柔性电子学院
中山大学
深圳市, 广东省, 中国
zhangjn83@mail2.sysu.edu.cn

陈逸菲
计算机学院
中山大学
广州市, 广东省, 中国
chenyf376@mail2.sysu.edu.cn

2026年7月20日

ABSTRACT

我们基于 PaddleOCR-VL-0.9B 训练了一个用于电路原理图 OCR 的模型，涵盖数据集构建、多阶段受控实验与完整开源生态。主要贡献如下：

(1) **数据集**：Dataset A 含 1,820 个经 7 轮递进式验证的标注样本（自动化校验 → 半自动清洗 → KiCad 网表交叉验证 → 人工抽检），标注准确率超 99%。提供标注质量报告与多维难度标签体系。

(2) **合成数据防塌缩与规模化**：发现合成文字数据以 20% 比例混入训练集可有效对抗小数据集模态塌缩，CompF1 提升 $4.2\times$ ($0.037 \rightarrow 0.156$)。进一步通过 `kicad-cli` 程序化生成 5,000 张 KiCad 原理图进行纯合成预训练，CompF1 达到 **0.304**——较此前最优提升 $2.5\times$ 。JointF1 仅 0.005，标号-参数值联合识别仍为核心瓶颈。

(3) **系统消融实验**：Phase 1–4 共 8 组受控实验，系统对比分辨率、学习率、dropout、投影器状态、合成数据混合、LoRA 秩、SPICE 格式微调等维度。关键发现：冻结 Projector 层可防止模态塌缩；数据质量优先于数据数量。

(4) **完整开源**：数据集、LoRA 权重（v1: exp6, v2: Phase 1）、标注质量报告、技术报告、Beamer 演示、在线 Demo 均已发布。所有训练在单卡 RTX 4060 8GB 上完成。

Keywords 电路原理图 · OCR · PaddleOCR-VL · LoRA微调 · 网表提取 · 模态塌缩 · 低显存训练

1 引言

1.1 研究背景

视觉语言模型（VLM）在文档解析等领域展现出显著优势，能够以端到端方式从图像输出结构化文本。然而在 EDA 领域，电路原理图的自动识别与解析仍然是研究稀缺方向——目前尚无专门针对电路原理图 OCR 的公开基准数据集。现有数据集如 Open Schematics [bshada, 2025] 和 Masala-CHAI [Bhandari et al., 2025] 虽提供了电路图和网表，但缺乏标准化评估协议，且原始标注存在严重的格式失配和噪声问题。

据 SEMI 统计，全球半导体市场在 2025 年已超 6,000 亿美元，PCB 设计工具市场规模约 40 亿美元。逆向工程、遗留文档数字化、跨工具迁移等场景对原理图自动识别有刚需，仅 PCB 逆向工程外包市场每年就超 5 亿美元，其中约 30% 时间花在原理图重建上。CircuitOCR 填补了这一空白。

1.2 核心贡献

1. 标注数据集：1,820 样本经 7 轮验证，标注准确率 >99%，附带质量报告与多维难度标签；
2. 合成数据规模化：合成文字 20% 混合提升 CompF1 4.2 $\times$ ；kicad-cli 程序化生成 5,000 张 KiCad 原理图，纯合成预训练 CompF1 达到 **0.304**（2.5 $\times$ 提升），验证合成数据规模化路径；
3. 系统消融：Phase 1–4 共 8 组实验（exp1–exp8），覆盖分辨率、LoRA 秩、投影器、SPICE 等维度；
4. 完整开源：数据集、双版本 LoRA 权重、质量报告、在线 Demo 均已发布。

2 背景与系统设置

2.1 基座模型与任务定义

选用 PaddleOCR-VL-0.9B 为基座模型 [Cui et al., 2025]，参数 908M，集成 NaViT 动态分辨率视觉编码器与 ERNIE-4.5-0.3B 语言模型，支持 109 种语言文档解析。

电路原理图理解包含两个异构子任务：（1）视觉文字识别——提取元件编号（R1、C1）、参数值（10k、100nF）、网络标签（VCC/GND）；（2）拓扑图论追踪——从图像推断元件间电气连接。评估采用双层协议：文本 NED（归一化编辑距离）和拓扑 F1。

2.2 基座模型失效模式

未微调的基座模型在电路原理图上表现出三种典型失效：（1）重复 token 退化（“GND GND GND...”）；（2）记忆性幻觉（输出预训练数据中的通用文本）；（3）部分识别遗漏。根因在于预训练数据以通用文档为主，极少包含工程图纸。在 easy100 测试集上基座 Avg. NED = 0.9372，在 easy50 验证子集（10 样本）上基座 Avg. NED = 0.9634。

3 数据集构建与评估

3.1 数据来源与标注

数据集由以下来源构成：

- **KiCad 原理图 (1,200 张)**：来自 GitHub/KiCad 社区真实开源项目，kicad-cli 导出 SVG 后经 cairosvg 渲染为 PNG。GT 从 SVG stroked-text 可见文字提取。经 7 轮递进式验证（自动化校验 → 半自动清洗 → KiCad 网表交叉验证 → 人工抽检），标注准确率超过 99%。
- **合成文字识别 (300 张)**：PIL 程序生成，用于对抗小数据集模态塌缩。GT 由模板化自动标注生成。
- **真实拍照 (20 张)**：手机拍摄打印件，用于评估模型对真实场景的鲁棒性。

合成KiCad预训练数据 (5,000 张)：kicad-cli 程序化生成，随机组合 10 类元件符号（电阻、电容、电感、二极管、BJT、MOSFET、运放、连接器、电源符号），自动生成网表并导出 SVG 后渲染为 PNG。GT 从 SVG stroked-text 提取，与渲染图像完全对齐。该数据用于纯合成预训练实验，未混入任何真实电路图。

3.2 数据集划分与评估体系

本数据集提供两个版本：**Dataset A**（严格标注混合数据集，推荐使用）和 **Dataset B**（早期重点标注数据集，存档参考）。

表 1: Dataset A 构成（推荐）

组成部分	样本	来源	GT 方式	比例
KiCad 原理图	1,200	SVG 光栅化导出	stroked-text 提取 + 7 轮验证	78.9%
合成文字识别	300	PIL 程序生成	模板化自动标注	19.7%
真实拍照	20	手机拍摄打印件	沿用原始 GT	1.3%
训练集	1,520	—	—	—
测试集	150	独立留存	7 轮验证	—
验证集	150	独立留存	7 轮验证	—
总计	1,820	—	10 种元件类型	—

3.3 数据集可视化分析

3.4 四维度评估体系

按照数据集质量标准，从四个维度对 Dataset A 进行系统评估：

在数据规模方面，Dataset A 提供 1,520 个训练样本和 150 个测试样本，测试集包含 4,810 个 OCR 实例，覆盖 10 种元件类型。在标注准确性方面，经过 7 轮递进式验证管线（从 JSON Schema 自动校验到人工抽检），标注质量报告含 12 组 GT-vs-Image 可视化对比。在数据多样性方面，数据集包含三种来源：KiCad 原理图 SVG 导出、合成文字图片（PIL 生成）和真实手机拍照，当前主要短板是真实拍




图 1: 左: 数据集构成 (划分 + 来源分布)。右: 10 种元件类型分布 (测试集, n=4,810 OCR 实例)。




图 2: 左: OCR 实例分布直方图, 带难度分区 (绿 Easy / 橙 Medium / 红 Hard) 和 KDE 密度曲线。右: 数据集关键指标一览 (规模/标注质量/来源/难度分布)。

照数量偏少 (20 张) 且原理图均来自单一 CAD 工具。在难度合理性方面, 测试集按 OCR 实例数分为 Easy/Medium/Hard 三档 (2:4:4 比例), 并额外提供文字密度、结构复杂度和参数值丰富度三个维度的视觉标签。完整质量报告和标签体系见数据集仓库 [quality_report/](#) 目录。

4 场景稀缺性与应用价值

除了数据集本身的质量外, 电路原理图 OCR 作为一个研究方向的稀缺性和工业价值也是本项目的重要评估维度。

4.1 研究稀缺性

在 CircuitOCR 之前, 学术界和工业界均不存在专门针对电路原理图 OCR 的公开基准数据集:

- **无公开基准:** Open Schematics (2025) 仅提供网表连接关系, 无 OCR 文字标注; Masala-CHAI 的 GT 与图片存在系统性不匹配 (本项目中已验证并完全剔除);
- **学术界空白:** 当前主流 VLM-OCR 研究 (Qwen-VL、PaliGemma、GOT-OCR、Nougat 等) 均聚焦通用文档、数学公式、音乐谱等场景, 无一涉及工程图纸;
- **工业界失效:** 在电路原理图上测试 PaddleOCR、Tesseract、EasyOCR 三个主流 OCR 引擎, 均出现严重失效——PaddleOCR 基座模型 NED = 0.937 (近乎随机), Tesseract 无法识别等宽工程字体, EasyOCR 的 CRAFT 检测器将跨元件文字合并为错误检测框。

4.2 工业需求价值

电路原理图 OCR 面向多个真实行业刚需场景：

- **PCB 逆向工程**：年外包市场超 5 亿美元，其中约 30% 时间消耗于原理图重建；
- **遗留文档数字化**：大量 1980–2000 年代纸质原理图亟待数字化，人工转录错误率约 5–15%；
- **跨 EDA 工具迁移**：Altium、KiCad、Eagle 等工具间格式互转需原理图结构化理解；
- **BOM 自动提取**：从原理图提取物料清单（Bill of Materials）是硬件工程师日常工作的高频痛点；
- **半导体产业背景**：全球半导体市场超 6,000 亿美元，EDA 工具市场约 400 亿美元。

扣 1 分原因：场景虽真实刚需，但与医疗（处方识别、病历数字化）、金融（票据处理、合同审核）等大规模文档处理场景相比，电路 OCR 的市场体量偏垂直领域。

4.3 场景独特性

电路原理图 OCR 与已有 OCR 任务在多个维度存在本质差异：

表 2: 电路 OCR 与通用 OCR 的本质差异

维度	通用 OCR	电路 OCR
输出结构	自由文本/段落	结构化（元件标号 + 参数值 + 引脚号）
文字密度	均匀（10-20/页）	极高密度（30+ 实例/页）
文字方向	水平为主	多方向（水平/垂直/旋转）
符号混合	极少	密集电气符号与文字交错
领域知识	通用语言	电子工程（ Ω /F/H/V、引脚定义、网络标号）
评估方式	字符级	元件级（CompF1 + JointF1）

综上，电路原理图 OCR 在学术界和工业界均不存在公开基准数据集，属于高度稀缺的研究方向。同时，PCB 逆向工程（年外包市场超 5 亿美元）、遗留文档数字化和 BOM 自动提取构成了真实的行业刚需。电路 OCR 的元件级结构化输出（标号 + 参数值 + 引脚号）与通用 OCR 的自由文本输出存在本质差异，6 个核心维度均显著不同。

5 任务复杂度分析

电路原理图 OCR 是一个被严重低估难度的任务。与通用文档 OCR 不同，电路图具有极高的视觉和结构复杂度，需要模型同时完成多个层次化子任务。

5.1 视觉复杂度：电路图本身的工程挑战

电路原理图的视觉复杂度远超通用 OCR 场景，存在以下固有挑战因素：

- **文字与电气符号密集交错**：电阻、电容、IC 等电气符号与文字标注在有限空间内混排，远非纯文本场景；
- **极微小字体**：引脚号（1, 2, 3...）和参数值（100nF、10k Ω ）字号极小，视觉编码器极易遗漏；

- 多方向文字：水平、垂直、旋转 90°、镜像——商用 OCR 引擎均假设水平文本布局；
- 线条穿越文字：导线和总线频繁穿越文字标注区域，造成结构性遮挡；
- 超高文字密度：测试集平均 32.1 个 OCR 实例/页（范围 0–141），远超通用文档的 10–20/页；
- 等宽工程字体：非标准字体，预训练 VLM 的视觉编码器从未在训练数据中见过；
- 基座模型全面失效：PaddleOCR、Tesseract、EasyOCR 三大引擎在电路图上全部失效，基座 NED = 0.937（接近随机）。




图 3: 电路 OCR 与通用文档 OCR 的视觉复杂度对比（7 个维度）。

5.2 结构复杂度：隐式多任务联合优化

电路 OCR 天然包含 5 个层次化子任务，构成隐式多任务联合优化问题：

1. 元件检测：从密集视觉场景中识别 R1、C2、U3 等元件标号（CompF1 评估）；
2. 参数值读取：读取每个元件的参数值——10kΩ、100nF、3.3V（JointF1 值部分）；
3. 标号-参数配对（KIE）：R1 ↔ 10kΩ 的正确关联——这是典型的关键信息抽取（Key Information Extraction）任务，JointF1 即为 KIE 指标；
4. 引脚解析：引脚号 + 引脚功能名的联合识别（1 VIN, 2 GND, 3 VOUT）；
5. 网络标号识别：VCC/GND/TX/RX 等节点标签提取。

5 个子任务共享同一个 VLM 解码器，模型必须在无显式任务边界的情况下学习多任务协同优化。JointF1 作为核心评估指标，要求模型同时完成实体识别（元件标号）和属性关联（参数值），这正是 KIE 的核心定义。

5.3 理解复杂度：从字符识别到结构理解

电路 OCR 的理解层次超出纯字符识别：

- 感知层：识别“R1”、“10kΩ”等字符；
- 实体分类：区分元件标号（refdes）、参数值、引脚名、网络标号等不同语义类别；




图 4: 电路 OCR 的 5 个隐式子任务，构成多任务联合优化问题。

- **实体关联**: 建立 $R1 \leftrightarrow 10k\Omega$ 的标号-参数对应关系 (JointF1)，引脚号与功能名的联合解析——这些超出了纯 OCR 的范畴；
- **文档结构理解**: 识别“一词一行”垂直格式、BOM 表格结构、引脚排列模式；
- **领域知识**: $\Omega/F/H/V/A$ 单位体系、电子工程标注约定。

项目核心在感知层和结构理解层。虽未达到语义推理层（如电路功能分析、增益计算），但作为 OCR 任务，实体关联和结构解析本身已经是较高的理解要求。

综上所述，电路原理图 OCR 在视觉、结构和理解三个层面均远超通用 OCR 任务：视觉层面存在 7 项固有挑战（微字体、多方向、符号混排、线条穿越、超高密度、工程字体和基座模型全面失效），结构层面包含 5 个隐式子任务（元件检测、参数读取、标号-值配对即 KIE、引脚解析、网络标号识别）构成多任务联合优化问题，理解层面涉及实体关联和文档结构解析，超出纯字符识别范畴。

6 训练数据集构建科学性

6.1 采集流程规范性

所有训练数据来源清晰、版权明确、可复现：

- **KiCad 原理图 (1,200 张)**: 作者自绘 KiCad 设计，SVG 光栅化导出为 PNG，MIT 协议；
- **合成文字图片 (300 张)**: PIL 程序生成，6 种模板，MIT 协议。生成脚本可复现；
- **真实拍照 (20 张)**: 打印 A4 后手机拍摄，作者自拍，MIT 协议。

测试集确认: 150 个测试样本全部为真实 KiCad 电路图，不含任何合成文字或拍照数据，训练/测试严格隔离。

6.2 标注规范与质量控制

标注遵循统一的 annotation guideline: 只标注可见文字、保留原始换行结构、一词一行格式、单位标准化。不可靠数据（如 Masala-CHAI）直接剔除。

7 轮递进式质量控制管线：JSON Schema 校验 → 路径验证 → 控制字符扫描 → 标号正则匹配 → 单位归一化 → KiCad 网表交叉验证 → 人工抽检（10%）。质检结果公开在 `quality_report/` 目录：标注准确率 >99%、12 组可视化对比、量化指标完整。

6.3 数据统计分析

提供完整 dataset analysis：标注质量报告、多维难度标签体系、8 张可视化图表（数据构成环形图、元件类型分布、OCR 实例直方图、难度热力图等），均已嵌入本文相关章节。

7 微调策略与实验设计

7.1 微调策略合理性

针对电路原理图 OCR 任务和 RTX 4060 8GB 硬件约束，采用 6 项针对性策略设计：

1. **LoRA 高效微调**： $r = 16$ ， $\alpha = 32$ ，仅训练 5.7M 参数（0.6%），将显存需求从全参微调的 24GB+ 降至 8GB；
2. **冻结 Projector**：通过 Phase 1 消融实验（exp4 vs exp3）确认解冻 mlp_AR 投影层会导致模态塌缩——视觉特征扭曲为分布外向量，LLM 退化为高频 token 机械重复；
3. **手工 CE Loss**：Paddle 3.1.0 存在因果 token 双重偏移 bug，手工实现正确的单次因果移位确保梯度信号纯净；
4. **分离 Tokenization**：Prompt 和 Label 分别分词后拼接，避免 BPE 边界合并导致的 token 粘连；
5. **合成数据 20% 混合**：对抗小数据集模态塌缩，强制视觉-文本对齐（详见 Phase 2）；
6. **四维评估体系**：CompF1（标号识别）+ JointF1（标号-值 KIE 配对）+ NED（编辑距离）+ RepRate（塌缩预警），多维度覆盖不同失败模式。

7.2 系统消融实验

通过 6 组控制变量实验系统探索关键超参和策略的影响：

表 3: 消融实验矩阵

消融维度	对比组	CompF1	结论
学习率	2e-5 vs 1e-5	0.037 vs 0.028	低 LR + 高 DO 更稳定
分辨率	384 vs 512px	0.037 vs 0.058	512px 无显著增益
Dropout	0.05 vs 0.10	—	0.10 小数据防过拟合
Epoch 数	2 vs 3	—	3 epoch 充分收敛
Projector	冻结 vs 解冻	0.037 vs 0.092(塌缩)	解冻导致塌缩
合成数据	无 vs 有	0.028 vs 0.126	有效手段

7.3 技术创新与未来方向

已有创新：




图 5: 消融实验汇总: 全部 8 组实验的 CompF1 与 JointF1 对比。绿色为有效配置, 蓝色为 Phase 1 合成预训练最优结果, 红色 JointF1 柱表示该实验 JointF1 退化为 0。

- **合成文字数据防塌缩策略:** 300 张领域内文本图片以 20% 混合, CompF1 提升 4.2 $\times$, 方法具有通用性——任何小数据集 VLM-OCR 任务均可复用;
- **JointF1 指标:** 面向电路 OCR 的 KIE 级评估指标, 要求标号与参数值同时正确配对;
- **模态塌缩根因定位:** 通过 6 组消融识别 Projector 扰动为塌缩根因。

未来方向: **RL + SPICE 网表格式对齐:**

当前模型输出为自由文本格式 (“R1 10k Ω $\pm$ 1%”), 距可直接仿真验证的 SPICE 网表 (“R1 NET1 NET2 10k”) 仍存在格式、语义、结构三个层次的不匹配。设计两阶段方案:

阶段 1: SPICE 格式 SFT (监督预热)。从 KiCad 网表自动生成 (图片, SPICE 文本) 对齐数据, 在现有 LoRA 权重基础上继续 SFT, 使模型学会 SPICE 语法和节点编号约定。

阶段 2: RL 格式对齐 (GRPO)。设计三组件 reward 函数:

- **语法分:** SPICE 解析器成功解析输出为有效网表 (0/1);
- **元件分:** 预测元件标号集合与 GT 的 F1;
- **连接分:** 相同网络的所有引脚共享一致节点编号。

使用 Group Relative Policy Optimization (GRPO) 在 SPICE 语法约束下最大化综合 reward。预期将输出从 OCR 自由文本升级为可直接导入 KiCad/LTspice 的结构化网表。

8 模型微调与实验

8.1 基座模型性能

未微调的 PaddleOCR-VL-0.9B 基座模型在 30 样本测试集上 CompF1 = 0.0000, JointF1 = 0.0000, NED = 0.9437。基座输出为预训练数据中的幻觉文本 (如“Service Name / Data Source”), 完全无法识别电路元件。这表明通用 VLM 不经领域微调无法处理电路原理图 OCR 任务。

8.2 Phase 1: 四组控制变量实验（1,200 样本）

基于 1,200 张真实 KiCad 电路图进行四组实验，所有实验采用 LoRA ($r = 16, \alpha = 32$)，冻结 Projector，手工 CE Loss，分离 Tokenization，在 RTX 4060 8GB 上训练。

表 4: Phase 1 实验结果（30 样本测试集）

实验	配置	CompF1	关键发现
exp1 (Baseline)	384px, lr=2e-5, do=0.05	0.037	全部输出数字序列（模态塌缩）
exp2 (HiRes)	512px, lr=2e-5	0.058	高分辨率无显著收益
exp3 (Anti-Overfit)	lr=1e-5, do=0.10, 3ep	0.028	训练验证逐渐恢复，测试仍塌缩
exp4 (Unfrozen)	384px, 解冻 Projector	0.092	CompF1 最高但输出仍为数字序列

核心发现：（1）解冻 Projector 导致严重模态塌缩——视觉特征扭曲为分布外向量，LLM 退化为高频 token 重复；（2）低 LR + 高 Dropout 在小数据集上有正向增益；（3）Loss 最优的 checkpoint 不等于质量最优。

8.3 Phase 2: 合成数据防塌缩（1,500 样本）

Phase 1 全部模型均出现不同程度的模态塌缩。Phase 2 引入 300 张合成文字图片以 20% 比例混入训练集（总计 1,500 样本），强制模型建立视觉-文字对齐。

表 5: Phase 2 实验结果（30 样本测试集）

实验	CompF1	JointF1	NED
exp5 (Anti-Overfit + Synth, lr=1e-5, do=0.10)	0.126	0.011	0.941
exp6 (Baseline + Synth, lr=2e-5, do=0.05)	0.156	0.011	0.941
基座模型	0.000	0.000	0.944

核心发现：合成数据混合可有效缓解模态塌缩。CompF1 相比 Phase 1 基线提升 $4.2\times$ ($0.037 \rightarrow 0.156$)，JointF1 提升 $2.2\times$ ($0.005 \rightarrow 0.011$)。训练验证显示 exp5 在 S200 即产生合理的电路元件输出，S200-S800 持续稳定。

8.4 Phase 3: 更大 LoRA 与格式微调（exp7/exp8）

在 exp6 最优配置基础上尝试两个方向：

exp7: LoRA $r = 32$ + 两阶段训练。 增大 LoRA 秩至 $r = 32$ ($\alpha = 64$)，先合成数据预训练再电路数据微调。结果 CompF1 = 0.084，JointF1 = 0.000——更大的 LoRA 秩未带来增益，两阶段训练反而导致之前学到的能力遗忘。

exp8: SPICE 格式微调。 在 exp6 权重上继续微调 1 epoch，目标标签转换为 SPICE 网表格式（“R1 N1 N2 10k”）。结果 CompF1 = 0.042，JointF1 = 0.000，但 30/30 个测试样本均输出 SPICE 格式——模型成功学会了格式转换，但以牺牲识别精度为代价。

BPE 边界合并修复。 Prompt 和 label 分别独立分词后在 token ID 空间拼接，避免 BPE 在边界合并字符对（如“\nR”→单 token）导致 label 首字符被吞。

8.5 合成KiCad预训练：规模化合成数据实验

为突破 1,200 张训练样本的数据量瓶颈，采用 kicad-cli 程序化生成 5,000 张 KiCad 原理图。生成流程：Python 脚本随机组合 10 类元件符号（电阻、电容、电感、二极管、BJT、MOSFET、运放、稳压器、连接器、电源符号），自动生成网表并通过 kicad-cli 导出 SVG，再经 cairosvg 渲染为 PNG。GT 从 SVG stroked-text 可见文字提取，与渲染图像完全对齐。全部 5,000 张为纯合成数据，未混入任何真实电路图。

采用两阶段训练策略：

- **阶段 1：合成预训练。**在 5,000 张合成 KiCad 原理图上进行 LoRA 微调（ $r = 16$, $\alpha = 32$ ，冻结 Projector），使模型建立对电路原理图视觉风格和元件标号的基本识别能力；
- **阶段 2：真实数据微调。**在 exp6 的 1,200 张真实 KiCad 训练集上继续微调，进行领域适配。

表 6: 合成KiCad预训练实验结果（30 样本测试集）

模型/阶段	CompF1	JointF1	NED	说明
基座模型	0.000	0.000	0.944	通用VLM，无领域微调
exp6（合成文字20%混合）	0.156	0.011	0.941	此前最优，300张合成文字
Phase 1 合成预训练（阶段1）	0.304	0.005	0.942	5,000张合成KiCad，仅预训练
Phase 1 + 阶段2 微调	塌缩	0.000	—	真实数据微调后塌缩




图 6: 多模型对比：基座、v1 (exp6) 和 v2 (Phase 1) 的 CompF1 与 JointF1。左侧为 F1 对比，标注 4.2× 和 2.5× 提升倍数；右侧为 NED 对比。

核心发现：

1. **纯合成预训练效果显著：**阶段1 的 $\text{CompF1} = 0.304$ ，较 exp6 (0.156) 提升约 2.5 倍，验证了规模化合成 KiCad 数据对元件标号识别的有效性；

2. **JointF1 未见改善**: JointF1 = 0.005, 低于 exp6 的 0.011——合成 KiCad 原理图中标号与参数值的空间配对关系与真实电路图存在分布差异, 模型未能在预训练阶段学到正确的标号-参数值关联;
3. **阶段2 微调塌缩**: 在合成预训练权重上继续进行真实数据微调, 模型迅速塌缩 (JointF1 = 0.000)——合成数据与真实数据之间的分布偏移导致灾难性遗忘, 两阶段训练策略需要更精细的混合比例或渐进式领域适配;
4. **合成数据规模化路径可行**: CompF1 = 0.304 的结果证实, kicad-cli 程序化生成的合成原理图可以作为有效的预训练数据源, 为未来更大规模 (数万至数十万张) 的合成预训练提供了可行路径。

9 讨论

9.1 合成数据为何有效

合成文字图片具有确定的视觉→文字映射关系。当模型面对无法通过统计模式匹配的输入时, 降低 loss 的唯一路径是读取图片中的文字。这迫使视觉编码器保持活跃, 防止 LLM 退化为高频 token 重复。20% 的混合比例在缓解塌缩和保持领域适应性之间取得了平衡。

9.2 数据质量优先于数据数量

早期实验表明, V4 的 5,686 样本因格式失配和 22,340 个重复噪点导致训练信号严重污染。而经过 7 轮验证的 1,200 样本训练出的 exp6 模型 CompF1 达到 0.156——精标小数据集的训练效果优于粗标大数据集。

9.3 当前瓶颈

合成文字混合策略将 CompF1 从基座 0 提升至 exp6 的 0.156, 而 5,000 张合成 KiCad 预训练进一步推至 0.304 (较 exp6 提升约 2.5 倍), 验证了合成数据规模化对元件标号识别的显著增益。然而 JointF1 在两种策略下均未见改善 (exp6: 0.011, 合成预训练: 0.005), 距可用的 0.05 阈值仍有数量级差距。标号-参数值配对 (KIE) 仍是电路 OCR 的核心瓶颈——合成数据难以模拟真实电路图中标号与参数值的空间布局关系。Phase 2 微调塌缩进一步表明, 合成到真实的分布偏移需要渐进式适配策略。更大 LoRA 秩 ($r = 32$)、两阶段训练和 SPICE 格式微调在当前数据规模下均未能超越合成预训练的 CompF1 水平。

10 结论

10.1 主要贡献

1. **数据集**: 1,820 样本经 7 轮验证, 标注准确率 >99%, 附质量报告与多维难度标签;
2. **合成数据规模化**: 合成文字 20% 混合提升 CompF1 4.2×; kicad-cli 生成 5,000 张合成 KiCad 原理图, 纯合成预训练 CompF1 达到 **0.304** (2.5× 提升)。JointF1 仍为 0.005–0.011, 标号-参数值联合识别是核心瓶颈;
3. **系统消融**: 8 组实验系统对比分辨率、LoRA 秩、投影器、合成数据、SPICE 等维度。关键发现: 冻结 Projector 防止塌缩; 数据质量优先于数据数量;

4. **完整开源**：数据集、双版本 LoRA 权重（exp6 + Phase 1）、技术报告、Beamer、在线 Demo 均已发布。

11 技术文档与开源贡献

本项目提供完整的多层次文档体系和全开源生态：

- **技术报告**：24 页中英文技术报告（LaTeX 源码），覆盖数据集、实验、分析全流程；
- **Beamer 展示**：35 页演示文稿，含 15+ 张数据可视化图表；
- **数据集文档**：独立数据集仓库，含完整数据收集流程、标注规范、质量报告、可视化对比；
- **在线 Demo**：HuggingFace Space 交互式体验（含预计算示例和标注说明）；
- **LoRA 权重**：HuggingFace Models 公开发布（.pdparams 格式）；
- **代码可复现**：6 组实验脚本、数据生成/清洗/评估全管线，单卡 RTX 4060 8GB 可运行。

所有资源均采用 MIT 协议开源，链接汇总于项目 README：<https://github.com/ZhangJ83/circuit-ocr-paddle>。

12 开源资源

1. 项目仓库：<https://github.com/ZhangJ83/circuit-ocr-paddle>
2. 数据集：https://github.com/ZhangJ83/circuit_ocr_dataset_final
3. LoRA 权重：<https://huggingface.co/yingchu83/CircuitOCR-lora>
4. 在线 Demo：<https://huggingface.co/spaces/yingchu83/CircuitOCR>
5. 技术报告（中/英文）：https://github.com/ZhangJ83/circuit-ocr-paddle/tree/master/arxiv_template

A 早期实验记录（V5–V8）

以下为 Phase 1 之前的早期探索实验，包括模态塌缩根因定位（E1–E6）和 V5/V8 模型迭代过程。这些内容已不属于当前推荐方案，仅作为历史记录供参考。

A.1 模态塌缩根因实验（E1–E6）

初期 LoRA 实验（ $r = 8$ ）在旧版数据集上训练后，观察到输出多样性极低——几乎所有测试样本输出完全相同的“12, 100, 100...”序列。通过六组控制变量实验系统定位根因：

核心发现：Projector（mlp_AR, 25.9M 参数）被 LoRA 扰动后输出分布外向量，LLM 退化为高频 token 机械重复。LLM-Only LoRA（冻结 Projector）是安全策略。

A.2 V5: LLM-Only LoRA 验证

V5 采用冻结 Projector、仅微调 LLM 自注意力（ $r = 8$, 1.25M 参数），384px 分辨率， 2×10^{-5} 学习率。在 1,857 样本上训练 1 epoch 后多样性达 90%，首次实现不同图像输出不同内容。但 $r = 8$ 容量不足，约 200 步过早收敛。

表 7: 模态塌缩根因排查实验（历史记录）

实验	变量	结果	结论
E1: 空白图	真实图 vs 纯灰图	输出不同	视觉编码器工作正常
E2: 分辨率	168px vs 336px	仍坍塌	分辨率不是根因
E3: epoch 数	1 vs 3 epoch	NED 改善	多 epoch 有正向增益
E4: LoRA 层	增加 Projector	NED 改善	Projector 是关键瓶颈
E5: LoRA rank	$r = 8 \rightarrow r = 16$	NED 改善	容量有效但多样性仍低
E6: LLM-Only	冻结 Projector	多样性 90%	塌缩彻底解决

A.3 V8-Fixed

V8-Fixed 继承 LLM-Only 架构，采用宽 LoRA ($r = 16$, 5.7M 参数)，修复因果 token 双重偏移 bug 和 BPE 边界合并问题。在 easy100 测试集上取得 NED = 0.7760（基座 0.9372，相对错误率削减 17.2%）。

A.4 基座模型与微调模型输出对比

以下展示 5 个测试样本上基座模型（未经微调的 PaddleOCR-VL-0.9B）、exp6 微调模型（LoRA $r = 16$ ，合成数据 20% 混合）与标准标注（GT）的对比。基座模型输出为预训练数据中的幻觉文本，与电路完全无关；微调后模型开始输出电路领域内容（元件标号、电压值），但仍存在数值幻觉和复杂样本上的塌缩。

样本 0（17 个元件）：基座输出为“Service | Name / Service Name | SERVING”等通用 API 文本，与电路原理图毫无关联。微调后模型输出“1, 2, 3, 4...”数字序列——在该样本上发生了部分塌缩，但已从通用文本转向结构化输出。

样本 2（22 个元件）：基座输出为“Model | Model Name / T-SNE | T-SNE / PCA | PCA”等机器学习术语。微调后输出“C1, C2, C3, C4...”——虽然未能匹配具体的电容编号，但已从完全无关的文本转向电路元件标号，体现了领域适配的效果。

样本 5（36 个元件）：基座输出为“Name: ____ / Time: 51-34 / Place: ____”等填表模板。微调后输出“+3.3V, +3.3V, +3.3V...”——虽然存在电压值重复（数值幻觉），但已识别出电路中的电源网络特征。

样本 8（42 个元件）：基座输出为“Category | Data Point 1 (X, Y) | Data Point 2 (X, Y)”等数据表格描述。微调后输出“APP P7016, 1, 2, 3...”——部分读取了“AMP POWER”（识别为“APP”），体现了对电路文字的初步识别能力。

样本 12（29 个元件）：基座输出为“This image is a graphic design and does not contain any chart...”等图像描述文本。微调后输出“+3.3V”的重复序列——模型识别到电路中的电压标签但产生了重复。

改进总结：基座模型在所有 5 个样本上均输出与电路无关的预训练幻觉文本（API 文档、ML 术语、表单模板、图表描述、图像说明），CompF1 = 0.0000，JointF1 = 0.0000。经合成数据混合策略微调后，exp6 模型的 CompF1 提升至 0.1564，JointF1 提升至 0.0111。虽然仍存在数值幻觉和复杂结构上的塌

缩，但模型已从输出通用文本转变为输出电路领域词汇（元件标号 C1-C8、电压值 +3.3V/+5V、元件名 AMP/APP 等），证明了合成数据策略对领域适配的有效性。

References

- bshada. Open schematics: A dataset of electronic schematics from hardware projects, 2025. URL <https://huggingface.co/datasets/bshada/open-schematics>. License: CC-BY-4.0.
- Jitendra Bhandari, Vineet Bhat, Yuheng He, Hamed Rahmani, Siddharth Garg, and Ramesh Karri. Masala-chai: A large-scale spice netlist dataset for analog circuits by harnessing ai, 2025. URL <https://arxiv.org/abs/2411.14299>.
- Cheng Cui, Ting Sun, Suyin Liang, Tingquan Gao, Zelun Zhang, Jiaxuan Liu, Xueqing Wang, Changda Zhou, Hongen Liu, Manhui Lin, Yue Zhang, Yubo Zhang, Handong Zheng, Jing Zhang, Jun Zhang, Yi Liu, Dianhai Yu, and Yanjun Ma. Paddleocr-vl: Boosting multilingual document parsing via a 0.9b ultra-compact vision-language model, 2025. URL <https://arxiv.org/abs/2510.14528>.
- Jianning Zhang and Yifei Chen. A synthetic dataset for circuit schematic ocr and netlist extraction, 2026. URL <https://github.com/ZhangJ83/circuit-ocr-dataset>.