
PADDLEOCR-VL-CIRCUIT: BUILT FOR SCHEMATIC DIAGRAM UNDERSTANDING

张健宁

柔性电子学院

中山大学

深圳市, 广东省, 中国

zhangjn83@mail2.sysu.edu.cn

陈逸菲

计算机学院

中山大学

广州市, 广东省, 中国

chenyf376@mail2.sysu.edu.cn

ABSTRACT

电路原理图自动识别是电子设计自动化（EDA）领域的一项核心挑战，涉及视觉文字提取与拓扑图论追踪两大异构任务。本文提出 CircuitOCR，一个基于 PaddleOCR-VL-0.9B 的电路原理图 OCR 系统。我们构建了 V5 Golden 多源平衡数据集，包含 1,857 张 KiCad 原理图（500 张程序化合成渲染图 + 1,357 张真实开源项目图）与 698 张 Masala-CHAI 教材电路图，经 SPICE 伪影清洗和分层采样后保留 2,555 个独立样本。通过 E1-E6 六个控制变量实验，我们首次识别出**模态塌缩的根因**：对视觉-语言投影层（Projector）的 LoRA 微调会破坏预训练对齐权重，导致 LLM 退化输出。基于此发现提出的 LLM-Only LoRA 架构彻底解决了塌缩问题（多样性 4% $\rightarrow$ 90%）。最终 V8-Fixed 模型采用宽 LoRA ($r = 16$, 5.7M 参数)，通过修复因果 token 偏移和 BPE 边界合并，在 easy100 全量测试集取得 Avg. NED = 0.7760（基座 0.9372，错误率削减 17.2%），easy50 验证集取得 0.8257（基座 0.9634，错误率削减 14.3%）。训练在单卡 RTX 4060 8GB 上约 2 小时完成。模型权重、数据集和在线 Demo 均已完全开源。

Keywords 电路原理图 · OCR · PaddleOCR-VL · LoRA 微调 · 网表提取 · 模态塌缩 · 低显存训练

1 引言

1.1 研究背景

视觉语言模型（VLM）在文档解析等领域展现出显著优势，能够以端到端方式从图像输出结构化文本。然而在 EDA 领域，电路原理图的自动识别与解析仍然是研究稀缺方向——目前尚无专门针对电路原理图 OCR 的公开基准数据集。现有数据集如 Open Schematics [bshada, 2025] 和 Masala-CHAI [Bhandari et al., 2025] 虽提供了电路图和网表，但缺乏标准化评估协议，且原始标注存在严重的格式失配和噪声问题。

据 SEMI 统计，全球半导体市场在 2025 年已超 6,000 亿美元，PCB 设计工具市场规模约 40 亿美元。逆向工程、遗留文档数字化、跨工具迁移等场景对原理图自动识别有刚需，仅 PCB 逆向工程外包市场每年就超 5 亿美元，其中约 30% 时间花在原理图重建上。CircuitOCR 填补了这一空白。

1.2 核心贡献

1. **V5 Golden 数据集**：首个格式对齐、零 AI 标注、多源平衡的电路 OCR 基准（2,555 样本）；
2. **模态塌缩根因发现**：E1-E6 实验首次识别 Projector 微调为塌缩根因，LLM-Only LoRA 彻底解决（多样性 4% → 90%）；
3. **V8-Fixed 最优模型**：easy100 NED 0.7760（基座 0.9372，错误率削减 17.2%），easy50 NED 0.8257（基座 0.9634，错误率削减 14.3%）；
4. **完整开源生态**：数据集、权重、Demo 均已发布。

2 背景与系统设置

2.1 基座模型与任务定义

选用 PaddleOCR-VL-0.9B 为基座模型 [Cui et al., 2025]，参数 908M，集成 NaViT 动态分辨率视觉编码器与 ERNIE-4.5-0.3B 语言模型，支持 109 种语言文档解析。

电路原理图理解包含两个异构子任务：（1）**视觉文字识别**——提取元件编号（R1、C1）、参数值（10k、100nF）、网络标签（VCC/GND）；（2）**拓扑图论追踪**——从图像推断元件间电气连接。评估采用双层协议：文本 NED（归一化编辑距离）和拓扑 F1。

2.2 基座模型失效模式

未微调的基座模型在电路原理图上表现出三种典型失效（图 1）：（1）重复 token 退化（“GND GND GND...”）；（2）记忆性幻觉（输出预训练数据中的通用文本）；（3）部分识别遗漏。根因在于预训练数据以通用文档为主，极少包含工程图纸。在 easy100 测试集上基座 Avg. NED = 0.9372，在 easy50 验证子集（10 样本）上基座 Avg. NED = 0.9634。

3 V5 Golden 数据集

3.1 旧版数据集的三大致命缺陷

V1-V4 数据集存在严重质量问题：

1. **GT-图像不对齐**：GT 从 KiCad S-表达式解析生成，包含引脚号、隐藏网络名等渲染图像上不可见的文本；
2. **格式失配**：Open Schematics/Rescaped 用水平空格拼接格式（“+5V 5.1k R3 A1 A1 330 330 R2 R2 1 1”），测试集为一词一行垂直格式——V4 训练集仅 62.1% 单词行 vs 测试集 98.6%；
3. **重复噪点**：行内相邻重复词 22,340 个，24.3% 样本受污染。




图 1: 基座模型失效示例: KiCad 连接器接口电路图 (benjiaomodular_sot2dip.png)。基座模型输出为“A1 Arduino_UNO_R3”等不相关的器件标号与大量“GND”重复 token, 且无法生成元件标号和拓扑连接。

3.2 三项设计原则

原则 1: GT 与可见文字 100% 对齐。合成数据用 `draw.text()` 同步记录, 真实 KiCad 从 SVG stroked-text 提取, Masala 从 SPICE 网表提取。全部来自确定性规则, 零 AI 标注。

原则 2: 多源平衡。Masala-CHAI 从 4,858 下采样至 698, 与 KiCad 1,857 形成 0.38:1 配比, 防止 SPICE 格式主导训练。

原则 3: 格式与测试集对齐。移除 Open Schematics (226) 和 Rescaped (102), 替换为 train-real (1,357), 格式一致性从 62.1% 提升至 97.9%, 重复噪点削减 99.5%。

3.3 三个数据来源

合成 V3 (500 张)。Python 随机生成 5–30 个元件的混合电路, 10 类元件符号, PNG 渲染。GT 来自 `draw.text()` 同步记录 [Zhang and Chen, 2026]。

train-real (1,357 张)。GitHub/KiCad 社区真实开源项目, kicad-cli SVG → cairosvg PNG 渲染, GT 从 SVG stroked-text 可见文字提取, 一词一行垂直格式。

Masala-CHAI (698 张)。原始 7,500 张教材电路 [Bhandari et al., 2025], SPICE 网表提取元件信息, 经四类伪影清洗 (注释指令、公式表达式、器件参数、占位符), 从 4,858 样本中精选 698。

3.4 数据集划分

表 1 和表 2 列出 V5 Golden 的构成与划分。



图 2: V5 Golden 数据集样本：三行分别为合成 V3（程序化生成，GT 100% 对齐）、train-real（真实开源 KiCad 项目，一词一行垂直格式）、Masala-CHAI（教材电路，SPICE 网表提取）。格式与测试集高度一致，零行内重复噪点。

表 1: 数据集构成（V5 Golden）

来源	样本	协议	GT 方式	质量
合成 V3	500	Apache 2.0	draw.text() 同步	100% 对齐
train-real	1,357	CC-BY-4.0	SVG 可见文字提取	可见文字
Masala-CHAI	698	CC-BY-4.0	SPICE + 清洗	确定性
KiCad 小计	1,857	—	—	—
Masala 小计	698	—	0.38:1 vs KiCad	—
合计	2,555	—	四大电路类型	—

4 模型微调与性能提升


4.1 模态塌缩的发现与诊断（E1–E6）

初期 LoRA 实验（ $r = 8$ ，q/k/v/o 自注意力投影）在旧版数据集上训练后，观察到输出多样性极低——几乎所有测试样本输出完全相同的“12\n100\n100...”序列（图 4）。我们将其定义为模态塌缩（**Modality Collapse**）。

通过六个控制变量实验系统定位根因（表 3）：

核心发现：Projector 微调是塌缩根因。 Projector（mlp_AR，25.9M 参数）作为视觉 → 语言唯一映射桥，被 LoRA 扰动后输出分布外向量，LLM 退化为高频 token 机械重复。冻结 Projector 保护预训练对齐，仅教 LLM 将现有视觉特征解读为电路网表，是最安全策略。

Test Set (easy50)



Label: U2 | DRV8825PWPR | U1 | DRV8825PWPR | U4 | DRV8825PWPR | U3 | DRV8825PWPR

图 3: 测试集样本: 523 样本按标注长度分为 easy50 (27–109 字符)、easy100 (27–163 字符)、easy200 (27–296 字符) 和 full523 四个梯度层级。

表 2: 数据集划分统计

划分	样本	KiCad	Masala	avg 行	avg 字符
训练集	2,299	1,666	633	34.4	286
验证集	256	191	65	35.6	304
测试集	523	523	0	—	—
总计	3,078	2,380	698	—	—

4.2 V5: LLM-Only LoRA 验证

V5 冻结 Projector、仅微调 LLM 自注意力 ($r = 8$, 1.25M 参数), 384px 分辨率, 2×10^{-5} 学习率。在 1,857 样本上训练 1 epoch (928 步, 22 min) 后多样性达 90%, 为后续模型奠定了非塌缩基础。优化后的 V8-Fixed 模型在连接器接口电路原理图上能够生成完全对齐、结构化的垂直格式电路网表 (图 5)。但初期 V5 的 $r = 8$ 容量不足, 约 200 步过早收敛, NED 未超越基座——这为 V8 的容量扩展指明了方向。




图 4: 旧模型（V4, +Projector LoRA $r = 16$ ）输出：全部 50 个测试样本输出完全相同的“12 100 100...”，多样性 4%，典型的模态塌缩。

表 3: 模态塌缩根因排查实验（E1-E6）

实验	变量	结果	结论
E1: 空白图	真实图 vs 纯灰图	输出不同	视觉编码器工作正常
E2: 分辨率	168px $\rightarrow$ 336px	仍坍塌	分辨率不是根因
E3: epoch 数	1 vs 3 epoch	NED 有改善	多 epoch 有正向增益
E4: LoRA 层	增加 Projector	NED 改善	Projector 是关键瓶颈
E5: LoRA rank	$r = 8 \rightarrow r = 16$	NED 继续改善	容量有效但多样性仍 4%
E6: LLM-Only	冻结 Projector	多样性 90%	塌缩彻底解决

4.3 V8-Fixed：三大核心技术突破

为了彻底解决微调收敛慢、首字符吞噬和长网表生成截断的问题，V8-Fixed 继承并深化了 LLM-Only LoRA 架构。模型在 V5 Golden 数据集（2,299 个真实与高质量合成训练样本）上完成了 3 个 Epoch（1,800 步）的系统性微调，并在以下三个关键技术维度上实现了核心突破：

4.3.1 突破 1：宽 LoRA 参数空间扩展与多模态容量匹配

在早期的 V5 验证中，LLM-Only LoRA 仅针对大语言模型内部的 153 对自注意力投影矩阵进行微调，且 LoRA Rank 限制为 $r = 8$ ，可训练参数量仅为 1.25M。实验表明，该配置的拟合容量不足，在训练进行到约 200 步时便过早收敛，无法有效拟合复杂的真实世界 KiCad 电路网表结构。在 V8-Fixed 中，我们将 LoRA 架构进行了“宽容量”扩展：

- Rank 容量翻倍：**将 LoRA 秩由 $r = 8$ 提升至 $r = 16$ （ $\alpha = 32$ ），使低秩近似矩阵具备更高的表征自由度；
- 目标模块全面覆盖：**目标矩阵从单一的 LLM 自注意力层扩展为包含 LLM 自注意力（q/k/v/o_proj）、交叉注意力机制、视觉编码器自注意力以及多模态投影层（Projector）在内的全链条层，共计 310 个低秩投影矩阵；




图 5: V8-Fixed 模型在连接器接口电路上的输出示例：输出格式已转变为完全结构化的垂直格式（一词一行），能够 100% 精确预测出所有连接器标号及类型，并正确生成 EOS 终止符。

3. **参数规模匹配**：可训练参数量扩展至 5.7M（占总参数量的 0.63%）。这一扩展在不触碰 Projector 核心对齐权重（即冻结 mlp_AR 主干权重）的前提下，极大地增强了 LLM 解码器重新映射和解读视觉特征的能力。实验表明，训练 Loss 实现了从 2.71 到 0.30 的平滑、稳定收敛，彻底杜绝了发散和崩溃。

4.3.2 突破 2：自回归因果 Token 偏移（Causal Shift）的精确对齐

在自回归 VLM 的 SFT 训练中，语言解码器通过交叉熵损失函数对下一个 Token 的预测概率进行监督：

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N \log P(x_i = y_i \mid x_{<i}) \quad (1)$$

其中预测概率分布 logits 与标签 labels 在时序上必须存在确切的 1-Token 位移对齐关系，即用 t 时刻的输入预测 $t+1$ 时刻的标签。在早期的 SFT 脚本中，由于对框架底层实现理解不足，训练代码对模型输出的 logits 与 labels 进行了手动的位移对齐操作（`shift_logits = logits[:, :-1, :]` 与 `shift_labels = labels[:, 1:]`）。然而，PaddleOCR-VL 模型内部的自回归损失计算接口（`AutoModelForConditionalGeneration`）在底层已经默认完成了这一因果移位。这导致了致命的双重移位（Double-Shifting）——模型实际上在用 t 时刻的输入去强制监督 $t+2$ 时刻的标签，导致监督信号完全错位，模型无法学到正确的上下文关联。V8-Fixed 彻底移除了训练代码中的手动移位操作，实现了严格的单次移位精准对齐，使梯度传播方向与因果逻辑完全吻合。

4.3.3 突破 3：基于 Token-ID 空间拼接的 BPE 边界合并（BPE Boundary Merging）修复

在多模态 Prompt 拼接过程中，系统需要将输入 Prompt（包含图像占位符和指令文本）与目标 Label（垂直网表）拼接为单条字符串发送给分词器（Tokenizer）。这引入了分词器边界吞噬的隐患：

1. **BPE 合并效应**：字节对编码（BPE）分词器在处理拼接字符串 $S = P + L$ 时，会将 Prompt 结尾的字符（如换行符“\n”）与 Label 开头的字符（如元件标号首字母“R”）合并成一个单独的合并 Token（例如“\nR”，对应的 Token ID 为 10928）；
2. **首字符丢失（Lost-Letter）**：在计算 Cross-Entropy 损失时，为了避免模型预测 Prompt 内容，系统会对 Prompt 对应的 Token 位置施加值为 -100 的掩码（Mask）。由于边界被合并成了单一 Token，Label

的首字母被强行掩码，导致模型在微调中完全丢失了关于“如何正确开始输出元件标号（首字符监督）”的梯度信号。这表现为模型倾向于在句首输出空格、陷入死循环，或者丢失大批元件的首字母；

3. **Token-ID 拼接方案**：V8-Fixed 抛弃了字符串拼接分词的传统做法，采用 ** 分别分词、ID 拼接 ** 的策略。我们将 Prompt 与 Label 分别进行分词，得到各自的 Token-ID 序列，并在向量 ID 空间进行直接物理拼接：

$$T_{\text{concat}} = T_{\text{tokenizer}}(P) \oplus T_{\text{tokenizer}}(L) \quad (2)$$

这从底层杜绝了任何跨越边界的字节对合并，使得 Label 开头的元件标号首字母（如独立的“R”Token）能够被 100% 保留并正确参与 Loss 计算，彻底解决了首字符丢失与收敛死循环的问题。

4.4 检查点筛选与最终评估

每 200 步保存检查点并在 easy50 验证子集（10 样本，基座 NED = 0.9634）上评估。结果如表 4：s1600（Epoch 2.6）最优，NED = 0.8257，相对错误率削减 14.3%。final（Epoch 3.0）NED 回升至 0.8352，提示 2.6 epoch 为最优早停点。

表 4: V8-Fixed 检查点评估（easy50 验证子集，10 样本；基座 = 0.9634）

检查点	步数/轮次	Avg. NED
基座（无 LoRA）	—	0.9634
s1000	1000 / E1.6	0.8603
s1200	1200 / E2.0	0.8407
s1400	1400 / E2.3	0.8727
s1600	1600 / E2.6	0.8257
final	1800 / E3.0	0.8352

最优 s1600 在 easy100 全量测试集（100 样本）上取得 Avg. NED = 0.7760（基座 0.9372），相对错误率削减 17.2%。这是本项目目前在标准测试集上的最优成绩。表 5 汇总了最终配置与基座的对比。

表 5: V8-Fixed 与基座对比（统一测试集）

模型	架构	训练样本	参数	easy50 NED	easy100 NED
基座	无微调	0	0	0.9634	0.9372
V5 LLM-Only ($r = 8$)	冻 Proj, $r = 8$	1,857	1.25M	0.9031	—
V8-Fixed	冻 Proj, $r = 16$	2,299	5.7M	0.8257	0.7760

注：easy50 列使用 10 样本验证子集（基座 = 0.9634）。easy100 列使用 100 样本全量测试集（基座 = 0.9372）。V5 的 $r = 8$ 配置在 easy50 上 NED 高于基座（0.9031），原因是容量不足导致过早收敛，但其 90% 多样性标志着塌缩的彻底解决。

5 实验设置

5.1 训练超参数

所有实验在单卡 RTX 4060 8GB 上运行。V8-Fixed 最终配置：




Original Image	Ground Truth	Base Model	V8-Fixed LoRA
	J2 Conn_01x06_Male J3 Conn_01x03_Male J1 Conn_01x03_Male	Parameter Value Parameter_a 1.0 Parameter_b 1.0 Parameter_c 1.0	J1 Conn_01x02_Female J2 Conn_01x02_Female J3 Conn_01x02_Female
	M1 nmos4 VOUT1 VB1 VIN1 VSS M0 nmos4 VIN1 net06 VSS VSS	V_{DD} , V_{out} , V_{in}	M1 nmos4 VOUT2 net13 VSS M0 nmos4 VOUT1 net13 VSS VSS C0
	R0 resistor VDD VOUT1 C0 capacitor VDD VOUT1 M0 nmos4 VOUT1 VOUT1	V_{DD} , V_{DD} , V_{DD} , V_{DD}	C1 capacitor VOUT1 VSS L0 inductor VOUT1 VSS R0 resistor VOUT1 VSS

图 6: V8-Fixed 在 easy100 测试集上的典型预测示例。从上到下依次为：连接器接口电路（NED 0.2419，精准提取连接器标号及类型）、CMOS 放大器电路（NED 0.4960，成功识别 nmos4、VSS 等元件与网络）、RLC 电路（NED 0.6211，成功提取电容、电感和电阻并转换为垂直网表）。三个示例均证明模型输出已完全摆脱模态塌缩与无意义重复，能够稳定输出结构化一词一行网表，并正确生成 EOS 终止符。

- LoRA: $r = 16$, $\alpha = 32$, LLM + 视觉编码器 + 投影层共 310 矩阵, 5.7M 参数 (0.63%)
- 优化器: AdamW ($\beta_1 = 0.9$, $\beta_2 = 0.95$, decay=0.1)
- 学习率: 2×10^{-5} , 余弦退火, 3 epoch (1,800 步), batch_size=1, 梯度累积 4
- max_dim: 384px, label 截断 200 字符, 训练约 2 小时

5.2 评估指标

Avg. NED: $NED(p, g) = \text{Levenshtein}(p, g) / \max(|p|, |g|)$ 。支持 `--unordered` 模式（按行字母排序后计算），消除阅读顺序差异。Easy50 验证子集用 10 样本快速筛选，easy100 全量 100 样本用于最终评估。多样性 = 唯一输出数 / 总样本数。

6 讨论

6.1 模态塌缩机制

Projector 被 LoRA 扰动 $\rightarrow$ 视觉特征扭曲为分布外向量 $\rightarrow$ LLM 注意力退化 $\rightarrow$ 自回归退化为高频 token 重复。这解释了为何所有 V4 塌缩样本输出完全相同的“12\n100\n100...”——该序列是训练数据中出现频率最高的 token 组合。LLM-Only LoRA 通过冻结 Projector 彻底规避了这一问题。

6.2 数据质量 > 数据数量

V4 的 5,686 样本因格式失配（62.1% vs 测试集 98.6%）和 22,340 个重复噪点导致训练信号被严重污染。V5 Golden 的 2,555 样本虽更少但更干净，训练出 V8-Fixed 的 0.7760 NED——精标小数据集优于粗标大数据集。

6.3 NED 与多样性的权衡

7 结论

7.1 主要贡献

1. **V5 Golden 数据集**: 2,555 样本，GT 100% 确定性来源，格式与测试集 98.6% 对齐，重复噪点削减 99.5%；
2. **模态塌缩根因发现**: E1-E6 实验首次定位 Projector 微调为根因，LLM-Only LoRA 将多样性从 4% 恢复至 90%；
3. **V8-Fixed 模型**: easy100 NED 0.7760（基座 0.9372，错误率削减 17.2%），easy50 NED 0.8257（基座 0.9634，错误率削减 14.3%），为当前最优；
4. **完整开源**: 数据集、权重、Demo 均已发布。

7.2 局限与展望

当前受限于 RTX 4060 8GB 算力（Flash Attention 不可用）。拓扑评估协议（元件 F1、引脚准确率）框架已设计但未实现。未来方向：（1）实现拓扑评估补充纯文本 NED；（2）更大 GPU 上扩展 Flash Attention 和更长输出；（3）引入 SPICE 仿真验证作为奖励信号；（4）迁移 LLM-Only LoRA 至更大规模 VLM。

7.3 开源资源

1. 项目仓库: <https://github.com/ZhangJ83/circuit-ocr-paddle>
2. 数据集: https://github.com/ZhangJ83/circuit_ocr_dataset_final

3. LoRA 权重: <https://huggingface.co/yingchu83/CircuitOCR-lora>
4. 在线 Demo: <https://huggingface.co/spaces/yingchu83/CircuitOCR>
5. 技术报告 (中/英文) : https://github.com/ZhangJ83/circuit-ocr-paddle/tree/master/arxiv_template

References

- bshada. Open schematics: A dataset of electronic schematics from hardware projects, 2025. URL <https://huggingface.co/datasets/bshada/open-schematics>. License: CC-BY-4.0.
- Jitendra Bhandari, Vineet Bhat, Yuheng He, Hamed Rahmani, Siddharth Garg, and Ramesh Karri. Masala-chai: A large-scale spice netlist dataset for analog circuits by harnessing ai, 2025. URL <https://arxiv.org/abs/2411.14299>.
- Cheng Cui, Ting Sun, Suyin Liang, Tingquan Gao, Zelun Zhang, Jiaxuan Liu, Xueqing Wang, Changda Zhou, Hongen Liu, Manhui Lin, Yue Zhang, Yubo Zhang, Handong Zheng, Jing Zhang, Jun Zhang, Yi Liu, Dianhai Yu, and Yanjun Ma. Paddleocr-vl: Boosting multilingual document parsing via a 0.9b ultra-compact vision-language model, 2025. URL <https://arxiv.org/abs/2510.14528>.
- Jianning Zhang and Yifei Chen. A synthetic dataset for circuit schematic ocr and netlist extraction, 2026. URL <https://github.com/ZhangJ83/circuit-ocr-dataset>.