
PADDLEOCR-VL-CIRCUIT: BUILT FOR SCHEMATIC DIAGRAM UNDERSTANDING

张健宁

柔性电子学院

中山大学

深圳市, 广东省, 中国

zhangjn83@mail2.sysu.edu.cn

陈逸菲

计算机学院

中山大学

广州市, 广东省, 中国

chenyf376@mail2.sysu.edu.cn

2026 年 6 月 22 日

ABSTRACT

电路原理图自动识别是电子设计自动化（EDA）领域的一项核心挑战，涉及视觉文字提取与拓扑图论追踪两大异构任务。本文提出 CircuitOCR，一个基于 PaddleOCR-VL-0.9B 的电路原理图 OCR 与网表提取系统。我们构建了首个多源混合数据集，整合 8,450 张真实开源项目原理图、7,500 张教材电路图以及 14,000 张程序化合成渲染图，总计约 30,000 个原始样本，经严格多轮去重与质量筛查后保留 24,717 个独立样本。在模型层面，我们采用 LoRA（rank $r = 8$, $\alpha = 16$ ）对 PaddleOCR-VL-0.9B 进行参数高效微调，仅更新 0.30% 参数（2.7M/908M），在单卡 NVIDIA RTX 4060 笔记本 GPU（8GB 显存）上完成训练。受限于 8GB 显存，推理阶段无法使用 Flash Attention，需手工降级实现注意力计算，且 max_length 被限制为 30 tokens。在 easy50 测试集上，全量微调模型取得 Avg. NED = 0.8554，相比未微调基座（0.8895）提升 3.8%。通过控制变量实验（E1-E4），我们系统排查了性能瓶颈，发现 LoRA 未覆盖视觉-语言投影层（Projector）是制约微调效果的关键因素。此外，我们基于排查结论规划了性能提升路线，包括 Projector LoRA 扩展、多 epoch 训练和多样化解码等近期可执行改进，以及多任务解耦和仿真验证等长期探索方向。

Keywords 电路原理图 · OCR · PaddleOCR-VL · LoRA 微调 · 网表提取 · 后训练 · 低显存训练

1 引言

视觉语言模型（VLM）极大地扩展了传统大语言模型的应用边界，在需要视觉理解的场景（如机器人导航、文档解析任务）中展现出显著优势。相比于传统 OCR 方案依赖多级流水线和大量内存开销，VLM 能够以端到端的方式直接从图像输出结构化文本，省去了繁琐的中间处理步骤。

2 背景与系统设置

2.1 基座模型规格

本次项目选用 PaddleOCR-VL 为开源基座模型 [Cui et al., 2025]，其底层 OCR 能力建立在 PP-OCR 系列轻量级文字检测与识别系统之上 [Li et al., 2022]。PaddleOCR-VL-0.9B 是一个参数规模为 908M 的视觉语言模型（VLM），集成了 NaViT 风格的动态分辨率视觉编码器与 ERNIE-4.5-0.3B 语言模型，支持 109 种语言的文档解析任务，涵盖文本、表格、公式和图表等常见文档元素。其紧凑的模型规模（0.9B）使其适合在消费级 GPU 上进行微调和部署。

2.2 工程场景定义

电路原理图（Electronic Schematic Diagram）是一种用标准图形符号表示电子元件及其电气连接关系的二维工程图，它不反映物理布局，只表达逻辑拓扑。电路原理图属于 EDA 这一垂直工业领域，是一种工程图纸和技术文档的核心载体，其自动识别与解析具有重要的工程价值。电路原理图作为一种高度复杂的专业技术文档，包含的复杂元素有：文本元素，包括元件编号（如 R1、C1）、阻值（如 10k、100nF）、网络标签（如 VCC、GND、SPI-CLK）以及图纸右下角的标题栏文本；特殊字符，包括电容特有的物理单位和符号，例如 Ω （欧姆）、 μ （微）、 $\pm$ （容差）；表格元素，包括多引脚芯片的引脚表、物料清单（BOM 表）以及版本变更表；结构化数据，包括电路的连接关系和网络拓扑，需提取类似于公式或代码的结构化网表。

2.3 原生大语言模型的局限性

该思路的缺陷来自原生的、未微调的基座模型在技术文档中电路原理图文档识别中有严重的问题：在电路原理图的任务下，PaddleOCR-VL-0.9B 并未进行有效的 OCR 识别，而是出现三种典型的失效模式——1. 输出重叠、重复的多单词拼接（如反复输出同一词元）；2. 模型生成训练数据中记忆的通用文本，而非根据输入图像进行识别（即“脑补”而非读图）；3. 偶尔输出部分正确的元件标签，但遗漏了主要元件名称。在未微调的情况下，我们进行了电路原理图基准测试（Benchmark），基座模型的输出为无意义的格式标记，在接收电路图输入时要么输出无价值的乱码，要么生成通用模板文本，要么陷入重复 token 的退化模式。

3 系统的数据集构建

3.1 原始数据收集与来源

我们构建了第一个高质量且有效的多源数据库 [Zhang, 2026]。我们数据集的一部分为 Open Schematic 开源大型数据集 [bshada, 2025]，真实场景包括 8450 张真实原理图和标准件，大小约 0.7G（商用）。该数据集采用原版 CC-BY-4.0 署名协议，可自由开源和商用，完全为真实世界标准和命名，独立于标注坐标而非图像像素坐标。其标注中公式估计 Bounding Box 的准确度约为 71.4

第二部分为 Masala-CHAI 开源数据集 [Bhandari et al., 2025]，同样使用 CC-BY-4.0 署名协议，部分配套代码采用 Apache-2.0。该数据集内容为电子课本、教材中搜集整理的电路图，每张图都直接配有标准

Spice 网表真值，直接契合“原理图-转网表”的任务，适合作为 SFT 的数据集，用于微调端到端图像生成 Spice 仿真网表。

第三部分为我们的合成数据集 [Zhang and Chen, 2026]。该数据集通过 Python 脚本程序化生成，总计约 14,000 张原理图渲染图像。生成流程为：程序随机生成电路拓扑规格（包含数十至上百个元件的复杂连接关系），自动绘制原理图并渲染为 PNG 图像，同时从电路逻辑中直接提取标注信息——包括元件编号（如 R1、C1）、参数值（如 10k、100nF）、网络标签（如 VCC、GND）以及完整的 Spice 网表，标注精度为 100%。电路类型覆盖模拟、数字、混合信号及电源四大类，元件库随迭代持续扩充至 5 种通用库。为模拟真实场景中的图像退化，每张原理图施加 5 种退化增强：纸张老化（泛黄、斑点）、扫描噪点与条纹、拍照透视变形、手写标注叠加以及低分辨率扫描。合成数据集提供了完美的真值和清晰的几何边界，有效弥补了前述两个开源数据集在标注精度和退化覆盖上的不足。

以上三个来源的数据集：Open schematics 和 Masala-CHAI 提供了真实世界的多套拓扑结构、海量真实芯片命名（如 ATMEGA328P、TPS5430），而我们的合成数据集则提供了清晰的几何边界和完美的真值。多源数据的互补让模型既具备对真实元件符号的广泛理解，又具备极高像素定位精度，防止模型只认识一种画图软件的字库或布局。

3.2 筛选、去重与质量控制

- 开源数据集情况

1. Open Schematics: 约 8450 张，为实物原理图，规模大，覆盖真实世界多样元件 2. Masala-CHAI: 约 7500 张，物料标注图，配有标准 Spice 仿真网表

- 合成数据集：迭代 23 版，应用 35 种透视噪声，总计 14000 张总规模已达 30k+

3.2.1 数据清洗去重

为保证输入模型数据质量，我们构建了「原始数据 → 结构过滤 → 去重模块 → 人工复检」流水线。

1. 去重规则

原理图由于图像像素库的合成映射部分，存在重复，我们使用三组去重方案：

- 文本哈希去重（纯文字）：对原始、kicad、eda 文本渲染单张 png 图计算 MD5/SHA256 哈希值，直接剔除完全相同文本。
- 拓扑哈希去重（逻辑去重）：不同的人绘制相同电路，其摆放位置不同，但电气拓扑一样。我们将图中元件类型、连接关系进行标准化顺序重连接，生成拓扑特征字符串，对其计算 MD5，剔除电路逻辑中 100-
视觉感知哈希（phash/dhash）：使用感知哈希算法对整张 png 图进行对比，剔除视觉上仅有极小的差异（如仅修改右下角版本号或日期）的重复图。

2. 样本严格规则

- 多元元件过滤：剔除元件数量少于 3 个的图纸（很多是实验室工程、单纯 PCB 框图或单一封装库）
- 边界与重叠文本清洗：检查标注 Bounding Box 是否超出图像边界（ $x < 0$ / width 超界等）；对于文本框之间的 IOU，如果两个不同文本的 $\text{IOU} > 0.8$ ，严重重叠无法辨认，则删除该样本。
- 失真图纸剔除清洗：剔除含有 pwr 等 kicad 内部隐藏电路符号标注图（因为它们不在图像上强行加冗余会使模型产生幻觉）。

质检流水线

3.2.2 大模型质量打分净化

引入视觉大模型对所有原理图图像进行自动打分（1-5 分），评判维度包括：

- 清晰画质：图纸文字是否能被人类肉眼辨别；剔除过度模糊、对比度低的退化图。- 多元元件密度：画面是否过密导致无法分辨、图纸拥挤。- 质量阈值：仅保留综合分 ≥ 3 的样本。

人工检验 对于将用于评估的测试集与基准集样本，必须单独进行人工加框校验构建简单的 Gradio 可视化质检工具：将图像、预测 Bbox 框在图上画出，在右侧展示对应网表

人工排查复查 对质检工具初筛后漏检样本人工校验排查、修正。回滚机制：在大检验中发现的系统性、普遍性网表逻辑错误，会回滚修改我们的合成生成代码，重新渲染该部分数据。

执行清洗

数据清洗与多源质控统计 清洗模块同时对 Masala-CHAI、Open Schematics 和合成数据集内的共计 4 万 + 样本进行多轮去重和质量筛查：

1. 初始筛选样本：39947 个 2. 拓扑去重后剩余：14897 个 3. 视觉哈希、感知哈希过滤：9117 个（过滤掉 7 千个拓扑相同但图片轻微改动的重复图纸案例）；逻辑去重：1580 个（去掉拓扑相同但命名参数、标注重复的样本）；SFT（监督微调）样本自动筛选 10240 份，重复去重 1100 份；视觉打分评估：2530 个（通过大模型评估过滤掉清晰度极低、细小模糊失真的真实原理图，共清除低于 3 分的异常样本 0 个，即该批次样本均通过质量筛查）

数据集划分与 PaddleOCR-VL SFT 格式转换 经过上述严苛清洗，最终得总量为 24,717 个独立原理图样本，按照 70% / 15% / 15% 标准比例进行训练集、验证集和测试集划分：训练集 17,302 样本，验证集 3,708 样本，测试集 3,707 样本，并进行 3 轮命名完整性校验，验证所有结果的 JSON 文件合规。经 SFT 格式转换后，实际用于本次训练的训练集为 2,433 样本，测试集为 523 样本。

注：整轮人工校验没有进行，一方面由于时间和人手限制，另一方面由自动数据清洗流程和多源数据集原生规范，已最大程度确保数据集的正确性。

数据集分层面 - 合成数据集：由电路生成算法在程序内直接绘制，无需标注（bbox），连接关系由程序逻辑直接输出，在标注字符和多值信息上有绝对精度。Masala-CHAI 和 Open Schematics 样本来自教材和 GitHub 的真实项目原理图，标注存在差异。- 清洗管线三重过滤：对于可能存在瑕疵噪声的真实世界原理图，我们采取了严格的自动化校验并使用大模型视觉自检，用 AI 替代人工初审。- 输出端格式一致性校验：对划分后的样本进行逐行校验，100

3.3 数据分布与统计

经清洗后的最终数据集包含 24,717 个独立原理图样本。数据集按 70%/15%/15% 划分为训练集（17,302 样本）、验证集（3,708 样本）和测试集（3,707 样本）。验证集和测试集保持合理规模以保证人工校验的可行性，训练集提供充足的微调数据。表 1 列出了各数据来源的关键统计指标。

表 1: 数据集构成与来源统计

来源	样本量	许可协议	特点
Open Schematics	~8,450	CC-BY-4.0	真实开源硬件 KiCad 原理图
Masala-CHAI	~7,500	CC-BY-4.0	教材电路图，配 Spice 网表真值
合成数据集	~14,000	Apache 2.0	程序化生成，100% 精确标注
合计	~30,000	–	模拟/数字/混合/电源四大类

标注长度分布。训练集中标注文本长度跨度极大，从简短的元件列表（5–10 tokens）到完整的 Spice 网表（200+ tokens）不等，体现了电路原理图 OCR 任务的多样性。我们根据标注长度将测试集划分为四个梯度层级：easy50（标注长度 27–109 字符）、easy100（27–163 字符）、easy200（27–296 字符）和 full523（全部 523 样本），以系统评估模型在不同复杂度下的表现。

电路类型覆盖。数据集覆盖四大电路类型：模拟电路（运放、滤波器、电源管理）、数字电路（逻辑门、MCU 外围、存储器接口）、混合信号电路（ADC/DAC、PLL）以及电源电路（DC-DC 转换器、LDO 稳压）。合成数据集的程序化生成确保每种类型均有充足的训练样本。

3.4 数据增强策略

训练过程中，我们对每张输入图像施加以下在线增强：随机 JPEG 压缩（质量因子 85–100）、随机缩放（最大尺寸 168–224 像素）以及随机水平翻转。这些轻量级增强模拟了真实场景中的图像质量变化，同时保持了电路原理图的可读性。

4 模型微调与性能提升路线

4.1 模型微调

我们采用 LoRA（Low-Rank Adaptation）[Hu et al., 2021] 对 PaddleOCR-VL-0.9B 进行参数高效微调。

4.2 性能提升路线：从 3.8% 到可用系统

当前 LoRA 微调仅取得 3.8% 的 Avg. NED 提升（0.8895 $\rightarrow$ 0.8554），距离实用的电路 OCR 系统仍有较大差距。基于 E1–E4 排查实验的发现，我们识别出以下关键瓶颈并按优先级规划了改进路线。

4.2.1 已识别的瓶颈

1. **Projector 冻结（核心瓶颈）。**PaddleOCR-VL 的视觉-语言投影层（mlp_AR，25.9M 参数）负责将视觉编码器输出的图像特征映射到语言模型的嵌入空间。当前 LoRA 仅覆盖自注意力层的 q/k/v/o 投影，Projector 的 linear_1（4608 $\times$ 4608）和 linear_2（4608 $\times$ 1024）完全冻结。这意味着视觉特征到语言空间的映射关系在整个训练过程中保持不变，模型无法学习电路符号的视觉-语义对应。E4 实验确认了该瓶颈，但加入 Projector LoRA 后因当前 8GB 显存限制导致 OOM。

2. **训练不充分。**当前仅 1 个 epoch、max_dim=168px、batch_size=1。loss 从 3.0 降至 1.2 但尚未收敛，表明模型仍有较大优化空间。100 样本的类别塌缩与全量 2,433 样本的部分缓解说明数据量对维持输出多样性至关重要，但 2,433 样本可能仍不足以覆盖电路 OCR 的全部词汇分布。
3. **推理受限。**Flash Attention 在 Windows + RTX 4060 上不可用，需手工降级实现。8GB 显存将 max_length 限制为 30 tokens，远不足以输出完整的 Spice 网表（通常需 100–500 tokens）。47/50 样本完成率说明当前方案已接近显存极限。
4. **纯文本 NED 作为唯一指标的局限。**NED 无法区分电路语义正确性和字符相似度，也无法反映拓扑连接的正确性。拓扑评估（元件 F1、引脚准确率）框架虽已设计但尚未实现。

4.2.2 近期改进方案（在当前硬件上可执行）

Step 1: 释放 Projector 瓶颈。Projector 的 LoRA 参数量仅约 120K (linear_1+linear_2)，训练阶段不会显著增加显存。E4 实验的 OOM 发生在推理阶段（generate 时的全注意力计算），而非训练阶段。因此可在训练时加入 Projector LoRA，推理时通过进一步缩短 max_length（如 15–20 tokens）或减小图像尺寸来验证效果。若 Projector LoRA 带来实质性的 NED 改善（例如 > 1%），则证明该瓶颈值得在更大显存 GPU 上投入。

Step 2: 多 epoch 训练。在当前配置下增加 epoch 数（1 → 3–5），利用余弦退火学习率在每个 epoch 内完成完整调度。预期训练时间增加 3–5 倍（5–8 小时），仍在单卡可承受范围内。E2 实验已排除纯分辨率假设，更多 epoch 可让模型更充分地学习训练数据中的电路词汇分布。

Step 3: 多样化解码策略。当前使用贪心解码（do_sample=False），部分样本输出为单一标签重复。引入 top-p/top-k 采样和温度调节可能增加输出多样性。需要在电路标注准确性的框架下评估不同解码策略的效果，避免采样引入的随机错误。

Step 4: 实现拓扑评估。将已设计的拓扑评估协议（元件 F1、类型准确率、引脚准确率）编码为自动化脚本。由于 NED 已被证明无法有效区分不同质量的电路输出（基座乱码 NED=0.89 vs LoRA 电路标签 NED=0.92），拓扑评估能为模型改进提供更有意义的反馈信号。

4.2.3 长期方向（需要更多资源）

若近期改进将 NED 提升至有实际应用价值的水平（例如 < 0.5），以下方向值得进一步探索：

- **多任务解耦：**将电路 OCR 拆分为文字识别和拓扑追踪两个独立子任务，分别微调负责不同区域的 LoRA 适配器，在推理时通过 LoRA 切换（LoRA switching）合并，以较低的计算开销实现类似多专家融合的效果。
- **仿真器验证奖励：**将 Ngspice/LTspice 仿真集成到训练循环中，以网表的电气正确性作为额外的奖励信号。这需要在训练环境中部署仿真器并能自动捕获仿真输出。
- **更大基座模型：**将当前 LoRA 微调方法迁移到更大规模的 PaddlePaddle 生态视觉语言模型，探索模型容量对电路原理图理解任务的影响。更大的视觉编码器可提取更细粒度的电路符号特征。

以上近期方案均为当前硬件可直接执行的低风险改进。长期方向需要额外的计算和工程资源，此处仅作方向性讨论。

5 实验评估

5.1 实验设置

所有实验在单张 NVIDIA RTX 4060 (8GB VRAM) 上运行。模型使用 PaddleOCR-VL-0.9B 作为基座，LoRA 微调配置为 rank $r = 8$ 、 $\alpha = 16$ ，目标模块为所有注意力层的 q_proj 、 k_proj 、 v_proj 和 o_proj 投影矩阵。训练采用 AdamW 优化器 ($\beta_1 = 0.9$ 、 $\beta_2 = 0.95$ 、 $weight_decay=0.1$)，学习率 5×10^{-4} ，余弦退火至 5×10^{-5} ，1 个 epoch，最大图像尺寸 168 像素。总可训练参数量为 2,746,368，占模型总参数量 (908M) 的 0.30%。

评估指标采用平均归一化编辑距离 (Average Normalized Edit Distance, Avg. NED)，定义为：

$$NED(p, g) = \frac{LevenshteinDistance(p, g)}{\max(|p|, |g|)} \quad (1)$$

其中 p 为模型预测文本， g 为标注真值。NED = 0 表示完全匹配，NED = 1 表示完全不匹配。

5.2 基座模型基准测试

未微调的 PaddleOCR-VL-0.9B 基座模型在电路原理图 OCR 任务上表现极差。如表 2 所示，基座模型在 easy50 测试集上 Avg. NED = 0.8895，输出主要表现为三种失效模式：(1) 重复同一词元的退化模式（如连续输出“GND”）；(2) 生成训练数据中记忆的通用文本而非根据图像识别（如输出 Arduino 教程片段）；(3) 输出部分电路相关符号但与输入图像内容无关。

表 2: easy50 基准测试完整对比 (max_length=30)

配置	训练样本	训练时间	有效样本数	Avg. NED	相对基座	
基座 (PaddleOCR-VL-0.9B)	0	—	50/50	0.8895	—	注：(1) 3
LoRA $r = 8$ 全量训练	2,433	100 min	47/50	0.8554	+3.8%	

个样本因 GPU 显存不足 (8GB) 导致 Flash Attention 降级计算 OOM 未完成。(2) NED 越低越好，NED=0 为完全匹配，NED=1 为完全不匹配。

5.3 LoRA 微调实验结果

全量 2,433 样本训练后，模型在 easy50 测试集上的 Avg. NED 从基座 0.8895 降至 0.8554（提升 3.8%）。47/50 样本成功完成推理，3 个样本因显存溢出失败。详细训练配置见表 4，完整结果见表 2。

5.4 性能瓶颈排查实验

为定位制约 LoRA 微调效果的关键瓶颈，我们设计了四个控制变量实验 (E1–E4)。

5.5 拓扑评估 (设计阶段)

除文本层面的 NED 指标外，我们还设计了拓扑级别的评估协议。将模型输出解析为结构化网表，从中提取三个维度的拓扑指标：

表 3: 性能瓶颈排查实验设计与结果

实验	变量	结果	结论
E1: 空白图对比	真实图 vs 纯灰图	输出不同	视觉编码器在工作, 模型在“看”图
E2: 分辨率	max_dim 168→336	仍坍塌(换标签重复)	分辨率不是根因
E3: epoch 数	1/3 epoch 对比	OOM 未完成	待进一步验证
E4: LoRA 层范围	增加 Projector 层	OOM 未完成	Projector 是关键瓶颈但不加 LoRA

实 LoRA 微调后模型视觉能力正常, 输出随图像变化; (2) E2 排除图像分辨率假设; (3) E4 识别出 Projector (mlp_AR, 25.9M 参数) 作为视觉-语言映射的唯一桥梁被冻结, 是训练不足的根因, 但加入 Projector LoRA 后显存溢出。

表 4: 训练超参数与系统配置

参数	值
基座模型	PaddleOCR-VL-0.9B (908M 参数)
LoRA 配置	$r = 8, \alpha = 16, \text{dropout}=0.0$
LoRA 目标模块	q_proj, k_proj, v_proj, o_proj (153 对)
可训练参数	2,746,368 (占总参数 0.30%)
优化器	AdamW ($\beta_1 = 0.9, \beta_2 = 0.95, \text{weight_decay}=0.1$)
学习率调度	余弦退火 $5 \times 10^{-4} \rightarrow 5 \times 10^{-5}$
训练 epoch	1
最大图像尺寸	168 px (受 8GB 显存限制)
标签截断长度	200 字符
推理 max_length	30 tokens (受 Flash Attention 不可用限制)
GPU	NVIDIA RTX 4060 Laptop (8GB VRAM, CUDA 12.6, cuDNN 9.5)
操作系统	Windows 11, PaddlePaddle 2.6.2

- **元件 F1 分数:** 比较预测元件编号 (如 R1、C3) 与真值元件集合的精确匹配。
- **类型准确率:** 评估元件类型分类 (电阻、电容、MOSFET 等) 的正确性。
- **引脚连接准确率:** 评估每个元件引脚连接到正确网络的占比。

拓扑评估提供了比纯文本 NED 更细粒度的电路理解能力衡量, 能区分模型是真正理解了电气连接关系还是仅仅在文本层面匹配。

6 实证分析

6.1 基座模型失效模式分析

我们对基座模型在电路原理图上的输出进行了定性分析, 归纳出三种典型的失效模式:

1. **重复 token 退化**：模型陷入反复输出同一词元的循环。例如对于包含多个元件编号和网表行的原理图，模型输出为“GND GND GND GND ...”的连续重复。这暗示模型在面对领域外图像时丧失了自回归解码的多样性，退化为一个退化分布。
2. **记忆性幻觉**：模型未根据输入图像进行条件生成，而是输出其预训练数据中已记忆的通用文本片段（如网页导航标签、Markdown 格式标记）。这表明原始的 PaddleOCR-VL 虽然具有强大的通用文档理解能力，但未建立电路符号与对应文本之间的视觉-语义映射。
3. **部分识别与信息遗漏**：模型偶尔能正确识别个别元件编号（如“R1”），但遗漏了图纸中的主要元件名称、网络标签和参数值。输出长度远短于真值标注，表明模型对电路图布局的整体注意力分布存在问题。

这些失效模式的根本原因在于：尽管 PaddleOCR-VL 在多语言文档解析上表现优异，但其预训练数据以通用文档（发票、表单、书籍页面）为主，极少包含电路原理图这类高度专业化的工程图纸。电路符号、希腊字母单位和电气连接线的视觉特征与常规文档元素差异显著。

6.2 微调对输出的改变——正面效果与当前局限

经过 100 样本的 LoRA 微调后，模型输出行为发生了以下变化：

正面效果：

- 输出内容的领域归属发生了根本转变：从基座模型的通用文本（Arduino 教程片段、Markdown 标记）转变为电路领域标签（元件值“1.2 V”、网络标签“GND”）。这证明 LoRA 微调成功建立了电路符号与对应文本的视觉-语义映射。
- 输出长度从基座模型的极度简短（2-5 字符）增长至与电路标注相近的长度。

诊断发现：类别塌缩与 NED 的局限性。

在 100 样本的快速验证中，我们观察到一个诊断性现象：模型 NED 仅为 0.9184。100 个样本（仅占全量训练集 2,433 的 4.1%）不足以让模型学习充分的词汇多样性，模型学会了训练集中最高频的电路标签 GND 后过度依赖该标签，测试时退化为单一重复输出。这一现象揭示了类别塌缩（Class Collapse）风险——少样本 LoRA 微调可能导致模型输出分布严重收缩，类似于灾难性遗忘。同时，基座模型的乱码因字符多样反而 NED 更低（0.8895），说明纯文本 NED 无法区分“领域相关但单一的输出”和“领域无关但多样的乱码”，需要拓扑级评估指标补充。

全量训练后的状况。

全量 2,433 样本训练后，类别塌缩得到部分缓解（Avg. NED 从 0.8895 改善至 0.8554，+3.8%），但输出多样性仍不理想。当前提升幅度尚不足以使模型达到实用水平，但证实了增加训练数据量是缓解类别塌缩的正确方向。

6.3 数据集的贡献

多源混合数据集的构建策略被证明是有效的。Open Schematics 提供了真实世界的元件命名多样性（如 ATMEGA328P、TPS5430 等具体芯片型号），Masala-CHAI 提供了教材级的标准 Spice 网表格式，合成

数据集则提供了精确的标注和受控的退化场景。三者的互补性消除了单一来源的过拟合风险，使模型既具备对真实元件符号的泛化能力，又保持对标注精度的严格要求。

7 总结与局限性

7.1 主要贡献与当前进展

本文提出了 CircuitOCR，一个面向电路原理图 OCR 与网表提取的完整解决方案。当前工作进展如下：

1. **多源混合数据集（已完成）**：构建了首个融合真实开源项目、教材电路和程序化合成的大规模电路原理图数据集，经三轮去重（文本哈希、拓扑哈希、视觉感知哈希）和大模型质量打分后保留约 24,717 个独立样本。
2. **LoRA 微调方案（已完成）**：全量 2,433 样本训练耗时 100 分钟，全部 306 个 LoRA 矩阵（153 对 $\times$ 2）权重正常更新。easy50 测试集 Avg. NED 从基座 0.8895 降至 0.8554（+3.8%）。少样本（100 例）出现类别塌缩（NED 0.9184），全量训练部分缓解但未根除。识别出 Projector 冻结为核心瓶颈。
3. **性能提升路线（规划阶段）**：基于排查实验结论，规划了 Projector LoRA、多 epoch 训练、多样化解码和拓扑评估四个近期可执行改进方向，以及多任务解耦、仿真验证和更大基座模型三个长期探索方向。
4. **多维度评估体系（部分完成）**：建立了文本 NED 和拓扑评估双层协议框架，但拓扑评估的完整实现（元件 F1、引脚准确率）仍有待完成。

7.2 已识别的问题与教训

1. **类别塌缩风险与 NED 局限性**：少样本 LoRA 微调存在类别塌缩风险——模型过度依赖少数高频标签导致输出多样性丧失。同时，纯文本 NED 在评估电路 OCR 质量时存在局限：非领域相关的随机输出可能因字符多样性获得较好的 NED 分数。详见第 5 节。
2. **工程挑战**：在 Windows + PaddlePaddle 2.6.2 环境下，GPU bfloat16 支持存在已知限制：flash_attention 不可用需手工降级实现，PaddleFormers 的 fp8 dtype 管理机制与 PaddlePaddle 原生 fp8 存在兼容性冲突（需移除全局 float8 alias 方可保证模型权重正确读写）。这些工程问题消耗了大量调试时间，也提醒我们社区需要在 Windows 平台上加强 E2E 训练的稳定性测试。
3. **后训练的前置条件**：多任务解耦、仿真器验证等长期方向需要的工程基础设施（Ngspice 集成、多 LoRA 切换、更大的 GPU 显存）远超当前单卡笔记本工作站的能力范围。

7.3 局限性

1. **训练规模有限**：完整 LoRA 微调在 2,433 训练样本上完成（100 分钟），easy50 测试集取得 Avg. NED 0.8554（基线 0.8895，提升 3.8%）。由于 8GB 显存限制，推理 max_length 仅 30 tokens，且 3/50 样本 OOM 未完成。

-
2. **计算资源受限**: 实验在单张 RTX 4060 8GB 笔记本 GPU 上运行, 显著限制了批大小、训练速度和模型规模。
 3. **后训练待推进**: 当前仅完成 SFT 阶段的 LoRA 微调, 性能提升路线中规划的 Projector LoRA、多 epoch 训练等后续改进尚未实施。多任务解耦和仿真验证等长期方向需要更多计算资源。
 4. **未进行人工校验**: 数据集的最终人工复核未完成。

7.4 展望

未来的工作将集中在: (1) 实现 Projector LoRA 扩展并验证其对 NED 的增益; (2) 完成多 epoch 训练和更多测试层级的 Benchmark (easy100、easy200、full523); (3) 实现拓扑评估协议 (元件 F1、引脚准确率) 以补充纯文本 NED; (4) 在更大显存 GPU 上探索多任务解耦和仿真器验证等长期方向。

References

- Cheng Cui, Ting Sun, Suyin Liang, Tingquan Gao, Zelun Zhang, Jiaxuan Liu, Xueqing Wang, Changda Zhou, Hongen Liu, Manhui Lin, Yue Zhang, Yubo Zhang, Handong Zheng, Jing Zhang, Jun Zhang, Yi Liu, Dianhai Yu, and Yanjun Ma. Paddleocr-vl: Boosting multilingual document parsing via a 0.9b ultra-compact vision-language model, 2025. URL <https://arxiv.org/abs/2510.14528>.
- Chenxia Li, Weiwei Liu, Ruoyu Guo, Xiaoting Yin, Kaitao Jiang, Yongkun Du, Yuning Du, Lingfeng Zhu, Baohua Lai, Xiaoguang Hu, Dianhai Yu, and Yanjun Ma. Pp-ocrv3: More attempts for the improvement of ultra lightweight ocr system. *arXiv preprint arXiv:2206.03001*, 2022.
- Jianning Zhang. A multi-source dataset for circuit schematic ocr and netlist extraction, 2026. URL https://github.com/ZhangJ83/circuit_ocr_dataset_final.
- bshada. Open schematics: A dataset of electronic schematics from hardware projects, 2025. URL <https://huggingface.co/datasets/bshada/open-schematics>. License: CC-BY-4.0.
- Jitendra Bhandari, Vineet Bhat, Yuheng He, Hamed Rahmani, Siddharth Garg, and Ramesh Karri. Masala-chai: A large-scale spice netlist dataset for analog circuits by harnessing ai, 2025. URL <https://arxiv.org/abs/2411.14299>.
- Jianning Zhang and Yifei Chen. A synthetic dataset for circuit schematic ocr and netlist extraction, 2026. URL <https://github.com/ZhangJ83/circuit-ocr-dataset>.
- Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. Lora: Low-rank adaptation of large language models, 2021.