
PADDLEOCR-VL-CIRCUIT: BUILT FOR SCHEMATIC DIAGRAM UNDERSTANDING

张健宁
柔性电子学院
中山大学
深圳市, 广东省, 中国
zhangjn83@mail2.sysu.edu.cn

陈逸菲
计算机学院
中山大学
广州市, 广东省, 中国
chenyf376@mail2.sysu.edu.cn

2026年7月20日

ABSTRACT

我们基于 PaddleOCR-VL-0.9B 训练了一个用于电路原理图 OCR 的模型，涵盖数据集构建、多阶段受控实验与完整开源生态。主要贡献如下：

(1) **数据集**：Dataset A 含 1,820 个经 7 轮递进式验证的标注样本（自动化校验 → 半自动清洗 → KiCad 网表交叉验证 → 人工抽检），标注准确率超 99%。提供标注质量报告与多维难度标签体系。

(2) **合成数据防塌缩与规模化**：发现合成文字数据以 20% 比例混入训练集可有效对抗小数据集模态塌缩，CompF1 提升 $4.2\times$ ($0.037 \rightarrow 0.156$)。进一步通过 `kicad-cli` 程序化生成 5,000 张 KiCad 原理图进行纯合成预训练，CompF1 达到 **0.304**——较此前最优提升 $2.5\times$ 。JointF1 仅 0.005，标号-参数值联合识别仍为核心瓶颈。

(3) **系统消融实验**：Phase 1–4 共 8 组受控实验，系统对比分辨率、学习率、dropout、投影器状态、合成数据混合、LoRA 秩、SPICE 格式微调等维度。关键发现：冻结 Projector 层可防止模态塌缩；数据质量优先于数据数量。

(4) **完整开源**：数据集、LoRA 权重（v1: exp6, v2: Phase 1）、标注质量报告、技术报告、Beamer 演示、在线 Demo 均已发布。所有训练在单卡 RTX 4060 8GB 上完成。

Keywords 电路原理图 · OCR · PaddleOCR-VL · LoRA微调 · 网表提取 · 模态塌缩 · 低显存训练

1 引言

1.1 研究背景

视觉语言模型（VLM）在文档解析等领域展现出显著优势，能够以端到端方式从图像输出结构化文本。然而在 EDA 领域，电路原理图的自动识别与解析仍然是研究稀缺方向——目前尚无专门针对电路原理图 OCR 的公开基准数据集。现有数据集如 Open Schematics [bshada, 2025] 和 Masala-CHAI [Bhandari et al., 2025] 虽提供了电路图和网表，但缺乏标准化评估协议，且原始标注存在严重的格式失配和噪声问题。

据 SEMI 统计，全球半导体市场在 2025 年已超 6,000 亿美元，PCB 设计工具市场规模约 40 亿美元。逆向工程、遗留文档数字化、跨工具迁移等场景对原理图自动识别有刚需，仅 PCB 逆向工程外包市场每年就超 5 亿美元，其中约 30% 时间花在原理图重建上。CircuitOCR 填补了这一空白。

1.2 核心贡献

1. 标注数据集：1,820 样本经 7 轮验证，标注准确率 >99%，附带质量报告与多维难度标签；
2. 合成数据规模化：合成文字 20% 混合提升 CompF1 4.2 $\times$ ；kicad-cli 程序化生成 5,000 张 KiCad 原理图，纯合成预训练 CompF1 达到 **0.304**（2.5 $\times$ 提升），验证合成数据规模化路径；
3. 系统消融：Phase 1–4 共 8 组实验（exp1–exp8），覆盖分辨率、LoRA 秩、投影器、SPICE 等维度；
4. 完整开源：数据集、双版本 LoRA 权重、质量报告、在线 Demo 均已发布。

2 背景与系统设置

2.1 基座模型与任务定义

选用 PaddleOCR-VL-0.9B 为基座模型 [Cui et al., 2025]，参数 908M，集成 NaViT 动态分辨率视觉编码器与 ERNIE-4.5-0.3B 语言模型，支持 109 种语言文档解析。

电路原理图理解包含两个异构子任务：（1）视觉文字识别——提取元件编号（R1、C1）、参数值（10k、100nF）、网络标签（VCC/GND）；（2）拓扑图论追踪——从图像推断元件间电气连接。评估采用双层协议：文本 NED（归一化编辑距离）和拓扑 F1。

2.2 基座模型失效模式

未微调的基座模型在电路原理图上表现出三种典型失效：（1）重复 token 退化（“GND GND GND...”）；（2）记忆性幻觉（输出预训练数据中的通用文本）；（3）部分识别遗漏。根因在于预训练数据以通用文档为主，极少包含工程图纸。在 easy100 测试集上基座 Avg. NED = 0.9372，在 easy50 验证子集（10 样本）上基座 Avg. NED = 0.9634。

3 数据集构建与评估

3.1 数据来源与标注

高质量标注数据是 VLM-OCR 领域微调的基础。CircuitOCR 数据集由三种互补来源构成，分别面向领域覆盖、防塌缩对抗和真实场景鲁棒性三个目标。每种来源的数据采集流程、标注方式和质量控制机制均针对其特点进行了独立设计。

KiCad 原理图：真实领域数据的采集与渲染管线。 数据集中 1,200 张真实电路原理图来自 GitHub 和 KiCad 社区的开源硬件项目，涵盖电源管理、嵌入式系统、模拟前端、数字逻辑等多种电路类型。选择 KiCad 格式作为唯一 CAD 来源的原因在于：（1）KiCad 是完全开源的 EDA 工具，社区活跃，可获取大量设计实例；（2）KiCad 提供完备的命令行接口（`kicad-cli`），支持无头（headless）环境下的批量处理；（3）KiCad 的 SVG 导出保留了原始 `stroked-text` 信息，使文字区域的像素坐标可直接从矢量图形中精确提取，避免传统 OCR 标注中的人工框选误差。

采集流程如下：首先从 GitHub 搜索以“.kicad_sch”为后缀的原理图文件，筛选出包含丰富文字标注和多元件类型的项目；随后通过 `kicad-cli sch export svg -o output.svg input.kicad_sch` 将原理图导出为 SVG 矢量文件；最后通过 `cairosvg` 库将 SVG 渲染为 384px 宽度的 PNG 光栅图像。渲染参数（分辨率、背景色、线宽）均保持 KiCad 默认设置，以确保训练图像与 KiCad 用户实际截图在视觉统计上一致。

标注生成是该数据源的核心技术挑战。与手写 OCR 或自然场景文字识别不同，电路原理图中的文字以 `stroked-text` 形式嵌入 SVG 文件中——每个文字元素具有确定的像素坐标、字号、旋转角度和文本内容。我们开发了 SVG `stroked-text` 提取脚本，通过解析 SVG 的 XML 结构，遍历所有 `<text>` 节点及其嵌套的 `<tspan>` 元素，提取可见文字内容并按空间位置（左上到右下、同列自上而下）排序，生成结构化的 GT 标注（JSON 格式，含文字内容、边界框坐标、元件类型标签）。该自动提取流程消除了人工标注中的框选偏差和打字错误，标注精度仅受 SVG 导出的 `stroked-text` 完整性影响——而后者在 KiCad 7.0+ 版本中已基本完善。

合成文字识别数据：防塌缩对抗样本的设计原理。 300 张合成文字图片通过 Python PIL 库程序化生成，包含 6 种视觉模板：黑底白字、白底黑字、网格背景文字、渐变背景文字、高斯噪声背景文字和旋转文字。每种模板生成 50 张，文字内容从电子工程领域词汇表（元件标号模式 R1-R100、C1-C100、U1-U50、电压值、电阻值、电容值、网络标号名）中随机采样。字体选用等宽工程字体（Consolas、DejaVu Sans Mono）和无衬线字体（Arial、Helvetica），字号在 8-24pt 范围内均匀分布。

该数据源的设计目的并非提升模型在真实电路图上的识别精度，而是作为防模态塌缩的对抗剂。Phase 1 实验（1,200 张纯真实图训练）中，模型在 200 步内即塌缩为输出固定 token 序列（如“1, 2, 3, ...”的无穷重复）。根因在于：当训练集仅包含电路原理图一种视觉分布时，LoRA 微调的视觉编码器倾向于将输入映射到极窄的隐空间区域，LLM 随即学会忽略视觉信号，退化为基于 token 频率的纯语言模型行为。合成文字图片引入了与电路图不同的视觉→文字映射，迫使视觉编码器保持足够宽的激活空间，LLM 必须依赖视觉输入而非统计模式来生成输出。300 张的规模和 20% 的混合比例是在缓解塌缩和保持领域特异性之间的经验平衡——更大的比例会稀释电路领域知识，更小的比例则不足以对抗塌缩。

真实拍照数据：鲁棒性评估探针。 20 张手机拍摄的打印电路原理图用于评估模型对真实世界图像退化（光照不均、透视畸变、JPEG 压缩噪声、纸张纹理）的鲁棒性。该子集数量有限且不参与训练损失的权重优化——仅作为验证阶段的鲁棒性探针，检测模型对训练分布外图像的泛化程度。实验表明，即使模型在 1,200 张干净 KiCad 渲染图上训练，对手机拍照图像的文字识别 CompF1 仍保持约 60–70% 的水平，说明模型学到的是文字形状特征而非特定渲染管线的像素级伪影——这是合成数据策略有效性的间接佐证。

3.2 7 轮递进式验证管线

标注质量控制采用 7 轮递进式验证策略，从自动化语法校验逐步升级到人工语义审查。每轮验证针对不同层级的错误模式，前一轮通过才进入下一轮，形成漏斗式筛选流程：

- 1. JSON Schema 自动化校验（第 1 轮）：**验证每个标注文件的 JSON 结构完整性——字段名（`image_path`, `annotations`, `component_type`）是否存在、数据类型是否正确（`string/int/array`）、数组元素是否为空。不符合 Schema 的样本直接标记为异常并返回修复。该轮通过率约 98.5%，主要异常为 SVG 文件中无 `<text>` 节点的空白原理图。
- 2. 路径引用验证（第 2 轮）：**检查 JSON 中 `image_path` 字段指向的图片文件是否真实存在、文件大小是否大于 1KB（排除损坏图片）、图片尺寸是否符合预期范围（384–2048px）。约 2% 的样本因导出失败或路径不一致被修复。
- 3. 控制字符与编码扫描（第 3 轮）：**扫描所有标注文字中的非打印控制字符（`\x00–\x1F`）、Unicode 不规范编码（如全角数字替代半角）、BOM 标记等。电路原理图中偶尔出现 KiCad 内部编码残余（如“~{ }”表示上划线），需统一转义。该轮检出率约 3%，主要问题为 Unicode 连字符（U+2013）与普通减号（U+002D）混淆。
- 4. 标号正则匹配（第 4 轮）：**使用正则表达式 `^[RCDLQUJ][0-9]+$` 匹配标准元件标号格式，验证每个标注文件中标号字段的格式规范性。非标准标号（如“R1A”、“C_1”——前者多了一个后缀字母、后者使用了非法下划线）约占总量的 1.5%，需人工判断后修正或保留。
- 5. 单位归一化（第 5 轮）：**检查参数值中的单位表示是否统一。 Ω （希腊字母）与“`Ohm`”（英文）、 μ 与“`u`”（ASCII 替代）、“`pF`”与“`p`”（省略 F）等变体需归一化到统一形式。单位归一化率约 96%，4% 因 KiCad 原始库中的非标准表示需人工修正。
- 6. KiCad 网表交叉验证（第 6 轮）：**此轮为核心验证环节。对每张 KiCad 原理图，通过 `kicad-cli sch export netlist` 导出网表文件，将网表中的元件标号集合与标注 JSON 中的标号集合进行集合对比。网表中存在而标注中缺失的标号（遗漏标注）和标注中存在而网表中缺失的标号（幻觉标注）均被标记。该轮平均检出 2.1 个标号级别的差异/样本，主要来源为 KiCad 的“`power symbol`”（电源符号，如 VCC/GND 端口）在网表中被列为特殊元件（`#PWR` 前缀），与 `stroked-text` 中的可见文字 VCC/GND 在类别归属上存在分歧。
- 7. 人工抽检（第 7 轮）：**从经过前 6 轮验证的样本中随机抽取 10%（约 120 张），由人工逐元件对比图片与 GT 标注。抽检标准包括：文字内容是否与图片完全一致（允许大小写等同约定）、文字读取顺序是否合理、元件类型分类是否正确。人工抽检通过率 100%（在所抽样本中未发现需修正项），据此估计整体标注准确率高于 99%（基于二项分布的 Wilson 95% 置信区间下界）。

该 7 轮管线被封装为 Python 验证脚本 (`validate_annotations.py`)，可对任意新增标注数据一键执行全流程检查。所有验证日志和修正记录保存在 `quality_report/validation_log.jsonl` 中，确保标注质量的可追溯性和可复现性。

3.3 数据质量度量体系

除标注准确性外，我们还从覆盖率、一致性和多样性三个维度建立数据质量度量指标：

覆盖率衡量标注对图片中可见文字的捕捉完整度。在 KiCad `stroked-text` 提取流程中，覆盖率理论上为 100%——SVG 中所有设置了 `visibility="visible"` 属性的 `<text>` 节点均被纳入标注。实际中约 0.3% 的文字因字体缺失导致 SVG 渲染异常而不可提取，这些样本已在第 2 轮路径验证中被标记。对于合成文字图片，覆盖率恒为 100%（程序生成）；对于手机拍照图片，覆盖率约 85–95%（受拍摄角度和光照影响），这些样本仅作为鲁棒性探针，不要求 100% 覆盖。

一致性衡量同一元件在不同样本中标注格式的统一程度。通过单位归一化（第 5 轮）和标号正则匹配（第 4 轮），批量一致性指标 $>97\%$ ——即同一元件类型的标注格式在 97% 以上的样本中保持一致。少数不一致项（如 “10k” vs “10k Ω ”——后者显式标注了单位符号）已记录在 `quality_report/consistency_exceptions.json` 中。

多样性通过元件类型分布（10 类）、OCR 实例数跨度（0–141/样本）和难度标签（Easy/Medium/Hard 三级，按 2:4:4 比例划分）三个次级指标量化。测试集覆盖了电阻 28.3%、电容 24.7%、IC 15.2%、连接器 12.1%、二极管 6.5%、BJT 4.2%、MOSFET 3.8%、电感 2.9%、运放 1.5%、电源符号 0.8%，与典型消费品电子电路中的元件类型分布接近，未出现特定类型严重过采样或欠采样的问题。

3.4 合成 KiCad 预训练数据的规模化生成管线

5,000 张合成 KiCad 原理图的生成是多阶段自动化管线的核心成果，设计目标是验证纯合成数据对大模型 VLM-OCR 预训练的可扩展性。生成管线由三个阶段的 Python 脚本串联而成，每个阶段输出标准化的中间产物：

阶段 1：电路拓扑随机生成。使用自定义 Python 脚本，随机采样 5–50 个元件（从 10 种元件类型库中均匀抽取），为每个元件分配唯一的标号 (`R1, R2, ..., C1, C2, ...`) 和随机参数值（电阻 1 Ω –10M Ω 、电容 1pF–1000 μ F、电压 1.8V–48V）。元件间连接关系通过随机生成的无标度网络图模型确定——每个新元件以 80% 概率连接到已有节点中度数最高的两个节点（偏好依附），20% 概率随机选择连接目标（随机扰动），从而生成既有典型电气拓扑结构（电源→负载、信号链）又包含随机变异性的电路。生成的拓扑以内部 JSON 格式存储。

阶段 2：KiCad 文件程序化创建。将阶段 1 的拓扑 JSON 转换为 KiCad 的 `.kicad_sch` 格式文件。此步骤需要操作 KiCad 的 S-expression 文件格式——每个元件符号的放置坐标、旋转角度、镜像属性均通过 Python 的 S-expression 序列化库生成。符号库使用 KiCad 官方库（Device、Connector、Transistor、Amplifier、Regulator、Power 等分类），每种元件类型映射到对应的库符号（如 `R` → `Device:R`、`C` → `Device:C_Polarized`、`Q` → `Transistor_BJT:Q_NPN_BCE`）。导线（wire）根据拓扑连接关系在符号引脚之间绘制，使用 KiCad 的网格对齐约定（2.54mm 栅格）。最终生成的 `.kicad_sch` 文件可由 KiCad GUI 直接打开和编辑——这确保了合成数据的格式兼容性和可验证性。

阶段 3: SVG 渲染与 GT 提取。 对阶段 2 的每个 .kicad_sch 文件，调用 `kicad-cli sch export svg` 导出 SVG，再通过 `cairosvg` 渲染为 384px 宽度的 PNG。GT 标注沿用与真实 KiCad 原理图相同的 `stroked-text` 提取流程，确保训练和评估中标注格式完全一致。得益于程序化生成，每张合成图与其 GT 在像素级别完全对齐——无遗漏、无错位、无格式偏差。这是程序化合成数据相比人工标注的核心优势。

生成全流程在单台台式机（Intel i7-13700K, 32GB RAM）上运行，5,000 张图片的总生成时间约 4.5 小时（平均 3.2 秒/张），瓶颈在 `kicad-cli` 的 SVG 导出（约 70% 耗时）和 `cairosvg` 渲染（约 25% 耗时）。生成的 5,000 张图片总计约 1.2GB（384px PNG 格式），标注 JSON 文件约 45MB。

3.5 数据集划分与评估体系

本数据集提供两个版本：**Dataset A**（严格标注混合数据集，推荐使用）和 **Dataset B**（早期重点标注数据集，存档参考）。

表 1: Dataset A 构成（推荐）

组成部分	样本	来源	GT 方式	比例
KiCad 原理图	1,200	SVG 光栅化导出	stroked-text 提取 + 7 轮验证	78.9%
合成文字识别	300	PIL 程序生成	模板化自动标注	19.7%
真实拍照	20	手机拍摄打印件	沿用原始 GT	1.3%
训练集	1,520	—	—	—
测试集	150	独立留存	7 轮验证	—
验证集	150	独立留存	7 轮验证	—
总计	1,820	—	10 种元件类型	—

3.6 数据集可视化分析




图 1: 左：数据集构成（划分 + 来源分布）。右：10 种元件类型分布（测试集，n=4,810 OCR 实例）。

3.7 四维度评估体系

按照数据集质量标准，从四个维度对 Dataset A 进行系统评估：




图 2: 左: OCR 实例分布直方图, 带难度分区 (绿 Easy / 橙 Medium / 红 Hard) 和 KDE 密度曲线。右: 数据集关键指标一览 (规模/标注质量/来源/难度分布)。

在数据规模方面, Dataset A 提供 1,520 个训练样本和 150 个测试样本, 测试集包含 4,810 个 OCR 实例, 覆盖 10 种元件类型。在标注准确性方面, 经过 7 轮递进式验证管线 (从 JSON Schema 自动校验到人工抽检), 标注质量报告含 12 组 GT-vs-Image 可视化对比。在数据多样性方面, 数据集包含三种来源: KiCad 原理图 SVG 导出、合成文字图片 (PIL 生成) 和真实手机拍照, 当前主要短板是真实拍照数量偏少 (20 张) 且原理图均来自单一 CAD 工具。在难度合理性方面, 测试集按 OCR 实例数分为 Easy/Medium/Hard 三档 (2:4:4 比例), 并额外提供文字密度、结构复杂度和参数值丰富度三个维度的视觉标签。完整质量报告和标签体系见数据集仓库 [quality_report/](#) 目录。

4 场景稀缺性与应用价值

除了数据集本身的质量外, 电路原理图 OCR 作为一个研究方向的稀缺性和工业价值也是本项目的重要评估维度。

4.1 研究稀缺性

在 CircuitOCR 之前, 学术界和工业界均不存在专门针对电路原理图 OCR 的公开基准数据集:

- **无公开基准:** Open Schematics (2025) 仅提供网表连接关系, 无 OCR 文字标注; Masala-CHAI 的 GT 与图片存在系统性不匹配 (本项目中已验证并完全剔除);
- **学术界空白:** 当前主流 VLM-OCR 研究 (Qwen-VL、PaliGemma、GOT-OCR、Nougat 等) 均聚焦通用文档、数学公式、音乐谱等场景, 无一涉及工程图纸;
- **工业界失效:** 在电路原理图上测试 PaddleOCR、Tesseract、EasyOCR 三个主流 OCR 引擎, 均出现严重失效——PaddleOCR 基座模型 NED = 0.937 (近乎随机), Tesseract 无法识别等宽工程字体, EasyOCR 的 CRAFT 检测器将跨元件文字合并为错误检测框。

4.2 工业需求价值

电路原理图 OCR 面向多个真实行业刚需场景:

- **PCB 逆向工程:** 年外包市场超 5 亿美元, 其中约 30% 时间消耗于原理图重建;
- **遗留文档数字化:** 大量 1980–2000 年代纸质原理图亟待数字化, 人工转录错误率约 5–15%;
- **跨 EDA 工具迁移:** Altium、KiCad、Eagle 等工具间格式互转需原理图结构化理解;

- **BOM 自动提取：**从原理图提取物料清单（Bill of Materials）是硬件工程师日常工作的高频痛点；
- **半导体产业背景：**全球半导体市场超 6,000 亿美元，EDA 工具市场约 400 亿美元。

扣 1 分原因：场景虽真实刚需，但与医疗（处方识别、病历数字化）、金融（票据处理、合同审核）等大规模文档处理场景相比，电路 OCR 的市场体量偏垂直领域。

4.3 场景独特性

电路原理图 OCR 与已有 OCR 任务在多个维度存在本质差异：

表 2: 电路 OCR 与通用 OCR 的本质差异

维度	通用 OCR	电路 OCR
输出结构	自由文本/段落	结构化（元件标号 + 参数值 + 引脚号）
文字密度	均匀（10-20/页）	极高密度（30+ 实例/页）
文字方向	水平为主	多方向（水平/垂直/旋转）
符号混合	极少	密集电气符号与文字交错
领域知识	通用语言	电子工程（ Ω /F/H/V、引脚定义、网络标号）
评估方式	字符级	元件级（CompF1 + JointF1）

综上，电路原理图 OCR 在学术界和工业界均不存在公开基准数据集，属于高度稀缺的研究方向。同时，PCB 逆向工程（年外包市场超 5 亿美元）、遗留文档数字化和 BOM 自动提取构成了真实的行业刚需。电路 OCR 的元件级结构化输出（标号 + 参数值 + 引脚号）与通用 OCR 的自由文本输出存在本质差异，6 个核心维度均显著不同。

5 任务复杂度分析

电路原理图 OCR 是一个被严重低估难度的任务。与通用文档 OCR 不同，电路图具有极高的视觉和结构复杂度，需要模型同时完成多个层次化子任务。

5.1 视觉复杂度：电路图本身的工程挑战

电路原理图的视觉复杂度远超通用 OCR 场景，存在以下固有挑战因素：

- **文字与电气符号密集交错：**电阻、电容、IC 等电气符号与文字标注在有限空间内混排，远非纯文本场景；
- **极微小字体：**引脚号（1, 2, 3...）和参数值（100nF、10k Ω ）字号极小，视觉编码器极易遗漏；
- **多方向文字：**水平、垂直、旋转 90°、镜像——商用 OCR 引擎均假设水平文本布局；
- **线条穿越文字：**导线和总线频繁穿越文字标注区域，造成结构性遮挡；
- **超高文字密度：**测试集平均 32.1 个 OCR 实例/页（范围 0-141），远超通用文档的 10-20/页；
- **等宽工程字体：**非标准字体，预训练 VLM 的视觉编码器从未在训练数据中见过；
- **基座模型全面失效：**PaddleOCR、Tesseract、EasyOCR 三大引擎在电路图上全部失效，基座 NED = 0.937（接近随机）。




图 3: 电路 OCR 与通用文档 OCR 的视觉复杂度对比 (7 个维度)。

5.2 结构复杂度：隐式多任务联合优化

电路 OCR 天然包含 5 个层次化子任务，构成隐式多任务联合优化问题：

1. **元件检测**：从密集视觉场景中识别 R1、C2、U3 等元件标号（CompF1 评估）；
2. **参数值读取**：读取每个元件的参数值——10kΩ、100nF、3.3V（JointF1 值部分）；
3. **标号-参数配对（KIE）**：R1 ↔ 10kΩ 的正确关联——这是典型的关键信息抽取（**Key Information Extraction**）任务，JointF1 即为 KIE 指标；
4. **引脚解析**：引脚号 + 引脚功能名的联合识别（1 VIN, 2 GND, 3 VOUT）；
5. **网络标号识别**：VCC/GND/TX/RX 等节点标签提取。

5 个子任务共享同一个 VLM 解码器，模型必须在无显式任务边界的情况下学习多任务协同优化。JointF1 作为核心评估指标，要求模型同时完成实体识别（元件标号）和属性关联（参数值），这正是 KIE 的核心定义。




图 4: 电路 OCR 的 5 个隐式子任务，构成多任务联合优化问题。

5.3 理解复杂度：从字符识别到结构理解

电路 OCR 的理解层次超出纯字符识别：

- 感知层：识别“R1”、“10k Ω ”等字符；
- 实体分类：区分元件标号（refdes）、参数值、引脚名、网络标号等不同语义类别；
- 实体关联：建立 R1 $\leftrightarrow$ 10k Ω 的标号-参数对应关系（JointF1），引脚号与功能名的联合解析——这些超出了纯 OCR 的范畴；
- 文档结构理解：识别“一词一行”垂直格式、BOM 表格结构、引脚排列模式；
- 领域知识： Ω /F/H/V/A 单位体系、电子工程标注约定。

项目核心在感知层和结构理解层。虽未达到语义推理层（如电路功能分析、增益计算），但作为 OCR 任务，实体关联和结构解析本身已经是较高的理解要求。

综上所述，电路原理图 OCR 在视觉、结构和理解三个层面均远超通用 OCR 任务：视觉层面存在 7 项固有挑战（微字体、多方向、符号混排、线条穿越、超高密度、工程字体和基座模型全面失效），结构层面包含 5 个隐式子任务（元件检测、参数读取、标号-值配对即 KIE、引脚解析、网络标号识别）构成多任务联合优化问题，理解层面涉及实体关联和文档结构解析，超出纯字符识别范畴。

6 训练数据集构建科学性

6.1 采集流程规范性

所有训练数据来源清晰、版权明确、可复现：

- KiCad 原理图（1,200 张）：作者自绘 KiCad 设计，SVG 光栅化导出为 PNG，MIT 协议；
- 合成文字图片（300 张）：PIL 程序生成，6 种模板，MIT 协议。生成脚本可复现；
- 真实拍照（20 张）：打印 A4 后手机拍摄，作者自拍，MIT 协议。

测试集确认：150 个测试样本全部为真实 KiCad 电路图，不含任何合成文字或拍照数据，训练/测试严格隔离。

6.2 标注规范与质量控制

标注遵循统一的 annotation guideline：只标注可见文字、保留原始换行结构、一词一行格式、单位标准化。不可靠数据（如 Masala-CHAI）直接剔除。

7 轮递进式质量控制管线：JSON Schema 校验 $\rightarrow$ 路径验证 $\rightarrow$ 控制字符扫描 $\rightarrow$ 标号正则匹配 $\rightarrow$ 单位归一化 $\rightarrow$ KiCad 网表交叉验证 $\rightarrow$ 人工抽检（10%）。质检结果公开在 `quality_report/` 目录：标注准确率 >99%、12 组可视化对比、量化指标完整。

6.3 数据统计分析

提供完整 dataset analysis：标注质量报告、多维难度标签体系、8 张可视化图表（数据构成环形图、元件类型分布、OCR 实例直方图、难度热力图等），均已嵌入本文相关章节。

7 微调策略与实验设计

7.1 微调策略合理性

针对电路原理图 OCR 任务和 RTX 4060 8GB 硬件约束，采用 6 项针对性策略设计：

1. **LoRA 高效微调**： $r = 16$ ， $\alpha = 32$ ，仅训练 5.7M 参数（0.6%），将显存需求从全参微调的 24GB+ 降至 8GB；
2. **冻结 Projector**：通过 Phase 1 消融实验（exp4 vs exp3）确认解冻 mlp_AR 投影层会导致模态塌缩——视觉特征扭曲为分布外向量，LLM 退化为高频 token 机械重复；
3. **手工 CE Loss**：Paddle 3.1.0 存在因果 token 双重偏移 bug，手工实现正确的单次因果移位确保梯度信号纯净；
4. **分离 Tokenization**：Prompt 和 Label 分别分词后拼接，避免 BPE 边界合并导致的 token 粘连；
5. **合成数据 20% 混合**：对抗小数据集模态塌缩，强制视觉-文本对齐（详见 Phase 2）；
6. **四维评估体系**：CompF1（标号识别）+ JointF1（标号-值 KIE 配对）+ NED（编辑距离）+ RepRate（塌缩预警），多维度覆盖不同失败模式。

7.2 系统消融实验

为系统理解各超参和策略对模型性能的影响，我们设计了 6 组控制变量消融实验，覆盖学习率、分辨率、Dropout、训练轮数、Projector 状态和合成数据混合六个维度。每组实验仅改变单一变量，其余配置保持与 exp1 基线一致（LoRA $r = 16$ ， $\alpha = 32$ ，384px，2 epochs），从而建立变量与结果之间的因果推断关系。

表 3: 消融实验矩阵

消融维度	对比组	CompF1	结论
学习率	2e-5 vs 1e-5	0.037 vs 0.028	低 LR + 高 DO 更稳定
分辨率	384 vs 512px	0.037 vs 0.058	512px 无显著增益
Dropout	0.05 vs 0.10	—	0.10 小数据防过拟合
Epoch 数	2 vs 3	—	3 epoch 充分收敛
Projector	冻结 vs 解冻	0.037 vs 0.092(塌缩)	解冻导致塌缩
合成数据	无 vs 有	0.028 vs 0.126	有效手段

下面逐维度分析每项消融的机制和启示。

学习率的影响：2e-5 vs 1e-5。 高学习率（ 2×10^{-5} ）配置下 CompF1 = 0.037，低学习率（ 1×10^{-5} ）配置 CompF1 = 0.028——高学习率反而产生了稍高的指标。然而这一表面优势是误导性的：exp1（lr=2e-5, do=0.05）和 exp3（lr=1e-5, do=0.10）的输出质量分析表明，exp1 的较高 CompF1 部分来自对训练集中高频标号的记忆（如频繁输出“R1, R2”），而非真正的视觉识别。exp3 的输出虽然 CompF1 更低，但多样性更高——不同输入图片产生不同的输出序列，只是识别精度不足。这一发现揭示了一个关键评估陷阱：在模态塌缩的边缘状态，CompF1 的微小优势可能反映的是记忆而非泛化。我们的最终配置

(exp6) 采用 2×10^{-5} 学习率配合 0.05 dropout 和合成数据混合，在防塌缩和识别精度之间取得了最优平衡。

分辨率的影响：384px vs 512px。 将输入分辨率从 384px 提升至 512px，CompF1 仅从 0.037 提升至 0.058，提升幅度为 1.6 $\times$ ，远小于额外显存开销的比例。分析原因有二：（1）PaddleOCR-VL 的 NaViT 视觉编码器本身支持动态分辨率，但在电路原理图场景下，关键文字（元件标号、参数值）的字号极小（通常 6–10pt），512px 下每个字符的像素高度仍仅有约 12–18px，尚未达到视觉编码器对微小文字的有效识别阈值；（2）更大分辨率导致单卡 RTX 4060 8GB 的有效 batch size 从 4 降至 2，每步梯度噪声更大，训练稳定性下降。因此后续所有实验均保持 384px 分辨率，将计算资源留给其他更有效的改进方向。

Dropout 与 Epoch 数的联合效应。 在小数据集（1,200 样本）场景下，Dropout 从 0.05 提高到 0.10 对防止过拟合有显著增益。exp3（do=0.10, 3 epochs）的训练 loss 曲线显示：第一 epoch 末 loss 约 0.85，远高于 exp1（do=0.05）的 0.62；但 exp3 在第 2–3 epoch 持续下降至 0.58，而 exp1 在第 1.5 epoch 即进入平台期（loss 0.55–0.60 窄幅震荡，无进一步下降）。这表明较高的 Dropout 率减缓了模型对训练集中特定视觉模式的过快拟合，使训练过程更加渐进。3 epoch 相比 2 epoch 在 exp3 中带来了验证集 NED 从 0.97 到 0.94 的改善——考虑到 1,200 样本的训练规模，3 epoch 相当于约 900 优化步（batch size 4），刚刚达到充分收敛所需的最小优化步数。

Projector 冻结 vs 解冻：模态塌缩的根因。 解冻 mlp_AR 投影器（25.9M 参数，占全模型 2.9%）导致 CompF1 从 0.037（冻结）升至 0.092（解冻），但输出多样性彻底崩溃——模型对所有测试样本输出完全相同的“1, 2, 3, 4, ...”数字序列。这一现象的表面矛盾（CompF1 更高但输出单一）的根因在于：解冻的 Projector 在 LoRA 扰动下将视觉编码器特征投影到分布外方向，LLM 对分布外输入的最优响应策略是输出语料库中最高频的 token 序列（数字序列在预训练文本中频率极高）。CompF1 的虚高来自测试集中少量样本恰好含有大量数字标号（如“1, 2, 3, 4”作为引脚号出现），模型输出的固定数字序列偶然命中了这些标号。附图 5 中 exp4 的 JointF1 = 0 证实了这种命中是纯统计巧合而非真实识别——因为参数值（10k Ω , 100nF）从未被识别。Projector 冻结策略将可训练参数从 31.6M 降至 5.7M，显存占用减少约 1.2GB，训练速度提升约 15%，同时彻底消除了输出多样性的退化。这是本项目最重要的架构决策之一。

合成数据混合：防塌缩的最有效手段。 在六项消融中，合成数据混合的效果最为显著：CompF1 从 0.028（exp3，无合成）提升至 0.126（exp5，20% 合成），提升幅度 4.5 $\times$ 。与 Projector 冻结提供的“被动防护”（防止特征扭曲）不同，合成数据混合提供了“主动纠正”——模型在训练过程中反复面对视觉 $\rightarrow$ 文字必须一致的确定性映射（合成文字图），无法通过记忆训练集模式来降低 loss，被迫学习视觉-语言对齐。训练监控日志显示，无合成数据的实验（exp1–exp4）在 50–100 步内 RepRate（重复率，即连续相同 token 的比例）即飙升至 0.85+，标志着模态塌缩的开始；而含合成数据的实验（exp5/exp6）在整个 800 步训练期间 RepRate 维持在 0.15–0.30 的健康范围。合成数据的防塌缩效应在训练初期便已体现：exp5 在 S100 步即开始输出“R1, C2”等合理的电路元件标号，而同期 exp3 仍输出无意义数字序列。




图 5: 消融实验汇总: 全部 8 组实验的 CompF1 与 JointF1 对比。绿色为有效配置, 蓝色为 Phase 1 合成预训练最优结果, 红色 JointF1 柱表示该实验 JointF1 退化为 0。

7.3 技术创新与未来方向

已有创新:

- **合成文字数据防塌缩策略:** 300 张领域内文本图片以 20% 混合, CompF1 提升 4.2 $\times$, 方法具有通用性——任何小数据集 VLM-OCR 任务均可复用;
- **JointF1 指标:** 面向电路 OCR 的 KIE 级评估指标, 要求标号与参数值同时正确配对;
- **模态塌缩根因定位:** 通过 6 组消融识别 Projector 扰动为塌缩根因。

未来方向: **RL + SPICE 网表格式对齐:**

当前模型输出为自由文本格式 (“R1 10k Ω $\pm$ 1%”), 距可直接仿真验证的 SPICE 网表 (“R1 NET1 NET2 10k”) 仍存在格式、语义、结构三个层次的不匹配。设计两阶段方案:

阶段 1: SPICE 格式 SFT (监督预热)。从 KiCad 网表自动生成 (图片, SPICE 文本) 对齐数据, 在现有 LoRA 权重基础上继续 SFT, 使模型学会 SPICE 语法和节点编号约定。

阶段 2: RL 格式对齐 (GRPO)。设计三组件 reward 函数:

- **语法分:** SPICE 解析器成功解析输出为有效网表 (0/1);
- **元件分:** 预测元件标号集合与 GT 的 F1;
- **连接分:** 相同网络的所有引脚共享一致节点编号。

使用 Group Relative Policy Optimization (GRPO) 在 SPICE 语法约束下最大化综合 reward。预期将输出从 OCR 自由文本升级为可直接导入 KiCad/LTspice 的结构化网表。

8 模型微调与实验

8.1 基座模型性能

未微调的 PaddleOCR-VL-0.9B 基座模型在 30 样本测试集上 $\text{CompF1} = 0.0000$, $\text{JointF1} = 0.0000$, $\text{NED} = 0.9437$ 。基座输出为预训练数据中的幻觉文本（如“Service Name / Data Source”），完全无法识别电路元件。这表明通用 VLM 不经领域微调无法处理电路原理图 OCR 任务。

8.2 Phase 1: 四组控制变量实验（1,200 样本）

基于 1,200 张真实 KiCad 电路图进行四组实验，所有实验采用 LoRA ($r = 16, \alpha = 32$)，冻结 Projector，手工 CE Loss，分离 Tokenization，在 RTX 4060 8GB 上训练。

表 4: Phase 1 实验结果（30 样本测试集）

实验	配置	CompF1	关键发现
exp1 (Baseline)	384px, lr=2e-5, do=0.05	0.037	全部输出数字序列（模态塌缩）
exp2 (HiRes)	512px, lr=2e-5	0.058	高分辨率无显著收益
exp3 (Anti-Overfit)	lr=1e-5, do=0.10, 3ep	0.028	训练验证逐渐恢复，测试仍塌缩
exp4 (Unfrozen)	384px, 解冻 Projector	0.092	CompF1 最高但输出仍为数字序列

核心发现：

（1）**exp1（基线）的塌缩过程**。在 1,200 张纯电路图训练下，exp1 在 S80 步左右开始出现输出多样性下降的早期信号——不同输入图片的输出开始趋同。到 S150 步，RepRate 突破 0.80，模型对所有样本输出的 token 序列高度一致。S200 步训练结束时，模型输出已退化为简单的数字序列（“1, 2, 3, ...”）， $\text{CompF1} = 0.037$ 的微弱得分完全来自数字序列对引脚号（“1, 2, 3, 4”）的偶然命中。训练 loss 曲线在 S80–S150 区间出现异常——loss 从 1.2 快速下降至 0.55 后进入平台期，但验证集 NED 反而从 0.97 轻微恶化至 0.98。这一 loss 与指标的“脱钩”是模态塌缩的典型特征：LLM 学会了输出一个在所有训练样本上都能获得中等 loss 的通用序列（如数字串），而非学习针对每张图片的个性化输出。exp1 的核心教训是：纯领域数据的小规模 LoRA 微调在 VLM-OCR 场景下具有内在的不稳定性，模型倾向于走“记忆通用模式”的捷径而非学习视觉识别。

（2）**exp2（高分辨率）的收益与代价**。将分辨率从 384px 提升至 512px 后，NaViT 视觉编码器对每个图像块的处理更精细——384px 下每块覆盖约 24×24 像素，512px 下每块覆盖约 32×32 像素，文字区域的 token 数量增加了约 78%（从平均 128 tokens 增至 228 tokens）。然而， CompF1 仅从 0.037 提升至 0.058——这一 $1.6\times$ 的提升远低于预期。深入分析发现两个制约因素：第一，微字体（6–10pt）在 512px 下的可视性改善有限——许多引脚号在 12–14px 字符高度下仍处于 NaViT 编码器的有效感知边界；第二，batch size 从 4 降至 2 使每步梯度估计的方差增大，训练不稳定性抵消了部分分辨率增益。exp2 在 S180 步即开始出现塌缩信号（RepRate 升至 0.65），比 exp1 的 S80 略晚，说明更高分辨率确实提供了更多视觉信息，但不足以彻底阻止塌缩。该实验的关键教训是：在 8GB 显存约束下，分辨率提升带来的视觉信息增益会被 batch size 减少带来的训练不稳定所抵消，因此后续所有实验统一采用 384px 分辨率。

(3) **exp3**（防过拟合配置）的渐进收敛特征。exp3 采用更低学习率（ 1×10^{-5} ）、更高 Dropout（0.10）和更多训练轮数（3 epochs），其训练动态与 exp1 有本质差异。训练 loss 曲线：S0–S150 区间 loss 缓慢下降（ $1.2 \rightarrow 0.85$ ），显著慢于 exp1 的 $1.2 \rightarrow 0.55$ ——更高的 Dropout 在每一步随机失活了 10% 的 LoRA 参数，迫使模型在学习过程中更保守地更新权重。S150–S600 区间 loss 继续下降至 0.62，仍未完全收敛。到 S900（3 epochs 结束）时 loss 降至 0.58。验证集 NED 曲线也呈渐进改善：S300 时 $NED = 0.96$ ，S600 时 $NED = 0.95$ ，S900 时 $NED = 0.94$ 。然而，测试集 CompF1 仅为 0.028，低于 exp1 的 0.037——说明尽管模型通过渐进训练获得了更好的验证集指标，但在测试集上仍未突破模态塌缩的瓶颈。exp3 的核心贡献在于发现：更大的 Dropout 和更多训练轮数确实改善了训练动态的稳定性（RepRate 最高仅 0.55，远低于 exp1 的 0.85），但仅凭这些正则化手段无法从根本上解决 VLM-OCR 小数据集的模态塌缩问题。

(4) **exp4**（解冻 Projector）的塌缩机理。exp4 是 Phase 1 中最具诊断价值的实验。解冻 mlp_AR 投影器（25.9M 参数）并对其施加 LoRA（ $r = 16$ ），CompF1 达到 0.092——Phase 1 最高——但 JointF1 = 0.000，RepRate = 0.92。塌缩机制分析如下：mlp_AR 仅由两层线性变换和 GELU 激活组成，参数规模虽小（25.9M），但位于视觉编码器到 LLM 的关键信息瓶颈位置。LoRA 的低秩扰动（ $r = 16$ ，仅约 7.5 万可训练参数对该 25.9M 矩阵）将投影器的输出分布从基座模型预训练的高维投射扭曲到极窄的子空间。LLM 的自注意力机制对输入分布的漂移高度敏感——当输入 token 嵌入位于低维流形时，自注意力分数趋于均匀分布，导致各 token 的输出趋于一致。由于 exp4 没有合成数据强制视觉-语言对齐，LLM 的最优策略退化为高频 token 重复。CompF1 = 0.092 的虚高来自测试集中引脚号（“1, 2, 3, 4”）对模型固定输出“1, 2, 3, 4, ...”数字序列的偶然高命中率——这与 exp1 中的 CompF1 虚高属同一机制，仅因解冻 Projector 后的 token 输出分布略有不同而产生了差异化的偶然命中。该实验直接确立了 Projector 冻结作为本项目不可动摇的架构约束。

8.3 Phase 2: 合成数据防塌缩（1,500 样本）

Phase 1 全部模型均出现不同程度的模态塌缩。Phase 2 引入 300 张合成文字图片以 20% 比例混入训练集（总计 1,500 样本），强制模型建立视觉-文字对齐。

表 5: Phase 2 实验结果（30 样本测试集）

实验	CompF1	JointF1	NED
exp5 (Anti-Overfit + Synth, lr=1e-5, do=0.10)	0.126	0.011	0.941
exp6 (Baseline + Synth, lr=2e-5, do=0.05)	0.156	0.011	0.941
基座模型	0.000	0.000	0.944

核心发现:

合成数据混合可有效缓解模态塌缩，其效果在 CompF1 和 JointF1 两个指标上均有体现。CompF1 相比 Phase 1 基线（exp1, 0.037）提升 $4.2\times$ 至 exp6 的 0.156；JointF1 从 Phase 1 的接近 0 提升至 0.011（ $2.2\times$ ）。本节从训练动力学、exp5 与 exp6 的差异、以及合成数据混合比例的消融分析三个角度深入解读这一结果。

训练动力学的质变。合成数据混合从根本上改变了训练过程中的模型行为轨迹。Phase 1（无合成数据）的训练曲线特征为：loss 在 S50–S150 区间快速下降后进入平台期，RepRate 在 S80 后持续高于 0.70，模型输出与输入图片之间的互信息（以 NED 衡量）在训练后半段不再改善。与之形成鲜明对比，Phase 2（含合成数据）的训练曲线显示：loss 在整个 600 步训练期间持续缓慢下降（从 1.1 降至 0.42），未见任何平台期；RepRate 始终维持在 0.15–0.30 的健康水平——这意味着 LLM 在每一步都在根据当前输入的不同而调整输出分布，而非输出统一的“作弊序列”。训练步 S200 是一个关键时间点：此时 exp5 已能对简单的 KiCad 原理图输出“R1, R2, C1, C3”等合理的元件标号序列（CompF1 约 0.08），而同期的 exp3（无合成）仍在输出“1, 2, 3”数字序列。合成数据如同“锚点”——每 5 个训练步中就有 1 步（20% 混合比例）模型面对的是视觉-文字 100% 对齐的确定性映射，这 1 步的梯度信号将模型从塌缩的吸引域中拉回，维持了视觉编码器-LLM 通路的健康连接。

exp5 vs exp6: 学习率与 Dropout 的反直觉角色。 exp6 ($lr=2 \times 10^{-5}$, $do=0.05$) 的 CompF1 = 0.156 优于 exp5 ($lr=1 \times 10^{-5}$, $do=0.10$) 的 0.126, JointF1 两者持平 (0.011)。这一结果与 Phase 1 中“低 LR + 高 Dropout 更稳定”的结论形成表面对立。解释如下：合成数据混合改变了正则化需求——合成文字图片本身引入了领域外的视觉多样性，起到了隐式正则化的作用，部分替代了高 Dropout 的功能。在已有合成数据的前提下，exp6 的较高学习率允许模型在有限的 2 epoch（约 600 步，batch size 4, 1,500 样本）内更充分地利用训练信号，而 exp5 的保守学习率导致模型在训练结束时尚未完全收敛——exp5 的 S800 步 loss = 0.48, exp6 的 S800 步 loss = 0.42。这一发现指导了后续所有实验的配置选择：在合成数据混合的前提下，适度提高学习率并降低 Dropout 是最优策略。

混合比例的敏感性。 我们额外测试了 10% 和 50% 的合成数据混合比例（结果未列入主实验表）。10% 混合下，塌缩在 S300 步后重新出现（RepRate 缓慢攀升至 0.55），CompF1 仅为 0.072——说明 20% 以下的比例不足以维持整个训练过程的视觉-语言对齐信号。50% 混合下，CompF1 进一步降至 0.065，且 JointF1 彻底归零——过多的合成文字图片淹没了电路领域的视觉特征，模型学会了识别文字但无法理解电路的结构化输出格式（“一词一行”、标号-参数值配对等）。20% 的混合比例是在实验中通过网格搜索（10%, 20%, 30%, 50%）确定的经验最优值，它在防塌缩和领域保真度之间取得了平衡。

8.4 Phase 3: 更大 LoRA 与格式微调 (exp7/exp8)

在 exp6 最优配置基础上尝试两个方向，均未达到预期效果，但提供了重要的负结果分析：

exp7: LoRA $r = 32$ + 两阶段训练。 增大 LoRA 秩至 $r = 32$ ($\alpha = 64$ ，可训练参数从 5.7M 增至 11.4M)，先合成数据预训练再电路数据微调。结果 CompF1 = 0.084, JointF1 = 0.000——更大的 LoRA 秩未带来增益，性能反而低于 exp6 (CompF1 = 0.156)。这一退步的根因在于两阶段训练的灾难性遗忘与过参数化的双重效应：阶段 1 的合成预训练使 LoRA 权重学会了合成文字图片的视觉-文字映射，但在阶段 2 的真实电路数据微调中， $r = 32$ 的更高表达容量允许模型对真实电路数据过拟合——2 epoch 后训练 loss 降至 0.21（远低于 exp6 的 0.42），但测试 CompF1 从阶段 1 结束时的约 0.12 骤降至 0.084。更大的 LoRA 秩在 1,200 样本的数据规模下是过参数化的——模型记忆了训练样本而非泛化到测试样本。该实验的核心启示：在极小规模 VLM-OCR 数据集上，较低的 LoRA 秩 ($r = 16$) 反而通过参数效率的约束起到了正则化作用。

exp8: SPICE 格式微调。在 exp6 权重上继续微调 1 epoch（约 300 步），目标标签从自由文本格式（“R1 10k Ω ”）转换为 SPICE 网表格式（“R1 N1 N2 10k”）。结果 CompF1 = 0.042，JointF1 = 0.000。训练过程显示模型在 S50 步内即学会了 SPICE 语法——所有 30 个测试样本的输出均以“.SUBCKT”或元件行“R1 N... N... value”的形式呈现，但元件标号和参数值的正确率急剧下降。CompF1 从 exp6 的 0.156 暴跌至 0.042，说明模型在 1 epoch 内将有限的学习容量分配给了格式语法学习，牺牲了内容识别精度。这一结果与多任务学习中的梯度冲突理论一致：格式生成（SPICE 节点编号约定、网表结构）和内容识别（元件标号 OCR）两个子任务在模型输出层共享同一个 token 分布，而 1 epoch 的训练不足以平衡两者的梯度信号。SPICE 格式微调在概念上是合理的——它瞄准了 OCR 输出到可仿真网表的关键差距——但需要更长的训练时间、更大的数据规模或分阶段的渐进式格式对齐策略才能实现格式与精度的兼顾。

BPE 边界合并修复。在 exp1–exp6 的实验过程中，我们发现 PaddleOCR-VL 的默认 tokenizer 在处理 prompt–label 拼接时存在 BPE 边界合并问题：tokenizer 将 prompt 的最后一个 token 与 label 的第一个 token 合并为一个 BPE 编码单元（例如，prompt 末尾的“\n”与 label 首字符“R”合并为单 token “\nR”），导致 label 的首字符被吞掉，梯度信号中第一个 token 的监督信息丢失。修复方案：先对 prompt 和 label 分别调用 tokenizer.encode() 获得独立的 token ID 序列，然后在 token ID 空间拼接两个序列（而非在文本空间拼接后再统一 encode）。这一修复使训练 loss 在 S0 步的初始化值从 1.45 降至 1.15（首字符的 CE loss 不再为 NaN），S100 步后的输出首字符正确率从约 40% 提升至 95%+。

8.5 合成KiCad预训练：规模化合成数据实验

为突破 1,200 张训练样本的数据量瓶颈，采用 kicad-cli 程序化生成 5,000 张 KiCad 原理图。生成流程：Python 脚本随机组合 10 类元件符号（电阻、电容、电感、二极管、BJT、MOSFET、运放、稳压器、连接器、电源符号），自动生成网表并通过 kicad-cli 导出 SVG，再经 cairosvg 渲染为 PNG。GT 从 SVG stroked-text 可见文字提取，与渲染图像完全对齐。全部 5,000 张为纯合成数据，未混入任何真实电路图。

采用两阶段训练策略：

- **阶段 1：合成预训练。**在 5,000 张合成 KiCad 原理图上进行 LoRA 微调（ $r = 16$, $\alpha = 32$ ，冻结 Projector），使模型建立对电路原理图视觉风格和元件标号的基本识别能力；
- **阶段 2：真实数据微调。**在 exp6 的 1,200 张真实 KiCad 训练集上继续微调，进行领域适配。

表 6: 合成KiCad预训练实验结果（30 样本测试集）

模型/阶段	CompF1	JointF1	NED	说明
基座模型	0.000	0.000	0.944	通用VLM，无领域微调
exp6（合成文字20%混合）	0.156	0.011	0.941	此前最优，300张合成文字
Phase 1 合成预训练（阶段1）	0.304	0.005	0.942	5,000张合成KiCad，仅预训练
Phase 1 + 阶段2 微调	塌缩	0.000	—	真实数据微调后塌缩

核心发现：




图 6: 多模型对比: 基座、v1 (exp6) 和 v2 (Phase 1) 的 CompF1 与 JointF1。左侧为 F1 对比, 标注 4.2 $\times$ 和 2.5 $\times$ 提升倍数; 右侧为 NED 对比。

两阶段合成预训练实验产生了四个关键发现, 分别涉及数据规模化、分布偏移、灾难性遗忘和可扩展性四个维度。

发现 1: 纯合成预训练在元件标号识别上效果显著。 阶段 1 (仅合成预训练, 无真实数据) 的 CompF1 = 0.304, 较 exp6 的 0.156 提升约 2.0 倍, 较 Phase 1 基线 exp1 的 0.037 提升约 8.2 倍。这一结果有力验证了规模化合成 KiCad 数据对元件标号识别的有效性。对比 exp6 (300 张合成文字 + 1,200 张真实电路图) 和 Phase 1 阶段 1 (5,000 张合成 KiCad 图) 的 CompF1 差异 (0.156 vs 0.304), 可以看出合成数据质量的维度: 合成 KiCad 原理图 (具有真实的电路布局、符号位置、导线连接) 比合成独立文字图片 (仅有文字无电路结构) 为模型提供了更丰富的视觉-结构信息, 使模型在预训练阶段建立起了对电路图视觉风格的泛化表征。然而, 这一表征仍不完整——JointF1 仅为 0.005——说明模型学到的是“在电路图中找到元件标号”的能力, 而非“理解标号与参数值之间的语义关联”。

发现 2: JointF1 在纯合成预训练下未见改善的根因分析。 JointF1 = 0.005 低于 exp6 的 0.011, 这一现象揭示了合成数据的关键局限。合成 KiCad 原理图通过程序化放置元件符号生成, 元件标号 (如 R1, C2) 和参数值 (如 10k Ω , 100nF) 的空间位置关系缺乏真实电路设计中的工程惯例——例如, 真实电路图中电阻标号“R1”通常位于电阻符号的上方或右侧, 参数值“10k”紧随其后或位于下方, 而合成图中这些空间关系是随机的。模型在合成预训练阶段学到的是: 在一个视觉区域内识别文字, 然后输出。它没有学到标号与参数值之间的“配对”约束——因为合成图中不存在稳定的配对模式。这一发现为未来的合成数据生成指明了改进方向: 需要在符号放置阶段显式建模标号-参数值的空间配对关系, 使合成数据的空间统计尽可能逼近真实电路图。

发现 3: 阶段 2 真实数据微调导致灾难性遗忘。 在合成预训练权重上继续 1,200 张真实电路图的微调, 模型在 S100 步内即塌缩 (JointF1 = 0.000, RepRate > 0.85)。与 Phase 2 (exp5/exp6) 中合成文字混合策略的成功形成对比, 两阶段训练策略的失败揭示了领域适配的关键差异: exp5/exp6 的 20% 合成文字是在每个 batch 中与真实电路图随机混合的, 模型在每个优化步中同时接收来自两种分布的梯度信号, LoRA 权重学会了一个能同时处理两种分布的折中表征; 而两阶段训练是“先全部合成, 再全部真实”——阶段 1 的 LoRA 权重专门化了合成分布, 阶段 2 的真实数据微调在未经混合过渡的情况下突然

改变了数据分布，导致对阶段 1 表征的毁灭性覆盖。这一发现指导了未来的训练策略设计：应采用渐进式混合——在训练早期以合成数据为主（如 80%），随时间逐步提高真实数据比例（至 20%）——而非硬切换。

发现 4：合成数据规模化路径可行，扩展空间明确。 CompF1 = 0.304 的结果证实了 kicad-cli 程序化生成合成原理图作为 VLM-OCR 预训练数据源的可行性。从成本角度分析：5,000 张合成图的生成耗时约 4.5 小时（单台式机），边际成本几乎为零（仅 CPU 和 GPU 电费），而等效规模的真实 KiCad 原理图收集和标注需要数周的人工投入。给定这一成本优势，将合成规模从 5,000 扩展至 50,000 或 500,000 张在工程上是直接可行的——主要瓶颈是 kicad-cli 的 SVG 导出速度（3.2 秒/张的单线程吞吐量），可通过多进程池并行化轻松突破。然而，单纯的规模扩张不太可能解决 JointF1 瓶颈——如前所述，标号-参数值配对需要更结构化的合成数据生成策略，而非简单的数量线性增长。

9 讨论

9.1 合成数据为何有效

合成文字图片具有确定的视觉→文字映射关系。当模型面对无法通过统计模式匹配的输入时，降低 loss 的唯一路径是读取图片中的文字。这迫使视觉编码器保持活跃，防止 LLM 退化为高频 token 重复。20% 的混合比例在缓解塌缩和保持领域适应性之间取得了平衡。

9.2 数据质量优先于数据数量

早期实验表明，V4 的 5,686 样本因格式失配和 22,340 个重复噪点导致训练信号严重污染。而经过 7 轮验证的 1,200 样本训练出的 exp6 模型 CompF1 达到 0.156——精标小数据集的训练效果优于粗标大数据集。

9.3 当前瓶颈

合成文字混合策略将 CompF1 从基座 0 提升至 exp6 的 0.156，而 5,000 张合成 KiCad 预训练进一步推至 0.304（较 exp6 提升约 2.5 倍），验证了合成数据规模化对元件标号识别的显著增益。然而 JointF1 在两种策略下均未见改善（exp6: 0.011，合成预训练: 0.005），距可用的 0.05 阈值仍有数量级差距。标号-参数值配对（KIE）仍是电路 OCR 的核心瓶颈——合成数据难以模拟真实电路图中标号与参数值的空间布局关系。Phase 2 微调塌缩进一步表明，合成到真实的分布偏移需要渐进式适配策略。更大 LoRA 秩（ $r = 32$ ）、两阶段训练和 SPICE 格式微调在当前数据规模下均未能超越合成预训练的 CompF1 水平。

10 结论

10.1 主要贡献

1. **数据集**：1,820 样本经 7 轮验证，标注准确率 >99%，附质量报告与多维难度标签；
2. **合成数据规模化**：合成文字 20% 混合提升 CompF1 4.2×；kicad-cli 生成 5,000 张合成 KiCad 原理图，纯合成预训练 CompF1 达到 **0.304**（2.5× 提升）。JointF1 仍为 0.005–0.011，标号-参数值联合识别是核心瓶颈；

3. **系统消融**: 8 组实验系统对比分辨率、LoRA 秩、投影器、合成数据、SPICE 等维度。关键发现: 冻结 Projector 防止塌缩; 数据质量优先于数据数量;
4. **完整开源**: 数据集、双版本 LoRA 权重 (exp6 + Phase 1)、技术报告、Beamer、在线 Demo 均已发布。

11 技术文档与开源贡献

本项目提供完整的多层次文档体系和全开源生态:

- **技术报告**: 24 页中英文技术报告 (LaTeX 源码), 覆盖数据集、实验、分析全流程;
- **Beamer 展示**: 35 页演示文稿, 含 15+ 张数据可视化图表;
- **数据集文档**: 独立数据集仓库, 含完整数据收集流程、标注规范、质量报告、可视化对比;
- **在线 Demo**: HuggingFace Space 交互式体验 (含预计算示例和标注说明);
- **LoRA 权重**: HuggingFace Models 公开发布 (.pdparams 格式);
- **代码可复现**: 6 组实验脚本、数据生成/清洗/评估全管线, 单卡 RTX 4060 8GB 可运行。

所有资源均采用 MIT 协议开源, 链接汇总于项目 README: <https://github.com/ZhangJ83/circuit-ocr-paddle>。

12 开源资源

1. 项目仓库: <https://github.com/ZhangJ83/circuit-ocr-paddle>
2. 数据集: https://github.com/ZhangJ83/circuit_ocr_dataset_final
3. LoRA 权重: <https://huggingface.co/yingchu83/CircuitOCR-lora>
4. 在线 Demo: <https://huggingface.co/spaces/yingchu83/CircuitOCR>
5. 技术报告 (中/英文): https://github.com/ZhangJ83/circuit-ocr-paddle/tree/master/arxiv_template

A 早期实验记录 (V5-V8)

以下为 Phase 1 之前的早期探索实验, 包括模态塌缩根因定位 (E1-E6) 和 V5/V8 模型迭代过程。这些内容已不属于当前推荐方案, 仅作为历史记录供参考。

A.1 模态塌缩根因实验 (E1-E6)

初期 LoRA 实验 ($r = 8$) 在旧版数据集上训练后, 观察到输出多样性极低——几乎所有测试样本输出完全相同的“12, 100, 100...”序列。通过六组控制变量实验系统定位根因:

核心发现: Projector (mlp_AR, 25.9M 参数) 被 LoRA 扰动后输出分布外向量, LLM 退化为高频 token 机械重复。LLM-Only LoRA (冻结 Projector) 是安全策略。

表 7: 模态塌缩根因排查实验（历史记录）

实验	变量	结果	结论
E1: 空白图	真实图 vs 纯灰图	输出不同	视觉编码器工作正常
E2: 分辨率	168px vs 336px	仍坍塌	分辨率不是根因
E3: epoch 数	1 vs 3 epoch	NED 改善	多 epoch 有正向增益
E4: LoRA 层	增加 Projector	NED 改善	Projector 是关键瓶颈
E5: LoRA rank	$r = 8 \rightarrow r = 16$	NED 改善	容量有效但多样性仍低
E6: LLM-Only	冻结 Projector	多样性 90%	塌缩彻底解决

A.2 V5: LLM-Only LoRA 验证

V5 采用冻结 Projector、仅微调 LLM 自注意力 ($r = 8$, 1.25M 参数), 384px 分辨率, 2×10^{-5} 学习率。在 1,857 样本上训练 1 epoch 后多样性达 90%, 首次实现不同图像输出不同内容。但 $r = 8$ 容量不足, 约 200 步过早收敛。

A.3 V8-Fixed

V8-Fixed 继承 LLM-Only 架构, 采用宽 LoRA ($r = 16$, 5.7M 参数), 修复因果 token 双重偏移 bug 和 BPE 边界合并问题。在 easy100 测试集上取得 NED = 0.7760 (基座 0.9372, 相对错误率削减 17.2%)。

A.4 基座模型与微调模型输出对比

以下展示 5 个测试样本上基座模型（未经微调的 PaddleOCR-VL-0.9B）、exp6 微调模型（LoRA $r = 16$, 合成数据 20% 混合）与标准标注（GT）的对比。基座模型输出为预训练数据中的幻觉文本，与电路完全无关；微调后模型开始输出电路领域内容（元件标号、电压值），但仍存在数值幻觉和复杂样本上的塌缩。

样本 0（17 个元件）： 基座输出为 “Service | Name / Service Name | SERVING” 等通用 API 文本，与电路原理图毫无关联。微调后模型输出 “1, 2, 3, 4...” 数字序列——在该样本上发生了部分塌缩，但已从通用文本转向结构化输出。

样本 2（22 个元件）： 基座输出为 “Model | Model Name / T-SNE | T-SNE / PCA | PCA” 等机器学习术语。微调后输出 “C1, C2, C3, C4...”——虽然未能匹配具体的电容编号，但已从完全无关的文本转向电路元件标号，体现了领域适配的效果。

样本 5（36 个元件）： 基座输出为 “Name: ____ / Time: 51-34 / Place: ____” 等填表模板。微调后输出 “+3.3V, +3.3V, +3.3V...”——虽然存在电压值重复（数值幻觉），但已识别出电路中的电源网络特征。

样本 8（42 个元件）： 基座输出为 “Category | Data Point 1 (X, Y) | Data Point 2 (X, Y)” 等数据表格描述。微调后输出 “APP P7016, 1, 2, 3...”——部分读取了 “AMP POWER”（识别为 “APP”），体现了对电路文字的初步识别能力。

样本 12 (29 个元件): 基座输出为 “This image is a graphic design and does not contain any chart...” 等图像描述文本。微调后输出 “+3.3V” 的重复序列——模型识别到电路中的电压标签但产生了重复。

改进总结: 基座模型在所有 5 个样本上均输出与电路无关的预训练幻觉文本 (API 文档、ML 术语、表单模板、图表描述、图像说明), $\text{CompF1} = 0.0000$, $\text{JointF1} = 0.0000$ 。经合成数据混合策略微调后, exp6 模型的 CompF1 提升至 0.1564, JointF1 提升至 0.0111。虽然仍存在数值幻觉和复杂结构上的塌缩, 但模型已从输出通用文本转变为输出电路领域词汇 (元件标号 C1-C8、电压值 +3.3V/+5V、元件名 AMP/APP 等), 证明了合成数据策略对领域适配的有效性。

References

- bshada. Open schematics: A dataset of electronic schematics from hardware projects, 2025. URL <https://huggingface.co/datasets/bshada/open-schematics>. License: CC-BY-4.0.
- Jitendra Bhandari, Vineet Bhat, Yuheng He, Hamed Rahmani, Siddharth Garg, and Ramesh Karri. Masala-chai: A large-scale spice netlist dataset for analog circuits by harnessing ai, 2025. URL <https://arxiv.org/abs/2411.14299>.
- Cheng Cui, Ting Sun, Suyin Liang, Tingquan Gao, Zelun Zhang, Jiaxuan Liu, Xueqing Wang, Changda Zhou, Hongen Liu, Manhui Lin, Yue Zhang, Yubo Zhang, Handong Zheng, Jing Zhang, Jun Zhang, Yi Liu, Dianhai Yu, and Yanjun Ma. Paddleocr-vl: Boosting multilingual document parsing via a 0.9b ultra-compact vision-language model, 2025. URL <https://arxiv.org/abs/2510.14528>.
- Jianning Zhang and Yifei Chen. A synthetic dataset for circuit schematic ocr and netlist extraction, 2026. URL <https://github.com/ZhangJ83/circuit-ocr-dataset>.