
PADDLEOCR-VL-CIRCUIT: BUILT FOR SCHEMATIC DIAGRAM UNDERSTANDING

张健宁

柔性电子学院

中山大学

深圳市, 广东省, 中国

zhangjn83@mail2.sysu.edu.cn

陈逸菲

计算机学院

中山大学

广州市, 广东省, 中国

chenyf376@mail2.sysu.edu.cn

ABSTRACT

电路原理图自动识别是电子设计自动化 (EDA) 领域的核心挑战。本文介绍 CircuitOCR, 一个基于 PaddleOCR-VL-0.9B 的电路原理图 OCR 系统。我们构建了 V5 Golden 数据集, 包含 1,857 张 100% 视觉字面对齐的原理图 (500 张合成 + 1,357 张真实 KiCad 项目)。通过系统性的 LoRA 消融实验, 我们定位到模态塌缩的根因——微调视觉-语言投影层会破坏预训练对齐权重——并采用 LLM-Only LoRA 策略彻底解决该问题。V10-Fixed 模型采用宽 LoRA ($r = 16, \alpha = 32$, 5.7M 参数), 修复了三个关键训练 Bug (因果 token 双重移位、BPE 边界合并、Paddle 3.1.0 中 `set_state_dict` 静默失效), 在 V5 Golden 上训练 3 epoch (1,165 步), 单卡 RTX 4060 8GB 耗时 43 分钟。阶段一多指标评估在 easy50-pure (44 样本) 上取得 Component F1 = 0.2061 (基座 0.0455, 4.5 $\times$ 提升)、Token Recall = 0.1540 (基座 0.0016, 96 $\times$ 提升)、NED = 0.8031 (基座 0.9296, 相对误差降低 13.6%)。S600 为最优检查点; S800 过拟合 (重复率 40.9%)。代码、权重、数据集及在线 Demo 均已开源。

Keywords 电路原理图 · OCR · PaddleOCR-VL · LoRA 微调 · 网表提取 · 模态塌缩

1 引言

视觉语言模型 (VLM) 能够端到端地从图像输出结构化文本, 但在电路原理图领域几乎未被探索。目前尚无专门的电路原理图 OCR 公开基准。现有数据集如 Open Schematics [bshada, 2025] 缺乏标准化评估协议, 教科书数据集则因 SPICE 隐性节点导致视觉-逻辑标注偏差。

工业需求巨大。全球半导体市场 2025 年超 6,000 亿美元 (SEMI/WSTS), 仅 PCB 逆向工程外包市场每年超 5 亿美元, 其中约 30% 时间花在原理图重建上。应用场景包括硬件逆向工程、遗留文档数字化 (1980–2000 年代纸质图纸)、跨工具迁移, 以及 GitHub 上 50 万 + KiCad/EAGLE 项目缺乏结构化网表导出。

电路原理图理解包含两个异构子任务：（1）视觉文字识别——提取元件编号（R1、C1）、参数值（10k、100nF）、网络标签（VCC、GND）；（2）拓扑图论追踪——从导线和网络标签推断电气连接。评估协议涵盖两个维度：文本 NED 和元件 F1。

2 系统设置

选用 PaddleOCR-VL-0.9B [Cui et al., 2025] (908M 参数)，集成 NaViT 动态视觉编码器与 ERNIE-4.5-0.3B 语言模型，支持 109 种语言。未微调的基座模型在电路原理图上系统性失效：输出通用文档文字（如参数表格）、记忆性幻觉或重复 token 序列。根因在于预训练数据以通用文档为主，极少包含工程图纸。

3 V5 Golden 数据集

3.1 旧版缺陷与设计原则

早期版本（V1–V4）存在三个致命缺陷：（1）GT-图像不对齐——从 KiCad S-表达式解析的标签包含图像上不可见的引脚号和隐藏网络名；（2）格式失配——Open Schematics 子集使用水平空格拼接格式（62.1% 单词行 vs. 测试集 98.6%）；（3）重复噪点——22,340 个行内重复词对，污染 24.3% 样本。

V5 Golden 基于两个原则重建：（1）GT 与可见文字 100% 对齐，合成数据用 `draw.text()` 同步记录，真实 KiCad 数据从 SVG `stroked-text` 提取，零 AI 标注；（2）格式与测试集对齐，替换失配子集为 `train-real` 数据（97.9% 单词行），重复噪点削减 99.5%（22,340 → 107）。

3.2 数据来源与统计

合成 V3（500 张）。随机电路拓扑（5–30 元件，10 种类型）PNG 渲染，标签来自 `draw.text()` 记录 [Zhang and Chen, 2026]。

train-real（1,357 张）。GitHub/KiCad 社区真实开源项目，`kicad-cli` SVG → `cairosvg` PNG 渲染，GT 从 SVG `stroked-text` 可见文字提取，一词一行垂直格式。

表 1: 数据集构成与划分

划分	合成 V3	train-real	合计	avg 行数
训练集	450	1,104	1,554	32.1
验证集	50	171	171	33.4
测试 (easy50)	—	—	44	—
测试 (easy100)	—	—	89	—
总计	500	1,357	1,857	—

训练时应用在线增强：随机 JPEG 压缩（质量 85–100）、随机缩放（`max_dim` 168–384px）、随机水平翻转。

4 模型微调

4.1 模态塌缩：发现与根因

初期全量 LoRA 实验 ($r = 8$, q/k/v/o 自注意力, 2.75M 参数, 2,433 样本) 将 NED 从 0.8848 降至 0.8554, 但输出多样性塌缩至 4%——几乎所有测试样本输出完全相同内容。我们将此定义为**模态塌缩 (Modality Collapse)**。

通过六个控制变量实验 (E1–E6, 表 2), 我们系统地定位了根因:

表 2: 模态塌缩消融实验

实验	变量	结果	结论
E1	真实图 vs 空白图	输出不同	视觉编码器正常
E2	分辨率 168→336px	仍塌缩	分辨率非根因
E3	1 vs 3 epoch	NED 改善 0.9%	多 epoch 有帮助但不足
E4	增加 Projector LoRA	NED 降至 0.8271	Projector 是关键瓶颈
E5	Rank $r = 8 \rightarrow r = 16$	NED 降至 0.7961	容量有效但多样性仍 4%
E6	冻结 Projector	多样性 90%	塌缩彻底解决

核心发现: Projector LoRA 是塌缩根因。 Projector (mlp_AR, 25.9M 参数) 是视觉到语言的唯一桥梁。LoRA 扰动将其输出扭曲为 LLM 无法解释的分布外向量, 导致自回归解码退化为机械重复训练数据中的高频 token。冻结 Projector、仅教 LLM 重新解读现有视觉特征, 是安全的微调策略。

4.2 V5: LLM-Only LoRA 验证

V5 冻结 Projector, 仅微调 LLM 自注意力 ($r = 8, \alpha = 16$, 1.25M 参数), 分辨率提升至 384px, 学习率 2×10^{-5} 。在 1,857 样本上训练 1 epoch (928 步, 22 分钟), 多样性达 90%——首个能对不同图像产生不同输出的微调模型。但 $r = 8$ 容量不足: NED (0.9031) 未超越基座, 因约 200 步即过早收敛。

4.3 V10-Fixed: 三项技术修复

V10-Fixed 将 LoRA 扩展至 $r = 16, \alpha = 32$ (5.7M 参数, 占 908M 的 0.63%), 覆盖 310 个投影矩阵 (LLM 自注意力 + 线性层)。修复了三个关键训练 Bug:

1. **因果 token 双重移位:** PaddleOCR-VL 的 `AutoModelForConditionalGeneration` 内部已执行因果移位。我们的手动移位导致双重移位——用 t 时刻监督 $t + 2$ 时刻标签, 梯度信号错位。修复方案: 移除手动移位。
2. **BPE 边界合并:** 将 Prompt 与 Label 字符串拼接后统一分词, BPE 会在边界合并跨字符串字符 (如 “\n” + “R” $\rightarrow$ 合并 token)。由于 Prompt 位置被 mask (-100), Label 首字符一同被屏蔽。修复方案: 分别分词后在 Token-ID 空间拼接。

3. **set_state_dict 静默失效**: Paddle 3.1.0 中 `LoRAModel.set_state_dict()` 返回 `None` 而非元组，导致 LoRA 加载静默失败。修复方案：使用 `LoRAModel wrapper` + 手动 `p.set_value()` 逐参数加载。

在 V5 Golden (1,554 训练样本) 上训练 3 epoch (1,165 步, 43 分钟)，SFT Loss 从 2.71 收敛至 0.30。

4.4 阶段一多指标评估

阶段一建立了八指标评估协议: ExactMatch、Component F1 (CompF1)、Component Precision (CompPrec)、Component Recall (CompRec)、Token Recall (TokenRec)、NED、Repetition Rate (RepRate)、Diversity。我们在 easy50-pure (44 样本) 上评估了全部四个检查点 (S400、S600、S800、final)。

表 3: 阶段一多指标基准测试 (easy50-pure, 44 样本)

模型	ExactMatch	CompF1	CompPrec	CompRec	TokenRec	NED ↓	RepRate	Diversity
Base	0%	0.0455	0.0455	0.0455	0.0016	0.9296	6.8%	90.9%
S400	0%	0.1820	0.1862	0.2501	0.1302	0.8298	20.5%	95.5%
S600	0%	0.2061	0.2024	0.3114	0.1540	0.8031	15.9%	90.9%
S800	0%	0.2080	0.2862	0.1996	0.1191	0.8063	40.9%	93.2%

S600 为最优。S800 过拟合: RepRate 飙升至 40.9%，TokenRec 降至 0.1191。




图 2: 阶段一基准测试可视化 (七项指标; ExactMatch 省略, 因所有模型均为 0%)。S600 (蓝色, 星标) 取得最佳平衡。S800 (橙色) 明显过拟合。

关键发现: (1) S600 在 NED、TokenRec、CompRec 上均最优, 多样性健康 (90.9%)。 (2) S800 过拟合: RepRate 40.9% (S600 的近 3 倍), CompRec 坍塌至 0.1996。 (3) CompF1 提升 4.5× (0.0455 → 0.2061), TokenRec 提升 96× (0.0016 → 0.1540)。 (4) ExactMatch 仍为 0%——模型能识别元件但无法重建完整网表。 (5) 无模态塌缩: 所有检查点多样性均超 90%。

表 4: 测试样本上的代表性模型输出 (easy50-pure)

测试图像	GT 网表 (节选)	基座模型输出	S600 输出
benjiaomodular_sot22lip	/	Parameter Value	GND / R1 / 10k /
	Conn_01x06_Male	/ Parameter_a 1.0	C2 / 10nF / J1 /
	/ J3 /	/ Parameter_b 1.0	Conn_01x04_Pin
	Conn_01x03_Male	(幻觉表格)	
	/ J1 /		
	Conn_01x03_Male		
JOBriant30_PIC32_Jdev_board	/	“(a)” (单 token 塌缩)	J1 /
	Conn_01x24_Pin		Conn_01x24_Pin
	/ J2 /		/ J2 /
	Conn_01x24_Pin /		Conn_01x24_Pin /
	U2 / PIC32CX...		U2 / PIC32...
nxlabs-ch_shared-workflows	+5V / +3.3V / GND / J1 / GPIO / C1 / 100n / R1 / 3.9k	“(a)” (单 token 塌缩)	+5V / +3.3V / GND / J1 / GPIO / C1 / 100n / R1 / 3.9k

4.5 版本演进概要

表 3 提供了唯一可直接对比的评估——全部四行 (Base、S400、S600、S800) 使用相同的修复版 `eval_benchmark_v3.py` 脚本在相同的 44 样本 `easy50-pure` 测试集上评估。早期版本使用不同的评估协议，无法与阶段一数据直接对比：

- **V5 ($r = 8$, LLM-Only LoRA)**: 实现了多样性 90% 的关键突破，验证了架构方向。NED (0.9066, 50 样本集，旧版有 Bug 的评估脚本) 因 LoRA 容量不足而未超越基座，但证明了冻结 Projector 可防止塌缩。
- **V9-Pure ($r = 16$, 宽 LoRA)**: 将容量扩展至 5.7M 参数，在 89 样本 `easy100` 上使用旧版评估脚本取得 NED 0.7797 (基座 0.9390)。在 6 样本验证子集上得分为 0.8261 (基座 0.9611)。当时 `set_state_dict` Bug 尚未发现，因此这些数值可能低估了真实性能。

阶段一评估 (表 3) 作为最终基准，取代了所有早期结果。

5 实验设置

5.1 训练配置

所有实验在单卡 RTX 4060 8GB 上运行。最终配置：LoRA $r = 16$, $\alpha = 32$, 310 个投影矩阵，5.7M 参数 (0.63%)。AdamW ($\beta_1 = 0.9$, $\beta_2 = 0.95$, $\text{decay}=0.1$)， $lr = 2 \times 10^{-5}$ ，余弦退火。3 epoch (1,165 步)，`batch_size=1`，梯度累积 4。`max_dim=384px`，label 截断 200 字符。训练约 43 分钟。

5.2 评估指标

主要指标：归一化编辑距离 $NED(p, g) = \text{Levenshtein}(p, g) / \max(|p|, |g|)$ ，支持 `--unordered` 模式（按行字母排序）。阶段一新增 **CompF1**（按行重排去重后的 token 级 F1）、**CompPrec**、**CompRec**、**TokenRec**、**ExactMatch**、**RepRate**、**Diversity**（唯一输出占比）。**RepRate** > 30% 或 **Diversity** < 10% 表明退化行为。

6 讨论

6.1 模态塌缩机制与解决

Projector (mlp_AR, 25.9M 参数) 是视觉到语言的唯一映射桥。即使极小比例的 LoRA 扰动 (~0.3% 参数) 也会将其输出扭曲为 LLM 无法解释的向量，导致自回归退化为高频 token 重复。LLM-Only LoRA 通过冻结 **Projector** 彻底规避了这一问题。该发现适用于任何小数据集 VLM 微调场景。

6.2 数据质量优于数量

V4 的 5,686 个噪声样本（格式失配 62.1% vs. 98.6%，22,340 个重复噪点）被 V5 Golden 的 1,857 个清洁样本超越。Masala-CHAI 教科书数据集 [Bhandari et al., 2025] 因 SPICE 衍生标注包含不可见逻辑节点（VSS、GND）导致幻觉而被弃用——移除这 30% 样本后评估分数反而提升。精标小数据集始终优于粗标大数据集。

6.3 检查点选择与过拟合

S600→S800 的退化（RepRate 15.9% → 40.9%，TokenRec 0.1540 → 0.1191）表明更长训练需要正则化。模型开始输出记忆的高频 token 而非阅读图像。S600 处早停至关重要；未来工作应研究 dropout 和 weight decay 调优。

7 结论

本文介绍 CircuitOCR，贡献包括：

1. **V5 Golden 数据集**：1,857 样本，100% 视觉字面对齐，重复噪点削减 99.5%，格式与测试集一致——首个纯化电路原理图 OCR 基准。
2. **模态塌缩解决**：E1-E6 实验定位 Projector LoRA 为根因；LLM-Only LoRA 将多样性从 4% 恢复至 90%。
3. **V10-Fixed 模型**：宽 LoRA ($r = 16$, 5.7M 参数) + 三项训练修复，在 easy50-pure 上取得 CompF1 0.2061 ($4.5\times$)、TokenRec 0.1540 ($96\times$)、NED 0.8031（误差降低 13.6%）。S600 最优；S800 过拟合。
4. **开源生态**：数据集、训练/评估脚本、LoRA 权重、Gradio Demo 全部开源。

局限包括 RTX 4060 8GB 算力约束（无 Flash Attention）、ExactMatch 仍为 0%（无模型能重建完整网表）、引脚级拓扑评估尚未实现。未来方向：完整拓扑指标、更大 GPU 上的 Flash Attention、SPICE 仿真验证作为奖励信号、正则化技术防止 S600→S800 过拟合。

附录


A. 原始数据集样本

图 4 展示各数据源的原始（未处理）样本图像及其 GT 标签。这些是训练和评估中实际使用的 PNG 文件——无合成、无后处理。

References


- bshada. Open schematics: A dataset of electronic schematics from hardware projects, 2025. URL <https://huggingface.co/datasets/bshada/open-schematics>. License: CC-BY-4.0.
- Cheng Cui, Ting Sun, Suyin Liang, Tingquan Gao, Zelun Zhang, Jiaxuan Liu, Xueqing Wang, Changda Zhou, Hongen Liu, Manhui Lin, Yue Zhang, Yubo Zhang, Handong Zheng, Jing Zhang, Jun Zhang, Yi Liu, Dianhai Yu, and Yanjun Ma. Paddleocr-vl: Boosting multilingual document parsing via a 0.9b ultra-compact vision-language model, 2025. URL <https://arxiv.org/abs/2510.14528>.
- Jianning Zhang and Yifei Chen. A synthetic dataset for circuit schematic ocr and netlist extraction, 2026. URL <https://github.com/ZhangJ83/circuit-ocr-dataset>.
- Jitendra Bhandari, Vineet Bhat, Yuheng He, Hamed Rahmani, Siddharth Garg, and Ramesh Karri. Masala-chai: A large-scale spice netlist dataset for analog circuits by harnessing ai, 2025. URL <https://arxiv.org/abs/2411.14299>.

Synthetic V3 (Training)




Y3
R1
F2
1M
1A
BC547
47k
1nF
BZX84
HEADER-3
1mH


train-real KiCad (Training)



J3
R1
C2
R4
100
100pF
LED6
LED9
F13
F17
Q1
Q2
C14
L15
L19
Y23
J12
J16
J10
J5




C1
F2
5A
D3
LED4
BZX84
White
USB-C
DC-JACK
1N4007



R1
100
Q1
BC547
C1
R2
47k

Test (easy50-pure)




U2
A1
Arduino_USB
R4
U3
~

Vin
GND
C2
1nF
J2
Conn_01x14_Pin
GND
C1

ESP32-WROOM

C1
10uF
C2
1uF
R1
100
F1
2A

D7
D_Photo
SW7
SW_SPST
SW7
SW_SPST
D7
LED7



VBUS
J3
D-SUB 9 Male
GND
C10
100n
GND

图 1: 数据集总览: 三类数据源。上排——合成 V3: 程序化随机拓扑生成 (5–30 元件, 10 种类型), `draw.text()` 同步记录 GT。中排——train-real (KiCad): GitHub 真实开源项目, `kicad-cli SVG→cairosvg PNG` 渲染, SVG stroked-text 提取 GT。下排——测试集 (easy50-pure): 留下的真实原理图用于评估。全部为原始 PNG 渲染, 零 AI 标注。




Original Image	Ground Truth	Base Model Output	S600 Output
	J2 Comm_01x06_Male J3 Comm_01x03_Male J1 Comm_01x03_Male	Parameter Value Parameter_a 1.0 Parameter_b 1.0 Parameter_c 1.0	J1 Comm_01x05_Male J2 Comm_01x05_Male J3 Comm_01x05_Male
		NED=0.8732	NED=0.1071
	J1 Comm_01x24_Pin J2 Comm_01x24_Pin U2 PIC32CX1012BZ25048	-	J1 Comm_01x_Odd_E_even J2 Comm_01x_Odd_E_even
		NED=1.0000	NED=0.6316
	+5V +3.3V GND GND J1 GPIO C1 100n R1 3.9k JP1 ID_W/P R2 3.9k +3.3V	-	GND GND GND +3.3V +3.3V +3.3V +3.3V +3.3V
		NED=1.0000	NED=0.6818

图 3: 模型对比: 三个测试样本, 分别展示原始原理图、GT 网表、基座模型输出 (微调前)、S600 输出 (微调后)。基座模型要么幻觉通用文本, 要么塌缩为重复输出 (NED ≥ 0.87)。S600 能正确识别元件编号和参数值, 但完整网表重建仍有不足。各输出列右下角标注 NED 值。




图 4: 原始数据集样本。上排: 合成 V3 (程序化生成, `draw.text()` 同步记录 GT)。下排: train-real (KiCad 开源项目, SVG stroked-text 提取 GT)。全部为原始 PNG 渲染。