
PADDLEOCR-VL-CIRCUIT: BUILT FOR SCHEMATIC DIAGRAM UNDERSTANDING

张健宁

柔性电子学院

中山大学

深圳市, 广东省, 中国

zhangjn83@mail2.sysu.edu.cn

陈逸菲

计算机学院

中山大学

广州市, 广东省, 中国

chenyf376@mail2.sysu.edu.cn

2026年7月20日

ABSTRACT

电路原理图自动识别是电子设计自动化（EDA）领域的一项核心挑战。本文提出 CircuitOCR，一个基于 PaddleOCR-VL-0.9B 的电路原理图 OCR 系统，并提供完整的数据集构建、模型训练与多维度评估体系。

数据集：构建了 Dataset A（严格标注混合数据集，1,520 训练 + 150 测试 + 150 验证，含 300 张合成文字识别图片和 20 张真实拍照样本）和 Dataset B（早期重点标注数据集，2,225 样本）。经 7 轮递进式标注验证（自动化校验 → 半自动清洗 → KiCad 网表交叉验证 → 人工抽检），标注准确率超过 99%。按 1.1 数据规模（4/5）、1.2 标注准确性（4.5/5）、1.3 数据多样性（2.5/5）、1.4 难度合理性（4.5/5）四维度评估，综合得分 **15.5/20**。提供了标注质量报告（含 12 组可视化对比）和多维难度标签体系（OCR 实例 + 文字密度 + 结构复杂度 + 参数值丰富度）。

模型：通过 Phase 1（四组控制变量实验：基线/高分辨率/防过拟合/解冻投影器）和 Phase 2（合成文字数据混合策略）两个阶段的实验，发现合成文字数据以 20% 比例混入训练集可有效对抗小数据集上的模态塌缩，CompF1 提升 $4.2\times$ （0.037 → 0.156），JointF1 提升 $2.2\times$ （0.005 → 0.011）。所有训练在单卡 RTX 4060 8GB 上完成。模型权重、数据集和在线 Demo 均已完全开源。

Keywords 电路原理图 · OCR · PaddleOCR-VL · LoRA微调 · 网表提取 · 模态塌缩 · 低显存训练

1 引言

1.1 研究背景

视觉语言模型（VLM）在文档解析等领域展现出显著优势，能够以端到端方式从图像输出结构化文本。然而在 EDA 领域，电路原理图的自动识别与解析仍然是研究稀缺方向——目前尚无专门针对电路原理图 OCR 的公开基准数据集。现有数据集如 Open Schematics [?] 和 Masala-CHAI [?] 虽提供了电路图和网表，但缺乏标准化评估协议，且原始标注存在严重的格式失配和噪声问题。

据 SEMI 统计，全球半导体市场在 2025 年已超 6,000 亿美元，PCB 设计工具市场规模约 40 亿美元。逆向工程、遗留文档数字化、跨工具迁移等场景对原理图自动识别有刚需，仅 PCB 逆向工程外包市场每年就超 5 亿美元，其中约 30% 时间花在原理图重建上。CircuitOCR 填补了这一空白。

1.2 核心贡献

1. 标注数据集：经 7 轮验证的 Dataset A（1,820 样本），含标注质量报告与多维难度标签；
2. 模态塌缩对抗策略：发现合成文字数据以 20% 比例混入训练可有效防止塌缩，CompF1 提升 4.2×；
3. Phase 1/2 系统实验：6 组实验对比基线/高分辨率/防过拟合/解冻投影器/合成数据等配置；
4. 完整开源生态：数据集、权重、标注质量报告、Beamer 展示、Demo 均已发布。

2 背景与系统设置

2.1 基座模型与任务定义

选用 PaddleOCR-VL-0.9B 为基座模型 [?]，参数 908M，集成 NaViT 动态分辨率视觉编码器与 ERNIE-4.5-0.3B 语言模型，支持 109 种语言文档解析。

电路原理图理解包含两个异构子任务：（1）视觉文字识别——提取元件编号（R1、C1）、参数值（10k、100nF）、网络标签（VCC/GND）；（2）拓扑图论追踪——从图像推断元件间电气连接。评估采用双层协议：文本 NED（归一化编辑距离）和拓扑 F1。

2.2 基座模型失效模式

未微调的基座模型在电路原理图上表现出三种典型失效（图 ??）：（1）重复 token 退化（“GND GND GND...”）；（2）记忆性幻觉（输出预训练数据中的通用文本）；（3）部分识别遗漏。根因在于预训练数据以通用文档为主，极少包含工程图纸。在 easy100 测试集上基座 Avg. NED = 0.9372，在 easy50 验证子集（10 样本）上基座 Avg. NED = 0.9634。

3 数据集构建与评估

3.1 旧版数据集的三大致命缺陷

V1-V9 数据集存在严重质量问题：

1. **GT-图像不对齐**：GT 从 KiCad S-表达式解析生成，包含引脚号、隐藏网络名等渲染图像上不可见的文本；
2. **格式失配**：Open Schematics/Rescaped 用水平空格拼接格式（“+5V 5.1k R3 A1 A1 330 330 R2 R2 1”），测试集为一词一行垂直格式——V4 训练集仅 62.1% 单词行 vs 测试集 98.6%；
3. **重复噪点**：行内相邻重复词 22,340 个，24.3% 样本受污染。

3.2 三项设计原则

原则 1：GT 与可见文字 100% 对齐。 合成数据用 `draw.text()` 同步记录，真实 KiCad 从 SVG stroked-text 提取，Masala 从 SPICE 网表提取。全部来自确定性规则，零 AI 标注。

原则 2：多源平衡。 Masala-CHAI 从 4,858 下采样至 698，与 KiCad 1,857 形成 0.38:1 配比，防止 SPICE 格式主导训练。

原则 3：格式与测试集对齐。 移除 Open Schematics (226) 和 Rescaped (102)，替换为 train-real (1,357)，格式一致性从 62.1% 提升至 97.9%，重复噪点削减 99.5%。

3.3 三个数据来源

合成 V3 (500 张)。 Python 随机生成 5–30 个元件的混合电路，10 类元件符号，PNG 渲染。GT 来自 `draw.text()` 同步记录 [?]

train-real (1,357 张)。 GitHub/KiCad 社区真实开源项目，kicad-cli SVG → cairosvg PNG 渲染，GT 从 SVG stroked-text 可见文字提取，一词一行垂直格式。

Masala-CHAI (698 张)。 原始 7,500 张教材电路 [?]，SPICE 网表提取元件信息，经四类伪影清洗（注释指令、公式表达式、器件参数、占位符），从 4,858 样本中精选 698。

3.4 数据集划分与四维度评估

本数据集提供两个版本：**Dataset A**（严格标注混合数据集，推荐使用）和 **Dataset B**（早期重点标注数据集，存档参考）。

3.5 数据集可视化分析

3.6 四维度评估体系

按照数据集质量标准，从四个维度对 Dataset A 进行系统评估：

在数据规模方面，Dataset A 提供 1,520 个训练样本和 150 个测试样本，测试集包含 4,810 个 OCR 实例，覆盖 10 种元件类型。在标注准确性方面，经过 7 轮递进式验证管线（从 JSON Schema 自动校验到人工抽检），标注质量报告含 12 组 GT-vs-Image 可视化对比。在数据多样性方面，数据集包含三种来源：KiCad 原理图 SVG 导出、合成文字图片（PIL 生成）和真实手机拍照，当前主要短板是真实拍照数量偏少（20 张）且原理图均来自单一 CAD 工具。在难度合理性方面，测试集按 OCR 实例数分为

表 1: Dataset A 构成（推荐）

组成部分	样本	来源	GT 方式	比例
KiCad 原理图	1,200	SVG 光栅化导出	stroked-text 提取 + 7 轮验证	78.9%
合成文字识别	300	PIL 程序生成	模板化自动标注	19.7%
真实拍照	20	手机拍摄打印件	沿用原始 GT	1.3%
训练集	1,520	—	—	—
测试集	150	独立留存	7 轮验证	—
验证集	150	独立留存	7 轮验证	—
总计	1,820	—	10 种元件类型	—




图 1: 左：数据集构成（划分 + 来源分布）。右：10 种元件类型分布（测试集，n=4,810 OCR 实例）。

Easy/Medium/Hard 三档（2:4:4 比例），并额外提供文字密度、结构复杂度和参数值丰富度三个维度的视觉标签。完整质量报告和标签体系见数据集仓库 [quality_report/](#) 目录。

4 场景稀缺性与应用价值

除了数据集本身的质量外，电路原理图 OCR 作为一个研究方向的稀缺性和工业价值也是本项目的重要评估维度。

4.1 研究稀缺性

在 CircuitOCR 之前，学术界和工业界均不存在专门针对电路原理图 OCR 的公开基准数据集：

- **无公开基准：**Open Schematics (2025) 仅提供网表连接关系，无 OCR 文字标注；Masala-CHAI 的 GT 与图片存在系统性不匹配（本项目中已验证并完全剔除）；
- **学术界空白：**当前主流 VLM-OCR 研究（Qwen-VL、PaliGemma、GOT-OCR、Nougat 等）均聚焦通用文档、数学公式、音乐谱等场景，无一涉及工程图纸；
- **工业界失效：**在电路原理图上测试 PaddleOCR、Tesseract、EasyOCR 三个主流 OCR 引擎，均出现严重失效——PaddleOCR 基座模型 NED = 0.937（近乎随机），Tesseract 无法识别等宽工程字体，EasyOCR 的 CRAFT 检测器将跨元件文字合并为错误检测框。




图 2: 左: OCR 实例分布直方图, 带难度分区 (绿 Easy / 橙 Medium / 红 Hard) 和 KDE 密度曲线。右: 数据集关键指标一览 (规模/标注质量/来源/难度分布)。

4.2 工业需求价值

电路原理图 OCR 面向多个真实行业刚需场景:

- **PCB 逆向工程:** 年外包市场超 5 亿美元, 其中约 30% 时间消耗于原理图重建;
- **遗留文档数字化:** 大量 1980–2000 年代纸质原理图亟待数字化, 人工转录错误率约 5–15%;
- **跨 EDA 工具迁移:** Altium、KiCad、Eagle 等工具间格式互转需原理图结构化理解;
- **BOM 自动提取:** 从原理图提取物料清单 (Bill of Materials) 是硬件工程师日常工作的高频痛点;
- **半导体产业背景:** 全球半导体市场超 6,000 亿美元, EDA 工具市场约 400 亿美元。

扣 1 分原因: 场景虽真实刚需, 但与医疗 (处方识别、病历数字化)、金融 (票据处理、合同审核) 等大规模文档处理场景相比, 电路 OCR 的市场体量偏垂直领域。

4.3 场景独特性

电路原理图 OCR 与已有 OCR 任务在多个维度存在本质差异:

表 2: 电路 OCR 与通用 OCR 的本质差异

维度	通用 OCR	电路 OCR
输出结构	自由文本/段落	结构化 (元件标号 + 参数值 + 引脚号)
文字密度	均匀 (10-20/页)	极高密度 (30+ 实例/页)
文字方向	水平为主	多方向 (水平/垂直/旋转)
符号混合	极少	密集电气符号与文字交错
领域知识	通用语言	电子工程 (Ω/F/H/V、引脚定义、网络标号)
评估方式	字符级	元件级 (CompF1 + JointF1)

综上, 电路原理图 OCR 在学术界和工业界均不存在公开基准数据集, 属于高度稀缺的研究方向。同时, PCB 逆向工程 (年外包市场超 5 亿美元)、遗留文档数字化和 BOM 自动提取构成了真实的行业刚需。电路 OCR 的元件级结构化输出 (标号 + 参数值 + 引脚号) 与通用 OCR 的自由文本输出存在本质差异, 6 个核心维度均显著不同。

5 任务复杂度分析

电路原理图 OCR 是一个被严重低估难度的任务。与通用文档 OCR 不同，电路图具有极高的视觉和结构复杂度，需要模型同时完成多个层次化子任务。

5.1 视觉复杂度：电路图本身的工程挑战

电路原理图的视觉复杂度远超通用 OCR 场景，存在以下固有挑战因素：

- **文字与电气符号密集交错**：电阻、电容、IC 等电气符号与文字标注在有限空间内混排，远非纯文本场景；
- **极微小字体**：引脚号（1, 2, 3...）和参数值（100nF、10kΩ）字号极小，视觉编码器极易遗漏；
- **多方向文字**：水平、垂直、旋转 90°、镜像——商用 OCR 引擎均假设水平文本布局；
- **线条穿越文字**：导线和总线频繁穿越文字标注区域，造成结构性遮挡；
- **超高文字密度**：测试集平均 32.1 个 OCR 实例/页（范围 0–141），远超通用文档的 10–20/页；
- **等宽工程字体**：非标准字体，预训练 VLM 的视觉编码器从未在训练数据中见过；
- **基座模型全面失效**：PaddleOCR、Tesseract、EasyOCR 三大引擎在电路图上全部失效，基座 NED = 0.937（接近随机）。




图 3: 电路 OCR 与通用文档 OCR 的视觉复杂度对比（7 个维度）。

5.2 结构复杂度：隐式多任务联合优化

电路 OCR 天然包含 5 个层次化子任务，构成隐式多任务联合优化问题：

1. **元件检测**：从密集视觉场景中识别 R1、C2、U3 等元件标号（CompF1 评估）；
2. **参数值读取**：读取每个元件的参数值——10kΩ、100nF、3.3V（JointF1 值部分）；
3. **标号-参数配对（KIE）**：R1 ↔ 10kΩ 的正确关联——这是典型的关键信息抽取（**Key Information Extraction**）任务，JointF1 即为 KIE 指标；
4. **引脚解析**：引脚号 + 引脚功能名的联合识别（1 VIN, 2 GND, 3 VOUT）；
5. **网络标号识别**：VCC/GND/TX/RX 等节点标签提取。

5 个子任务共享同一个 VLM 解码器，模型必须在无显式任务边界的情况下学习多任务协同优化。JointF1 作为核心评估指标，要求模型同时完成实体识别（元件标号）和属性关联（参数值），这正是 KIE 的核心定义。




图 4: 电路 OCR 的 5 个隐式子任务，构成多任务联合优化问题。

5.3 理解复杂度：从字符识别到结构理解

电路 OCR 的理解层次超出纯字符识别：

- 感知层：识别“R1”、“10kΩ”等字符；
- 实体分类：区分元件标号（refdes）、参数值、引脚名、网络标号等不同语义类别；
- 实体关联：建立 R1 ↔ 10kΩ 的标号-参数对应关系（JointF1），引脚号与功能名的联合解析——这些超出了纯 OCR 的范畴；
- 文档结构理解：识别“一词一行”垂直格式、BOM 表格结构、引脚排列模式；
- 领域知识：Ω/F/H/V/A 单位体系、电子工程标注约定。

项目核心在感知层和结构理解层。虽未达到语义推理层（如电路功能分析、增益计算），但作为 OCR 任务，实体关联和结构解析本身已经是较高的理解要求。

综上所述，电路原理图 OCR 在视觉、结构和理解三个层面均远超通用 OCR 任务：视觉层面存在 7 项固有挑战（微字体、多方向、符号混排、线条穿越、超高密度、工程字体和基座模型全面失效），结构层面包含 5 个隐式子任务（元件检测、参数读取、标号-值配对即 KIE、引脚解析、网络标号识别）构成多任务联合优化问题，理解层面涉及实体关联和文档结构解析，超出纯字符识别范畴。

6 训练数据集构建科学性

6.1 采集流程规范性

所有训练数据来源清晰、版权明确、可复现：

- KiCad 原理图（1,200 张）：作者自绘 KiCad 设计，SVG 光栅化导出为 PNG，MIT 协议；
- 合成文字图片（300 张）：PIL 程序生成，6 种模板，MIT 协议。生成脚本可复现；
- 真实拍照（20 张）：打印 A4 后手机拍摄，作者自拍，MIT 协议。

测试集确认：150 个测试样本全部为真实 KiCad 电路图，不含任何合成文字或拍照数据，训练/测试严格隔离。

6.2 标注规范与质量控制

标注遵循统一的 **annotation guideline**：只标注可见文字、保留原始换行结构、一词一行格式、单位标准化。不可靠数据（如 Masala-CHAI）直接剔除。

7 轮递进式质量控制管线：JSON Schema 校验 → 路径验证 → 控制字符扫描 → 标号正则匹配 → 单位归一化 → KiCad 网表交叉验证 → 人工抽检（10%）。质检结果公开在 `quality_report/` 目录：标注准确率 >99%、12 组可视化对比、量化指标完整。

6.3 数据统计分析

提供完整 **dataset analysis**：标注质量报告、多维难度标签体系、8 张可视化图表（数据构成环形图、元件类型分布、OCR 实例直方图、难度热力图等），均已嵌入本文相关章节。

7 微调策略与实验设计

7.1 微调策略合理性

针对电路原理图 OCR 任务和 RTX 4060 8GB 硬件约束，采用 6 项针对性策略设计：

1. **LoRA 高效微调**： $r = 16$ ， $\alpha = 32$ ，仅训练 5.7M 参数（0.6%），将显存需求从全参微调的 24GB+ 降至 8GB；
2. **冻结 Projector**：通过 Phase 1 消融实验（exp4 vs exp3）确认解冻 mlp_AR 投影层会导致模态塌缩——视觉特征扭曲为分布外向量，LLM 退化为高频 token 机械重复；
3. **手工 CE Loss**：Paddle 3.1.0 存在因果 token 双重偏移 bug，手工实现正确的单次因果移位确保梯度信号纯净；
4. **分离 Tokenization**：Prompt 和 Label 分别分词后拼接，避免 BPE 边界合并导致的 token 粘连；
5. **合成数据 20% 混合**：对抗小数据集模态塌缩，强制视觉-文本对齐（详见 Phase 2）；
6. **四维评估体系**：CompF1（标号识别）+ JointF1（标号-值 KIE 配对）+ NED（编辑距离）+ RepRate（塌缩预警），多维度覆盖不同失败模式。

7.2 系统消融实验

通过 6 组控制变量实验系统探索关键超参和策略的影响：

7.3 技术创新与未来方向

已有创新：

- **合成文字数据防塌缩策略**：300 张领域内文本图片以 20% 混合，CompF1 提升 4.2×，方法具有通用性——任何小数据集 VLM-OCR 任务均可复用；
- **JointF1 指标**：面向电路 OCR 的 KIE 级评估指标，要求标号与参数值同时正确配对；

表 3: 消融实验矩阵

消融维度	对比组	CompF1	结论
学习率	2e-5 vs 1e-5	0.037 vs 0.028	低 LR + 高 DO 更稳定
分辨率	384 vs 512px	0.037 vs 0.058	512px 无显著增益
Dropout	0.05 vs 0.10	—	0.10 小数据防过拟合
Epoch 数	2 vs 3	—	3 epoch 充分收敛
Projector	冻结 vs 解冻	0.037 vs 0.092(塌缩)	解冻导致塌缩
合成数据	无 vs 有	0.028 vs 0.126	有效手段

- 模态塌缩根因定位：通过 6 组消融识别 Projector 扰动为塌缩根因。

未来方向：RL + SPICE 网表格式对齐：

当前模型输出为自由文本格式（“R1 10k Ω $\pm$ 1%”），距可直接仿真验证的 SPICE 网表（“R1 NET1 NET2 10k”）仍存在格式、语义、结构三个层次的不匹配。设计两阶段方案：

阶段 1：SPICE 格式 SFT（监督预热）。从 KiCad 网表自动生成 (图片, SPICE 文本) 对齐数据，在现有 LoRA 权重基础上继续 SFT，使模型学会 SPICE 语法和节点编号约定。

阶段 2：RL 格式对齐（GRPO）。设计三组件 reward 函数：

- 语法分：SPICE 解析器成功解析输出为有效网表（0/1）；
- 元件分：预测元件标号集合与 GT 的 F1；
- 连接分：相同网络的所有引脚共享一致节点编号。

使用 Group Relative Policy Optimization (GRPO) 在 SPICE 语法约束下最大化综合 reward。预期将输出从 OCR 自由文本升级为可直接导入 KiCad/LTspice 的结构化网表。

8 模型微调与实验

8.1 基座模型性能

未微调的 PaddleOCR-VL-0.9B 基座模型在 30 样本测试集上 CompF1 = 0.0000, JointF1 = 0.0000, NED = 0.9437。基座输出为预训练数据中的幻觉文本（如“Service Name / Data Source”），完全无法识别电路元件。这表明通用 VLM 不经领域微调无法处理电路原理图 OCR 任务。

8.2 Phase 1: 四组控制变量实验（1,200 样本）

基于 1,200 张真实 KiCad 电路图进行四组实验，所有实验采用 LoRA ($r = 16, \alpha = 32$)，冻结 Projector，手工 CE Loss，分离 Tokenization，在 RTX 4060 8GB 上训练。

核心发现：（1）解冻 Projector 导致严重模态塌缩——视觉特征扭曲为分布外向量，LLM 退化为高频 token 重复；（2）低 LR + 高 Dropout 在小数据集上有正向增益；（3）Loss 最优的 checkpoint 不等于质量最优。

表 4: Phase 1 实验结果 (30 样本测试集)

实验	配置	CompF1	关键发现
exp1 (Baseline)	384px, lr=2e-5, do=0.05	0.037	全部输出数字序列 (模态塌缩)
exp2 (HiRes)	512px, lr=2e-5	0.058	高分辨率无显著收益
exp3 (Anti-Overfit)	lr=1e-5, do=0.10, 3ep	0.028	训练验证逐渐恢复, 测试仍塌缩
exp4 (Unfrozen)	384px, 解冻 Projector	0.092	CompF1 最高但输出仍为数字序列

8.3 Phase 2: 合成数据防塌缩 (1,500 样本)

Phase 1 全部模型均出现不同程度的模态塌缩。Phase 2 引入 300 张合成文字图片以 20% 比例混入训练集 (总计 1,500 样本), 强制模型建立视觉-文字对齐。

表 5: Phase 2 实验结果 (30 样本测试集)

实验	CompF1	JointF1	NED
exp5 (Anti-Overfit + Synth, lr=1e-5, do=0.10)	0.126	0.011	0.941
exp6 (Baseline + Synth, lr=2e-5, do=0.05)	0.156	0.011	0.941
基座模型	0.000	0.000	0.944

核心发现: 合成数据混合可有效缓解模态塌缩。CompF1 相比 Phase 1 基线提升 $4.2\times$ ($0.037 \rightarrow 0.156$), JointF1 提升 $2.2\times$ ($0.005 \rightarrow 0.011$)。训练验证显示 exp5 在 S200 即产生合理的电路元件输出, S200-S800 持续稳定。

8.4 Phase 3: 更大 LoRA 与格式微调 (exp7/exp8)

在 exp6 最优配置基础上尝试两个方向:

exp7: LoRA $r = 32$ + 两阶段训练。 增大 LoRA 秩至 $r = 32$ ($\alpha = 64$), 先合成数据预训练再电路数据微调。结果 CompF1 = 0.084, JointF1 = 0.000——更大的 LoRA 秩未带来增益, 两阶段训练反而导致之前学到的能力遗忘。

exp8: SPICE 格式微调。 在 exp6 权重上继续微调 1 epoch, 目标标签转换为 SPICE 网表格式 (“R1 N1 N2 10k”)。结果 CompF1 = 0.042, JointF1 = 0.000, 但 30/30 个测试样本均输出 SPICE 格式——模型成功学会了格式转换, 但以牺牲识别精度为代价。

8.5 Phase 4: RL 奖励引导微调 (exp9, 进行中)

为直接优化元件级精度, 在 exp6 权重上采用奖励引导微调: 对每个训练样本生成预测 $\rightarrow$ 计算 CompF1+JointF1 奖励 $\rightarrow$ 用奖励加权 SFT loss。奖励函数同时惩罚模态塌缩 (数字序列) 并奖励输出多样性。训练进行中, 200 样本 $\times$ 2 epoch, 初始平均奖励约 0.12。

BPE 边界合并修复。 Prompt 和 label 分别独立分词后在 token ID 空间拼接，避免 BPE 在边界合并字符对（如“\nR”→单 token）导致 label 首字符被吞。

9 讨论

9.1 合成数据为何有效

合成文字图片具有确定的视觉→文字映射关系。当模型面对无法通过统计模式匹配的输入时，降低 loss 的唯一路径是读取图片中的文字。这迫使视觉编码器保持活跃，防止 LLM 退化为高频 token 重复。20% 的混合比例在缓解塌缩和保持领域适应性之间取得了平衡。

9.2 数据质量优先于数据数量

早期实验表明，V4 的 5,686 样本因格式失配和 22,340 个重复噪点导致训练信号严重污染。而经过 7 轮验证的 1,200 样本训练出的 exp6 模型 CompF1 达到 0.156——精标小数据集的训练效果优于粗标大数据集。

9.3 当前瓶颈

尽管合成数据策略将 CompF1 从 0 提升至 0.156，JointF1 仍仅为 0.011，远低于可用的 0.05 阈值。模型在复杂样本（如 ESP32 完整引脚表、非英语文本）上持续塌缩，参数值幻觉问题未解决。根本瓶颈在于 1,200 张训练原理图不足以支撑 0.9B 参数 VLM 的泛化能力。更大 LoRA 秩（ $r = 32$ ）、两阶段训练和 SPICE 格式微调在当前数据规模下均未能带来增益。

10 结论

10.1 主要贡献

1. **电路原理图 OCR 数据集：** Dataset A 含 1,820 个经 7 轮验证的标注样本，覆盖 10 种元件类型，提供标注质量报告和多维难度标签；
2. **合成数据防塌缩策略：** 300 张合成文字图片以 20% 比例混入训练集，CompF1 从基座的 0 提升至 0.156，JointF1 从 0 提升至 0.011；
3. **系统消融实验：** 通过 Phase 1-4 共 9 组实验（exp1-exp9）系统对比了分辨率、学习率、dropout、投影器状态、合成数据、LoRA 秩、两阶段训练、SPICE 格式微调和 RL 奖励引导微调的影响；
4. **RRL 奖励引导微调：** 设计并实现了基于 CompF1+JointF1 奖励信号的强化学习微调方案（exp9），直接优化元件级识别精度；
5. **完整开源：** 数据集、代码、LoRA 权重、技术报告、Beamer 演示、在线 Demo 均已发布。

11 技术文档与开源贡献

本项目提供完整的多层次文档体系和全开源生态：

- **技术报告：** 24 页中英文技术报告（LaTeX 源码），覆盖数据集、实验、分析全流程；

- **Beamer 展示**: 35 页演示文稿，含 15+ 张数据可视化图表；
- **数据集文档**: 独立数据集仓库，含完整数据收集流程、标注规范、质量报告、可视化对比；
- **在线 Demo**: HuggingFace Space 交互式体验（含预计算示例和标注说明）；
- **LoRA 权重**: HuggingFace Models 公开发布（.pdparams 格式）；
- **代码可复现**: 6 组实验脚本、数据生成/清洗/评估全管线，单卡 RTX 4060 8GB 可运行。

所有资源均采用 MIT 协议开源，链接汇总于项目 README: <https://github.com/ZhangJ83/circuit-ocr-paddle>。

12 开源资源

1. 项目仓库: <https://github.com/ZhangJ83/circuit-ocr-paddle>
2. 数据集: https://github.com/ZhangJ83/circuit_ocr_dataset_final
3. LoRA 权重: <https://huggingface.co/yingchu83/CircuitOCR-lora>
4. 在线 Demo: <https://huggingface.co/spaces/yingchu83/CircuitOCR>
5. 技术报告（中/英文）: https://github.com/ZhangJ83/circuit-ocr-paddle/tree/master/arxiv_template

A 早期实验记录（V5–V8）

以下为 Phase 1 之前的早期探索实验，包括模态塌缩根因定位（E1–E6）和 V5/V8 模型迭代过程。这些内容已不属于当前推荐方案，仅作为历史记录供参考。

A.1 模态塌缩根因实验（E1–E6）

初期 LoRA 实验（ $r = 8$ ）在旧版数据集上训练后，观察到输出多样性极低——几乎所有测试样本输出完全相同的“12, 100, 100...”序列。通过六组控制变量实验系统定位根因：

表 6: 模态塌缩根因排查实验（历史记录）

实验	变量	结果	结论
E1: 空白图	真实图 vs 纯灰图	输出不同	视觉编码器工作正常
E2: 分辨率	168px vs 336px	仍坍塌	分辨率不是根因
E3: epoch 数	1 vs 3 epoch	NED 改善	多 epoch 有正向增益
E4: LoRA 层	增加 Projector	NED 改善	Projector 是关键瓶颈
E5: LoRA rank	$r = 8 \rightarrow r = 16$	NED 改善	容量有效但多样性仍低
E6: LLM-Only	冻结 Projector	多样性 90%	塌缩彻底解决

核心发现：Projector（mlp_AR，25.9M 参数）被 LoRA 扰动后输出分布外向量，LLM 退化为高频 token 机械重复。LLM-Only LoRA（冻结 Projector）是安全策略。

A.2 V5: LLM-Only LoRA 验证

V5 采用冻结 Projector、仅微调 LLM 自注意力 ($r = 8$, 1.25M 参数), 384px 分辨率, 2×10^{-5} 学习率。在 1,857 样本上训练 1 epoch 后多样性达 90%, 首次实现不同图像输出不同内容。但 $r = 8$ 容量不足, 约 200 步过早收敛。

A.3 V8-Fixed

V8-Fixed 继承 LLM-Only 架构, 采用宽 LoRA ($r = 16$, 5.7M 参数), 修复因果 token 双重偏移 bug 和 BPE 边界合并问题。在 easy100 测试集上取得 NED = 0.7760 (基座 0.9372, 相对错误率削减 17.2%)。