
PADDLEOCR-VL-CIRCUIT: BUILT FOR SCHEMATIC DIAGRAM UNDERSTANDING

张健宁

柔性电子学院

中山大学

深圳市, 广东省, 中国

zhangjn83@mail2.sysu.edu.cn

陈逸菲

计算机学院

中山大学

广州市, 广东省, 中国

chenyf376@mail2.sysu.edu.cn

2026 年 6 月 22 日

ABSTRACT

Keywords 电路原理图 · OCR · PaddleOCR-VL · LoRA 微调 · 网表提取

1 引言

视觉语言模型 (VLM) 极大地扩展了传统大语言模型的应用边界, 在需要视觉理解的场景 (如机器人导航、文档解析任务) 中展现出显著优势。相比于传统 OCR 方案依赖多级流水线和大量内存开销, VLM 能够以端到端的方式直接从图像输出结构化文本, 省去了繁琐的中间处理步骤。

2 背景与系统设置

2.1 基座模型规格

本次项目选用 PaddleOCR-VL 为开源基座模型 [Cui et al., 2025]。PaddleOCR-VL 是一款为文档解析任务量身打造的、性能顶尖 (SOTA) 且轻量高效的模型。它的核心是 PaddleOCR-VL-0.9B——一个紧凑而强大的视觉语言模型 (VLM)。该模型创新地集成了 NaViT 风格的动态分辨率视觉编码器与 ERNIE-4.5-0.3B 语言模型, 从而能够精准地识别各类文档元素。

这款模型不仅能高效支持 109 种语言, 还擅长识别文本、表格、公式、图表等复杂元素, 并始终保持极低的资源占用。在多个权威的公开及内部基准测试中, PaddleOCR-VL 的页面级文档解析与元素级识别性能均达到了业界顶尖水平。其性能远超现有方案, 面对顶级视觉语言模型也极具竞争力, 且推理速度飞快。这些杰出特性使其成为在真实场景中落地部署的理想选择。

2.2 工程场景定义

电路原理图 (Electronic Schematic Diagram) 是一种用标准图形符号表示电子元件及其电气连接关系的二维工程图, 它不反映物理布局, 只表达逻辑拓扑。电路原理图属于 EDA 这一垂直工业领域, 是一种工程图纸和技术文档的核心载体, 其自动识别与解析具有重要的工程价值。电路原理图作为一种高度复杂的专业技术文档, 包含的复杂元素有: 文本元素, 包括元件编号 (如 R1、C1)、阻值 (如 10k、100nF)、网络标签 (如 VCC、GND、SPI-CLK) 以及图纸右下角的标题栏文本; 特殊字符, 包括电容特有的物理单位和符号, 例如 Ω (欧姆)、 μ (微)、 $\pm$ (容差); 表格元素, 包括多引脚芯片的引脚表、物料清单 (BOM 表) 以及版本变更表; 结构化数据, 包括电路的连接关系和网络拓扑, 需提取类似于公式或代码的结构化网表。

2.3 原生大语言模型的局限性

该思路的缺陷来自原生的、未微调的基座模型在技术文档中电路原理图文档识别中有严重的问题: 在电路原理图的任务下, PaddleOCR-VL-0.9B 并未进行有效的 OCR 识别, 而是出现三种典型的失效模式——1. 输出重叠、重复的多单词拼接 (如反复输出同一词元); 2. 模型生成训练数据中记忆的通用文本, 而非根据输入图像进行识别 (即“脑补”而非读图); 3. 偶尔输出部分正确的元件标签, 但遗漏了主要元件名称。在未微调的情况下, 我们进行了电路原理图基准测试 (Benchmark), 基座模型的输出为无意义的格式标记, 在接收电路图输入时要么输出无价值的乱码, 要么生成通用模板文本, 要么陷入重复 token 的退化模式。

3 系统的数据集构建

3.1 原始数据收集与来源

我们构建了第一个高质量且有效的多源数据库 [Zhang, 2026]。我们数据集的一部分为 Open Schematic 开源大型数据集 [bshada, 2025], 真实场景包括 8450 张真实原理图和标准件, 大小约 0.7G (商用)。该数据集采用原版 CC-BY-4.0 署名协议, 可自由开源和商用, 完全为真实世界标准和命名, 独立于标注坐标而非图像像素坐标。其标注中公式估计 Bounding Box 的准确度约为 71.4

第二部分为 Masala-CHAI 开源数据集 [Bhandari et al., 2025], 同样使用 CC-BY-4.0 署名协议, 部分配套代码采用 Apache-2.0。该数据集内容为电子课本、教材中搜集整理的电路图, 每张图都直接配有标准 Spice 网表真值, 直接契合“原理图-转网表”的任务, 适合作为 SFT 的数据集, 用于微调端到端图像生成 Spice 仿真网表。

第三部分为我们的合成数据集 [Zhang and Chen, 2026]。该数据集通过 Python 脚本程序化生成, 总计约 14,000 张原理图渲染图像。生成流程为: 程序随机生成电路拓扑规格 (包含数十至上百个元件的复杂连接关系), 自动绘制原理图并渲染为 PNG 图像, 同时从电路逻辑中直接提取标注信息——包括元件编号 (如 R1、C1)、参数值 (如 10k、100nF)、网络标签 (如 VCC、GND) 以及完整的 Spice 网表, 标注精度为 100%。电路类型覆盖模拟、数字、混合信号及电源四大类, 元件库随迭代持续扩充至 5 种通用库。为模拟真实场景中的图像退化, 每张原理图施加 5 种退化增强: 纸张老化 (泛黄、斑点)、扫描噪点与条纹、拍照透视变形、手写标注叠加以及低分辨率扫描。合成数据集提供了完美的真值和清晰的几何边界, 有效弥补了前述两个开源数据集在标注精度和退化覆盖上的不足。

以上三个来源的数据集：Open schematics 和 Masala-CHAI 提供了真实世界的多套拓扑结构、海量真实芯片命名（如 ATMEGA328P、TPS5430），而我们的合成数据集则提供了清晰的几何边界和完美的真值。多源数据的互补让模型既具备对真实元件符号的广泛理解，又具备极高像素定位精度，防止模型只认识一种画图软件的字库或布局。

3.2 筛选、去重与质量控制

- 开源数据集情况

1. Open Schematics: 约 8450 张，为实物原理图，规模大，覆盖真实世界多样元件 2. Masala-CHAI: 约 7500 张，物料标注图，配有标准 Spice 仿真网表

- 合成数据集：迭代 23 版，应用 35 种透视噪声，总计 14000 张总规模已达 30k+

3.2.1 数据清洗去重

为保证输入模型数据质量，我们构建了「原始数据 → 结构过滤 → 去重模块 → 人工复检」流水线。

1. 去重规则

原理图由于图像像素库的合成映射部分，存在重复，我们使用三组去重方案：

- 文本哈希去重（纯文字）：对原始、kicad、eda 文本渲染单张 png 图计算 MD5/SHA256 哈希值，直接剔除完全相同文本。- 拓扑哈希去重（逻辑去重）：不同的人绘制相同电路，其摆放位置不同，但电气拓扑一样。我们将图中元件类型、连接关系进行标准化顺序重连接，生成拓扑特征字符串，对其计算 MD5，剔除电路逻辑中 100- 视觉感知哈希（phash/dhash）：使用感知哈希算法对整张 png 图进行对比，剔除视觉上仅有极小的差异（如仅修改右下角版本号或日期）的重复图。

2. 样本严格规则

- 多元元件过滤：剔除元件数量少于 3 个的图纸（很多是实验室工程、单纯 PCB 框图或单一封装库）- 边界与重叠文本清洗：检查标注 Bounding Box 是否超出图像边界（ $x < 0$ / width 超界等）；对于文本框之间的 IOU，如果两个不同文本的 IOU > 0.8，严重重叠无法辨认，则删除该样本。- 失真图纸剔除清洗：剔除含有 pwr 等 kicad 内部隐藏电路符号标注图（因为它们不在图像上强行加冗余会使模型产生幻觉）。

质检流水线

3.2.2 大模型质量打分净化

引入视觉大模型对所有原理图图像进行自动打分（1-5 分），评判维度包括：

- 清晰画质：图纸文字是否能被人类肉眼辨别；剔除过度模糊、对比度低的退化图。- 多元元件密度：画面是否过密导致无法分辨、图纸拥挤。- 质量阈值：仅保留综合分 ≥ 3 的样本。

人工检验

对于将用于评估的测试集与基准集样本，必须单独进行人工加框校验构建简单的 Gradio 可视化质检工具：将图像、预测 Bbox 框在图上画出，在右侧展示对应网表

人工排查复查

对质检工具初筛后漏检样本人工校验排查、修正。回滚机制：在大检验中发现的系统性、普遍性网表逻辑错误，会回滚修改我们的合成生成代码，重新渲染该部分数据。

3.2.3 执行清洗

数据清洗与多源质控统计

清洗模块同时对 Masala-CHAI、Open Schematics 和合成数据集内的共计 4 万 + 样本进行多轮去重和质量筛查：

1. 初始筛选样本：39947 个 2. 拓扑去重后剩余：14897 个 3. 视觉哈希、感知哈希过滤：9117 个（过滤掉 7 千个拓扑相同但图片轻微改动的重复图纸案例）；逻辑去重：1580 个（去掉拓扑相同但命名参数、标注重复的样本）；SFT（监督微调）样本自动筛选 10240 份，重复去重 1100 份；视觉打分评估：2530 个（通过大模型评估过滤掉清晰度极低、细小模糊失真的真实原理图，共清除低于 3 分的异常样本 0 个，即该批次样本均通过质量筛查）

数据集划分与 PaddleOCR-VL SFT 格式转换

经过上述严苛清洗，最终得总量为 24717 个独立原理图样本，按照 70

注：整轮人工校验没有进行，一方面由于时间和人手限制，另一方面由自动数据清洗流程和多源数据集原生规范，已最大程度确保数据集的正确性。

数据集分层面

- 合成数据集：由电路生成算法在程序内直接绘制，无需标注（bbox），连接关系由程序逻辑直接输出，在标注字符和多值信息上有绝对精度。Masala-CHAI 和 Open Schematics 样本来自教材和 GitHub 的真实项目原理图，标注存在差异。- 清洗管线三重过滤：对于可能存在瑕疵噪声的真实世界原理图，我们采取了严格的自动化校验并使用大模型视觉自检，用 AI 替代人工初审。- 输出端格式一致性校验：对划分后的样本进行逐行校验，100

3.3 数据分布与统计

4 模型微调以及后训练

4.1 模型微调

4.2 后训练

5 实验评估

5.1 基线模型

5.2 微调与后训练后的模型

6 实证分析

7 总结与局限性

References

- Cheng Cui, Ting Sun, Suyin Liang, Tingquan Gao, Zelun Zhang, Jiaxuan Liu, Xueqing Wang, Changda Zhou, Hongen Liu, Manhui Lin, Yue Zhang, Yubo Zhang, Handong Zheng, Jing Zhang, Jun Zhang, Yi Liu, Dianhai Yu, and Yanjun Ma. Paddleocr-vl: Boosting multilingual document parsing via a 0.9b ultra-compact vision-language model, 2025. URL <https://arxiv.org/abs/2510.14528>.
- Jianning Zhang. A multi-source dataset for circuit schematic ocr and netlist extraction, 2026. URL https://github.com/ZhangJ83/circuit_ocr_dataset_final.
- bshada. Open schematics: A dataset of electronic schematics from hardware projects, 2025. URL <https://huggingface.co/datasets/bshada/open-schematics>. License: CC-BY-4.0.
- Jitendra Bhandari, Vineet Bhat, Yuheng He, Hamed Rahmani, Siddharth Garg, and Ramesh Karri. Masala-chai: A large-scale spice netlist dataset for analog circuits by harnessing ai, 2025. URL <https://arxiv.org/abs/2411.14299>.
- Jianning Zhang and Yifei Chen. A synthetic dataset for circuit schematic ocr and netlist extraction, 2026. URL <https://github.com/ZhangJ83/circuit-ocr-dataset>.