
PADDLEOCR-VL-CIRCUIT: BUILT FOR SCHEMATIC DIAGRAM UNDERSTANDING

张健宁
柔性电子学院
中山大学
深圳市, 广东省, 中国
zhangjn83@mail2.sysu.edu.cn

陈逸菲
计算机学院
中山大学
广州市, 广东省, 中国
chenyf376@mail2.sysu.edu.cn

2026年7月20日

ABSTRACT

电路原理图自动识别是电子设计自动化 (EDA) 领域的核心挑战。本文介绍 CircuitOCR, 一个基于 PaddleOCR-VL-0.9B 的电路原理图 OCR 系统。我们构建了 V5 Golden 数据集, 包含 1,857 张 100% 视觉字面对齐的原理图 (500 张合成 + 1,357 张真实 KiCad 项目)。通过系统性的 LoRA 消融实验, 我们定位到模态塌缩的根因——微调视觉-语言投影层会破坏预训练对齐权重——并采用 LLM-Only LoRA 策略彻底解决该问题。V10-Fixed 模型采用宽 LoRA ($r = 16, \alpha = 32, 5.7M$ 参数), 修复了六个关键训练 Bug (三项序列生成: 因果 token 双重移位、BPE 边界合并、Paddle 3.1.0 中 `set_state_dict` 静默失效; 三项 PaddleOCR-VL 特定: LoRA 精度损失、tokenizer 偏移、梯度累积解耦; 详见 Dataset README), 在 V5 Golden 上训练 3 epoch (1,165 步), 单卡 RTX 4060 8GB 耗时 43 分钟。阶段一多指标评估在 easy50-pure (44 样本) 上取得 Component F1 = 0.2061 (基座 0.0455, $4.5\times$ 提升)、Token Recall = 0.1540 (基座 0.0016, $96\times$ 提升)。阶段二拓扑评估揭示真实能力: joint (标号, 值) 对 F1 = 0.019——仅约 2% 的元件完全正确, 87% 的参数值被幻觉。代码、权重、数据集及在线 Demo 均已开源。详细实验结果、标注示例和版本历史见附录。

Keywords 电路原理图 · OCR · PaddleOCR-VL · LoRA微调 · 网表提取 · 模态塌缩

1 引言

视觉语言模型 (VLM) 能够端到端地从图像输出结构化文本, 但在电路原理图领域几乎未被探索。目前尚无专门的电路原理图 OCR 公开基准。现有数据集如 Open Schematics [?] 缺乏标准化评估协议, 教科书数据集则因 SPICE 隐性节点导致视觉-逻辑标注偏差。

工业需求巨大。全球半导体市场 2025 年超 6,000 亿美元（SEMI/WSTS），仅 PCB 逆向工程外包市场每年超 5 亿美元，其中约 30% 时间花在原理图重建上。应用场景包括硬件逆向工程、遗留文档数字化（1980–2000 年代纸质图纸）、跨工具迁移，以及 GitHub 上 50 万+ KiCad/EAGLE 项目缺乏结构化网表导出。

电路原理图理解包含两个异构子任务：（1）视觉文字识别——提取元件编号（R1、C1）、参数值（10k、100nF）、网络标签（VCC、GND）；（2）拓扑图论追踪——从导线和网络标签推断电气连接。评估协议涵盖两个维度：文本 NED 和元件 F1。

2 系统设置

选用 PaddleOCR-VL-0.9B [?]（908M 参数），集成 NaViT 动态视觉编码器与 ERNIE-4.5-0.3B 语言模型，支持 109 种语言。未微调的基座模型在电路原理图上系统性失效：输出通用文档文字（如参数表格）、记忆性幻觉或重复 token 序列。根因在于预训练数据以通用文档为主，极少包含工程图纸。




图 1: LLM-Only LoRA 架构。蓝色模块为冻结；橙色 LLM 模块接收低秩适配器。Projector (mlp_AR) 是唯一的视觉-语言桥梁——扰动它会导致模态塌缩（E4，第 4.1 节）——因此保持冻结。仅 LLM 自注意力和线性投影矩阵（310 个目标）被适配。

3 V5 Golden 数据集

3.1 旧版缺陷与设计原则

早期版本（V1–V4）存在三个致命缺陷：（1）GT-图像不对齐——从 KiCad S-表达式解析的标签包含图像上不可见的引脚号和隐藏网络名；（2）格式失配——Open Schematics 子集使用水平空格拼接格式（62.1% 单词行 vs. 测试集 98.6%）；（3）重复噪点——22,340 个行内重复词对，污染 24.3% 样本。

V5 Golden 基于两个原则重建：（1）GT 与可见文字 100% 对齐，合成数据用 `draw.text()` 同步记录，真实 KiCad 数据从 SVG stroked-text 提取，零 AI 标注；（2）格式与测试集对齐，替换失配子集为 train-real 数据（97.9% 单词行），重复噪点削减 99.5%（22,340 → 107）。

3.2 数据来源与统计

合成 V3 (500 张)。随机电路拓扑 (5–30 元件, 10 种类型) PNG 渲染, 标签来自 `draw.text()` 记录 [?]

train-real (1,357 张)。GitHub/KiCad 社区真实开源项目, kicad-cli SVG $\rightarrow$ cairosvg PNG 渲染, GT 从 SVG stroked-text 可见文字提取, 一词一行垂直格式。

表 1: 数据集构成与划分

划分	合成 V3	train-real	合计	avg 行数
训练集	450	1,104	1,554	32.1
验证集	50	171	221	33.4
测试 (easy50)	–	–	44	–
测试 (easy100)	–	–	89	–
总计	500	1,357	1,857	–

总计行 (1,857) 与训练+验证行之和 (1,775) 之间的 82 样本差值为预留的额外真实 KiCad 测试集, 独立于 easy50/easy100 基准划分。V5 Golden 总量为 $1,857 = 1,554$ (训练) + 221 (验证) + 82 (预留测试)。

4 模型微调

4.1 模态塌缩: 发现与根因

初期全量 LoRA 实验 ($r = 8$, q/k/v/o 自注意力, 2.75M 参数, 2,433 样本) 将 NED 从 0.8848 降至 0.8554, 但输出多样性塌缩至 4%——几乎所有测试样本输出完全相同内容。我们将此定义为模态塌缩 (Modality Collapse)。

通过六个控制变量实验 (E1–E6, 表 2), 我们系统地定位了根因:

表 2: 模态塌缩消融实验

实验	变量	结果	结论
E1	真实图 vs 空白图	输出不同	视觉编码器正常
E2	分辨率 168 $\rightarrow$ 336px	仍塌缩	分辨率非根因
E3	1 vs 3 epoch	NED 改善 0.9%	多 epoch 有帮助但不足
E4	增加 Projector LoRA	NED 降至 0.8271	Projector 是关键瓶颈
E5	Rank $r = 8 \rightarrow r = 16$	NED 降至 0.7961	容量有效但多样性仍 4%
E6	冻结 Projector	多样性 90%	塌缩彻底解决

核心发现：Projector LoRA 是塌缩根因。 Projector (mlp_AR, 25.9M 参数) 是视觉到语言的唯一桥梁。LoRA 扰动将其输出扭曲为 LLM 无法解释的分布外向量，导致自回归解码退化为机械重复训练数据中的高频 token。冻结 Projector、仅教 LLM 重新解读现有视觉特征，是安全的微调策略。

4.2 V5: LLM-Only LoRA 验证

V5 冻结 Projector，仅微调 LLM 自注意力 ($r = 8, \alpha = 16$, 1.25M 参数)，分辨率提升至 384px，学习率 2×10^{-5} 。在 1,857 样本上训练 1 epoch (928 步，22 分钟)，多样性达 90%——首个能对不同图像产生不同输出的微调模型。但 $r = 8$ 容量不足：NED (0.9031) 未超越基座，因约 200 步即过早收敛。

4.3 V10-Fixed: 六项技术修复

V10-Fixed 将 LoRA 扩展至 $r = 16, \alpha = 32$ (5.7M 参数，占 908M 的 0.63%)，覆盖 310 个投影矩阵 (LLM 自注意力 + 线性层)。LoRA [?] 用低秩更新 $\Delta W = BA$ 增广冻结权重 $W_0 \in \mathbb{R}^{d \times k}$ ，其中 $B \in \mathbb{R}^{d \times r}$ ， $A \in \mathbb{R}^{r \times k}$ ， $r \ll \min(d, k)$ 。前向传播变为 $h = W_0 x + \frac{\alpha}{r} B A x$ ， W_0 冻结，仅训练 A, B 。修复了六个关键训练 Bug (另有三项 PaddleOCR-VL 特定 Bug 记录于 Dataset README)：

1. **因果 token 双重移位：**PaddleOCR-VL 的 `AutoModelForConditionalGeneration` 内部已执行因果移位。我们的手动移位导致双重移位——用 t 时刻监督 $t + 2$ 时刻标签，梯度信号错位。修复方案：移除手动移位。
2. **BPE 边界合并：**将 Prompt 与 Label 字符串拼接后统一分词，BPE 会在边界合并跨字符串字符（如 “\n” + “R” $\rightarrow$ 合并 token）。由于 Prompt 位置被 mask (-100)，Label 首字符一同被屏蔽。修复方案：分别分词后在 Token-ID 空间拼接。
3. **set_state_dict 静默失效：**Paddle 3.1.0 中 `LoRAModel.set_state_dict()` 返回 None 而非元组，导致 LoRA 加载静默失败。修复方案：使用 `LoRAModel wrapper` + 手动 `p.set_value()` 逐参数加载。

这六项 Bug 是我们为社区利益记录的实施陷阱——它们影响所有遵循标准实践的 PaddleOCR-VL 微调 workflow。上述三项序列生成 Bug 影响任何 VLM 微调管线。另三项 PaddleOCR-VL 特定 Bug——(4) LoRA 权重精度损失 (`p.set_value()` float32 $\rightarrow$ float16 截断误差)、(5) tokenizer 特殊 token 偏移 (坐标预测偏差)、(6) 梯度累积与学习率解耦 (`global_step` 错位)——详见 Dataset README，修复方案已合并入 `LoRAModel wrapper`。全部六项修复已向上游 PaddleOCR-VL 社区报告。

在 V5 Golden (1,554 训练样本) 上训练 3 epoch (1,165 步，43 分钟)，SFT Loss 从 2.71 收敛至 0.30。

4.4 阶段一多指标评估

阶段一建立了八指标评估协议：ExactMatch、Component F1 (CompF1)、Component Precision (CompPrec)、Component Recall (CompRec)、Token Recall (TokenRec)、NED、Repetition Rate (RepRate)、Diversity。主指标归一化编辑距离定义为 $NED(s_1, s_2) = \text{Lev}(s_1, s_2) / \max(|s_1|, |s_2|)$ ，其中 $\text{Lev}(\cdot)$ 为 Levenshtein 距离；我们使用 `-unordered` 模式以消除行序偏差。我们在 easy50-pure (44 样本) 上使用修复版 `eval_benchmark_v3.py` 脚本评估了全部四个检查点 (S400、S600、S800、final)——这是所有模型间唯一可直接对比的评估。全部四个评估划分 (easy50/100/200/full523，共 523 样本) 的

完整结果见附录 B。正文以 easy50-pure 子集为重点，因其最干净、最具代表性；各划分间指标稳定（CompF1 差异在 0.005 以内）。

表 3: 阶段一多指标基准测试（easy50-pure，44 样本）

模型	ExactMatch	CompF1	CompPrec	CompRec	TokenRec	NED ↓	RepRate	Diversity
Base	0%	0.0455	0.0455	0.0455	0.0016	0.9296	6.8%	90.9%
S400	0%	0.1820	0.1862	0.2501	0.1302	0.8298	20.5%	95.5%
S600	0%	0.2061	0.2024	0.3114	0.1540	0.8031	15.9%	90.9%
S800	0%	0.2080	0.2862	0.1996	0.1191	0.8063	40.9%	93.2%

S600 为最优。S800 过拟合：RepRate 飙升至 40.9%，TokenRec 降至 0.1191。全部划分（easy50/100/200/full523）的完整结果见附录 B。




图 4: 阶段一基准测试可视化（七项指标；ExactMatch 省略，因所有模型均为 0%）。S600（蓝色，星标）取得最佳平衡。S800（橙色）明显过拟合。

关键发现：（1）S600 在 NED、TokenRec、CompRec 上均最优，多样性健康（90.9%）。（2）S800 过拟合：RepRate 40.9%（S600 的近 3 倍），CompRec 坍塌至 0.1996。（3）CompF1 提升 $4.5\times$ （ $0.0455 \rightarrow 0.2061$ ），TokenRec 提升 $96\times$ （ $0.0016 \rightarrow 0.1540$ ）。（4）ExactMatch 仍为 0%——模型能识别元件但无法重建完整网表。（5）无模态塌缩：所有检查点多样性均超 90%。

4.5 阶段二拓扑评估

阶段一的 CompF1 仅衡量元件标号级别的 F1——只要标号（如 R1）匹配即算正确，不要求参数值（如 10k）正确。这高估了实际可用性。阶段二通过 eval_topology_v2.py 引入联合（标号, 值）对评估：将扁平网表文本解析为（标号, 值）对并计算对级 F1。一个元件只有在其标号和值同时正确时才计入。

表 4: 阶段二拓扑指标 (easy50-pure, 44 样本)

模型	comp_f1	joint_f1	value_acc
Base	0.0455	0.0000	—
S400	0.1820	0.0027	0.006
S600	0.2061	0.0191	0.133
S800	0.2080	0.0064	0.023

comp_f1 精确复现阶段一数值。joint_f1 揭示真实能力差距：S600 仅 1.9% 的 (标号, 值) 对完全正确。值匹配采用大小写不敏感比较并做单位归一化 (如 “10k” = “10kΩ”, “100n” = “100nF”)。逐样本分解见附录 C, 标注示例见附录 D。

comp_f1 (0.206) 与 joint_f1 (0.019) 之间的差距是阶段二的核心发现：S600 能识别约 31% 的元件标号，但仅约 2% 的元件标号和值同时正确。即使在 14 对匹配的标号中，value_acc 也仅为 0.133——87% 的值错误，模型倾向于输出训练数据中的高频值 (10k、100nF、1k)。这直接驱动了阶段三：对视觉编码器高层施加 LoRA 并提高输入分辨率以改善细粒度值判别能力。

需要强调，ExactMatch = 0% 和 joint_f1 = 0.019 是当前规模下的预期结果 (0.9B 参数, 5.7M 可训练, 1,554 样本, 消费级 GPU 43 分钟)。有意义的信号是 CompF1 4.5× 提升和 TokenRec 96× 提升，这证明了 LoRA 能够在无模态塌缩的前提下教会小型 VLM 领域词汇。

4.6 版本演进概要

表 3 提供了唯一可直接对比的评估——全部四行使用相同的脚本在相同的 44 样本测试集上完成。早期版本 (V1–V9) 使用不同评估协议，详见附录 E。简要而言：V1–V4 发现并诊断了模态塌缩 (多样性 4%)；V5 通过冻结 Projector (LLM-Only LoRA, $r = 8$) 实现了多样性 90% 的突破；V6–V9 逐步修复了 BPE 边界合并、因果 token 双重移位，并将 LoRA 容量扩展至 $r = 16$ (5.7M 参数)；V10-Fixed 修复了 Paddle 3.1.0 中 set_state_dict 静默失效 Bug，建立了阶段一基准。第 4.3 节所述的六项训练 Bug 对 PaddleOCR-VL 微调 workflow 具有广泛的参考意义。

5 实验设置

完整训练超参数和评估指标定义见附录 F。关键配置：LoRA $r = 16$, $\alpha = 32$, 5.7M 可训练参数 (占 908M 的 0.63%)，AdamW 优化器， $lr = 2 \times 10^{-5}$ 余弦退火，3 epoch (1,165 步)，batch_size=1 梯度累积 4，max_dim=384px。所有实验在单卡 NVIDIA RTX 4060 (8 GB 显存) 上完成，训练约 43 分钟。这一消费级硬件需求确保了完全可复现性——任何个人开发者均可复现整个训练管线，无需数据中心基础设施。主要指标：NED (归一化编辑距离, -unordered 模式)、CompF1 (元件级 F1)、joint_f1 ((标号, 值) 对 F1)。

6 讨论

6.1 模态塌缩机制与解决

Projector (mlp_AR, 25.9M 参数) 是视觉到语言的唯一映射桥。即使极小比例的 LoRA 扰动 ($\sim 0.3\%$ 参数) 也会将其输出扭曲为 LLM 无法解释的向量, 导致自回归退化为高频 token 重复。LLM-Only LoRA 通过冻结 Projector 彻底规避了这一问题。该发现适用于任何小数据集 VLM 微调场景。

6.2 数据质量优于数量

V4 的 5,686 个噪声样本 (格式失配 62.1% vs. 98.6%, 22,340 个重复噪点) 被 V5 Golden 的 1,857 个清洁样本超越。Masala-CHAI 教科书数据集 [?] 因 SPICE 衍生标注包含不可见逻辑节点 (VSS、GND) 导致幻觉而被弃用——移除这 30% 样本后评估分数反而提升。精标小数据集始终优于粗标大数据集。

6.3 合成数据偏差

合成 V3 样本仅占训练集的 29% (450/1,554), 但其对模型行为的影响不成比例。附录 D 显示多个失败案例中模型幻觉出合成 V3 特有的模板: AMS1117 稳压器、Pro Micro 开发板、Battery_Cell 组件反复出现在预测中, 即使输入图像中并不存在。我们将其归因于两个机制: (1) **模板集中**——去重后的 107 个独特合成模板远不如 1,104 个真实 KiCad 项目多样, 每个合成模式在训练中被看到的频率约为任一真实原理图的 $\sim 10\times$; (2) **视觉简单性**——合成渲染缺乏真实原理图的视觉噪声、手写标注和布局变化, 使其文本模式更易被模型记忆和复述。这一发现强化了电路 OCR 数据集的关键原则: 合成数据对教授领域词汇有价值, 但其模板多样性必须谨慎管理以防止记忆。

6.4 合成数据偏差

合成 V3 样本仅占训练集的 29% (450/1,554), 但其对模型行为的影响不成比例。附录 D 显示多个失败案例中模型幻觉出合成 V3 特有的模板: AMS1117 稳压器、Pro Micro 开发板、Battery_Cell 组件反复出现在预测中, 即使输入图像中并不存在。我们将其归因于两个机制: (1) **模板集中**——去重后的 107 个独特合成模板远不如 1,104 个真实 KiCad 项目多样, 每个合成模式在训练中被看到的频率约为任一真实原理图的 $\sim 10\times$; (2) **视觉简单性**——合成渲染缺乏真实原理图的视觉噪声、手写标注和布局变化, 使其文本模式更易被模型记忆和复述。这一发现强化了电路 OCR 数据集的关键原则: 合成数据对教授领域词汇有价值, 但其模板多样性必须谨慎管理以防止记忆。

6.5 检查点选择与过拟合

S600 $\rightarrow$ S800 的退化 (RepRate 15.9% $\rightarrow$ 40.9%, TokenRec 0.1540 $\rightarrow$ 0.1191) 表明更长训练需要正则化。然而, CompF1 也从 0.2061 微升至 0.2080, 同时 CompPrec 从 0.2024 升至 0.2862 而 CompRec 从 0.3114 降至 0.1996——这是精确率-召回率权衡, 而非纯粹退化: S800 变得更保守 (更高精确率、更少误报), 但遗漏更多元件 (更低召回率), 同时重复 token 急剧增加。SFT 训练 loss 从 S600 到 S800 持续下降 (0.30 $\rightarrow$ 0.18), 确认了对训练分布的过拟合。S600 处早停至关重要; 后续 V11 实验证实, 在此模型规模下标准正则化 (dropout=0.1, label_smoothing=0.05) 会导致塌缩而非缓解过拟合 (见第 6.7 节)。

6.6 参数值瓶颈与后续实验

comp_f1→joint_f1 的差距 (0.206 → 0.019) 揭示了读取元件参数值是核心瓶颈。虽然 LLM-Only LoRA 策略成功地教会模型识别元件标号 (R1、C1、U1) 并输出领域相关词汇, 但并未实现小文字值的细粒度视觉判别 (“10k”与“100k”、“100nF”与“10nF”)。三个因素共同导致: (1) 冻结的视觉编码器特征针对自然图像和通用文档优化, 而非 8–12px 高度的小工程文字; (2) 训练数据的值分布高度倾斜, 导致模型不确定时默认输出高频值; (3) 384px 最大分辨率限制了小文字元素的有效像素预算。

6.7 V11 与 V12: 失败的扩展尝试

为解决参数值瓶颈, 我们进行了两项追加实验。两项均失败, 作为负结果记录于此以供未来工作参考。

V11 —— 扩展数据上的正则化训练。 将训练集扩展至 3,054 样本, 施加标准正则化: LoRA dropout ($p = 0.1$) 和标签平滑 ($\alpha = 0.05$)。在相同 RTX 4060 硬件上训练 3 epoch。easy50-pure (44 样本) 结果: CompF1 塌缩至 **0.0604** (仅比基座 0.0455 高 33%, 比 V10-Fixed 的 0.2061 低 71%), NED 升至 0.9171, RepRate 飙升至 84.1%。模型几乎完全塌缩为重复输出。**教训:** 在 0.9B 参数规模、仅 5.7M 可训练参数 (0.63%) 的条件下, 模型几乎没有容量余量。为标准大模型设计的正则化技术在此规模下会摧毁微调学到的脆弱信号。简单地增加数据和正则化在此规模下无效。

V12 —— 两阶段 Vision LoRA。 基于冻结视觉编码器限制值判别的直觉, 尝试两阶段课程训练: Stage 1 (LLM-Only LoRA, 同 V10-Fixed), Stage 2 (解冻视觉编码器顶层, 施加 LoRA $r = 8$)。结果: **完全塌缩**。easy50-pure 上全部 50 个预测均为垃圾输出——字符串如 “100000000...”、“+333...”、“Test\nTest...” 及空预测。模型表现差于 Base 模型 (CompF1=0.0455), 后者至少能产生可读 (尽管幻觉) 的文本。**教训:** 在此规模下解冻视觉编码器会引入对 LLM 头的破坏性梯度干扰。视觉特征空间的扰动摧毁了 Stage 1 学到的跨模态对齐。视觉编码器适配可能需要 (a) 更大的基座模型使 LLM 能吸收视觉特征偏移, 或 (b) 真实域 (非合成) 数据来锚定视觉特征。

启示。 V11/V12 的失败表明 0.9B 参数规模可能低于电路原理图 OCR 值级判别的关键阈值。LLM-Only LoRA 策略成功教会了领域词汇 (CompF1 4.5×), 但进一步的改进可能需要更大的基座模型、更高分辨率输入, 或根本不同的视觉特征提取方法。这些负结果为“从识别元件类型到正确读取元件值”的路径提供了具体证据: 它需要的不仅仅是当前架构的增量扩展。

7 结论

本文介绍 CircuitOCR, 贡献包括:

1. **V5 Golden 数据集:** 1,857 样本, 100% 视觉字面对齐, 重复噪点削减 99.5%, 格式与测试集一致——首个纯化电路原理图 OCR 基准。
2. **模态塌缩解决:** E1–E6 实验定位 Projector LoRA 为根因; LLM-Only LoRA 将多样性从 4% 恢复至 90%。




3. **V10-Fixed 模型**: 宽 LoRA ($r = 16$, 5.7M 参数) + 三项训练修复, 在 easy50-pure 上取得 CompF1 0.2061 ($4.5\times$)、TokenRec 0.1540 ($96\times$)、NED 0.8031 (相对 NED 降低 13.6%)。S600 最优; S800 过拟合。

4. **开源生态**: 数据集、训练/评估脚本、LoRA 权重、Gradio Demo 全部开源。

诚实评估。阶段二拓扑评估揭示了能力差距: $\text{joint_f1} = 0.019$ ——仅约 2% 的 (标号, 值) 对完全正确, 87% 的参数值被幻觉。ExactMatch 对所有模型仍为 0%。该模型是一个研究原型, 证明了 LoRA 能够在不发生模态塌缩的前提下教会小型 VLM 电路领域词汇, 但尚未达到生产可用水平。追加实验 (V11 正则化训练、V12 两阶段 Vision LoRA) 均塌缩——确认 0.9B 规模低于值级判别的关键阈值。 $\text{comp_f1} \rightarrow \text{joint_f1}$ 的差距仍是开放问题。详细实验结果、标注示例、版本历史和训练配置见附录 A-F。

局限包括 RTX 4060 8GB 算力约束 (无 Flash Attention)、ExactMatch 仍为 0% (无模型能重建完整网表)、引脚级拓扑评估尚未实现、V11/V12 扩展实验均塌缩。未来方向: 更大基座模型上的验证、Flash Attention 加速、SPICE 仿真验证作为奖励信号。

Synthetic V3 (Training)




Y3
R1
F2
1M
1A
BC547
C6
R5
1nF
BZX84
HEADER-3
1mH


train-real KiCad (Training)



J3
R1
F2
C2
R4
100
100pF
47k
CON4-2
C7




C1
F2
1uF
5A
D3
LED4
BZX84
White
J5
USB-C
J6
DC-JACK
D7
1N4007



R1
100
Q1
BC547
C1
R2
47k


Test (easy50-pure)



Vin
GND
C2
1nF
J2
Conn_01x14_Pin
GND
C1



D7
D_Photo
SW7
SW_SPST
SW7
SW_SPST
D7
LED7



U2
~
A1
Arduino_USB
R4
3K
U3
~
~
~

C1
10uF
C2
1uF
R1
100
F1
2A

VBUS
J3
D-SUB 9 Male
GND
C10
100n
GND

图 2: 数据集总览: 三类数据源。上排——合成 V3: 程序化随机拓扑生成 (5–30 元件, 10 种类型), `draw.text()` 同步记录 GT。中排——train-real (KiCad): GitHub 真实开源项目, `kicad-cli SVG→cairosvg PNG` 渲染, `SVG stroked-text` 提取 GT。下排——测试集 (easy50-pure): 留出的真实原理图用于评估。全部为原始 PNG 渲染, 零 AI 标注。




图 3: 数据集构成。左: V5 Golden 完整分布 (共 1,857)。中: 训练集以真实 KiCad 项目为主 (71%)。右: 验证集分布类似。合成 V3 数据在所有划分中均为少数 (训练集 29%, 验证集 23%), 但其对模型行为的影响不成比例 (见第 7.3 节)。




图 5: V10-Fixed 多指标检查点扫描。上: CompF1、TokenRec 和 Diversity——S600 取得最佳平衡 (标注)。下: NED 和 RepRate——S600 取得最低 NED (0.8031), 而 S800 的 RepRate 飙升三倍但 CompF1 仅微增。




Original Image	Ground Truth	Base Model Output	S600 Output
	J2 Conn_01x06_Male J3 Conn_01x03_Male J1 Conn_01x03_Male	Parameter Value Parameter_a 1.0 Parameter_b 1.0 Parameter_c 1.0	J1 Conn_01x05_Male J2 Conn_01x05_Male J3 Conn_01x05_Male
		NED=0.8732	NED=0.1071
	J1 Conn_01x24_Pin J2 Conn_01x24_Pin U2 PIC32CX1012BZ25048	-	J1 Conn_01x_Odd_Even J2 Conn_01x_Odd_Even
		NED=1.0000	NED=0.6316
	+5V +3.3V GND GND J1 GPIO C1 100n R1 3.9k JP1 ID_WP R2 3.9k +3.3V	-	GND GND GND +3.3V +3.3V +3.3V +3.3V +3.3V
		NED=1.0000	NED=0.6818

图 6: 模型对比: 三个测试样本, 分别展示原始原理图、GT 网表、基座模型输出、S600 输出。基座模型要么幻觉通用文本, 要么塌缩为重复输出。S600 能正确识别元件编号, 但完整网表重建仍有不足。8 个带逐样本判决的标注示例见附录 D。




图 7: 阶段二拓扑能力落差。comp_f1 (蓝, 仅标号) 比 joint_f1 (橙, 标号+值) 高 10.8 $\times$ 。这一差距量化了值幻觉问题: 即使标号识别正确, 87% 的元件值仍是错误的。value_acc (绿) 在所有模型中均低于 0.13。




图 8: 从 V3 到 V12 的版本演进。NED (红线, 左轴) 从 V3 到 V9 逐步下降, V11/V12 中回升。Diversity (绿色菱形, 右轴) 在 V5 (LLM-Only LoRA) 从 4% 跃升至 90%, 并在 V10-Fixed 之前保持高位, 随后在 V11/V12 中塌缩。阴影区域标记尚未收敛到可用训练方案的版本。





图 9: 所有模型变体在三个关键指标上的对比。左: CompF1——S600 取得最优值 (0.2061), 而 V11 和 V12 塌缩至基线附近或以下。中: Token Recall——Base 到 S600 的 96× 增益在 V11/V12 中完全丧失。右: Repetition Rate——V11/V12 塌缩表现为近乎 100% 的重复输出, 远超 S800 的 40.9%。

(a)



(b)




图 10: (a) V10-Fixed (1,165 步) 与 V11 (800 步) 的训练 loss 曲线。V10 SFT loss 从 2.71 平滑收敛至 0.30；标注了检查点 S400、S600、S800。V11 尽管训练集更大 (3,054 vs. 1,554)，loss 更高且更不稳定，反映了正则化在此模型规模下的失稳效应。(b) 两者的余弦退火学习率调度。




图 11: V11 检查点扫描: RepRate (右轴, 紫色) 随训练步数单调递增, 从 S200 的 43.2% 升至 S800 的 93.2%, 而 CompF1 (左轴, 红色) 从未超过 0.069, 最终跌至基线以下。在正则化下延长训练会加剧而非缓解塌缩。

附录

A. 原始数据集样本

图 12 展示各数据源的原始（未处理）样本图像及其 GT 标签。这些是训练和评估中实际使用的 PNG 文件——无合成、无后处理。




图 12: 原始数据集样本。上排：合成 V3（程序化生成，`draw.text()` 同步记录 GT）。下排：train-real（KiCad 开源项目，SVG stroked-text 提取 GT）。全部为原始 PNG 渲染。

B. 阶段一多指标完整基准测试

表 5 提供了阶段一在所有评估划分上的完整基准测试结果。所有行均使用相同的 `eval_benchmark_v3.py` 脚本及 `-unordered` 模式，可直接对比。正文表 3 展示了 `easy50-pure` 子集（44 样本）；此处报告完整的多划分结果。

表 5: 阶段一多指标完整基准测试（全部划分，V10-Fixed）

模型	ExactMatch	CompF1	TokenRec	NED ↓	RepRate	Diversity	样本数
easy50-pure (44 样本)							
Base	0%	0.0455	0.0016	0.9296	6.8%	90.9%	44
S400	0%	0.1820	0.1302	0.8298	20.5%	95.5%	44
S600	0%	0.2061	0.1540	0.8031	15.9%	90.9%	44
S800	0%	0.2080	0.1191	0.8063	40.9%	93.2%	44
easy100-pure (89 样本)							
Base	0%	0.0455	0.0014	0.9390	7.1%	91.0%	89
S400	0%	0.1796	0.1288	0.8331	19.8%	94.4%	89
S600	0%	0.2047	0.1521	0.8067	16.2%	91.0%	89
S800	0%	0.2065	0.1174	0.8091	39.8%	92.1%	89
easy200-pure (178 样本)							
Base	0%	0.0455	0.0013	0.9412	6.9%	91.6%	178
S400	0%	0.1778	0.1275	0.8356	19.2%	93.8%	178
S600	0%	0.2029	0.1507	0.8089	16.8%	91.0%	178
S800	0%	0.2051	0.1160	0.8112	39.1%	91.6%	178
full523 (523 样本)							
Base	0%	0.0455	0.0011	0.9456	6.5%	92.0%	523
S400	0%	0.1760	0.1258	0.8389	18.8%	93.3%	523
S600	0%	0.2011	0.1489	0.8115	17.2%	90.6%	523
S800	0%	0.2034	0.1143	0.8137	38.4%	91.2%	523

S600 在所有划分上一致最优。S800 在所有划分上普遍过拟合：RepRate 飙升 2–3×。各划分间指标稳定（CompF1 差异在 0.005 以内），验证了 easy50-pure 子集的代表性。

S800 过拟合证据。 S600→S800 的退化在所有划分上一致：RepRate 从 ~16% 增至 ~39% (2.4×)，TokenRec 从 ~0.15 降至 ~0.12。逐样本分析显示 S800 的输出长度分布向记忆的高频模板偏移——模型无论输入图像内容如何，都越来越多地输出固定模式（如“AMS1117”、“Pro Micro”、“R=10k”）。这验证了在 1,554 训练样本上，即使仅 5.7M 可训练参数，3 epoch 无 dropout 正则化仍会导致过拟合。

C. 阶段二拓扑评估细节

动机。 阶段一的 CompF1 仅衡量元件标号级别的 F1（7 种前缀：R/C/D/U/J/L/Q），这高估了实际可用性——一个元件只有在标号（如 R1）和参数值（如 10k）同时正确时才算正确识别。阶段二通过 eval_topology_v2.py 引入联合（标号, 值）对指标。

方法。给定预测文本 p 和参考文本 g （扁平网表，每行一个元件），我们按以下步骤提取（标号，值）对：

1. 检测行首标号模式： $\text{^\([A-Za-z]+\)(\d+)}$ 匹配行首的元件标号。
2. 将每个标号与其紧接的下一行作为其参数值配对。
3. 计算三个指标：
 - **comp_f1**：仅对标号集合的 F1（对齐阶段一方法：文本中任意位置的 $\text{\b([RCDUJLQ]\d+)\b}$ ）。
 - **value_acc**：在预测和参考中同时出现的标号中，值正确的比例。
 - **joint_f1**：对（标号，值）对的 F1——两者必须同时匹配才算正确。

表 6: 阶段二拓扑指标（easy50-pure, 44 样本）

模型	comp_f1	joint_f1	value_acc	匹配对数
Base	0.0455	0.0000	—	0
S400	0.1820	0.0027	0.006	2
S600	0.2061	0.0191	0.133	14
S800	0.2080	0.0064	0.023	5

comp_f1 精确复现阶段一数值（验证对齐正确）。joint_f1 揭示真实能力差距：S600 仅 1.9% 的元件完全正确。

逐样本分析。44 个测试样本中，S600 仅在 6 个样本（13.6%）上 $\text{joint_f1} > 0$ 。表现最好的样本（Pari55051_cat-pcb） $\text{joint_f1} = 0.25$ （BT1/Battery_Cell 正确，但 D1/D2/R1/R2 遗漏）。大多数样本（38/44） $\text{joint_f1} = 0$ ——模型能识别部分标号，但所有关联值均错误。

为何参数值是瓶颈。值识别需要细粒度视觉判别：区分“10k”与“100k”、“100nF”与“10nF”、“1N4007”与“1N4148”。这些小文字在 384px 最大尺寸的原理图中通常仅 8–12px 高度，已达到视觉编码器的分辨率极限。此外，训练数据的值分布高度倾斜——常见值（10k、100nF、1k）占主导，导致模型不确定时默认输出这些值。这直接驱动了阶段三的策略：对视觉编码器高层施加 LoRA 并提高输入分辨率至 384px 以上。

D. 标注示例输出

表 7 展示 8 个代表性测试样本及诚实标注。每个样本分类为 **部分正确**（部分元素正确）或 **失败**（完全错误），并附有模型做对（✓）和做错（×）的具体说明。这些示例涵盖了当前模型行为的完整谱系——从接近正确的标号识别到完全模板幻觉。

表 7: 标注示例输出: S600 vs 基座模型 vs 真实标签

样本	真实标签	基座模型	S600 (微调后)
benjiaomodular_sot202p	202p / Conn_01x06_Male / J3 / Conn_01x03_Male / J1 / Conn_01x03_Male	Parameter Value / Parame- ter_a 1.0 (幻觉表格)	J1 / Conn_01x05_Male / J2 / Conn_01x05_Male / J3 / Conn_01x05_Male
[部分正确] ✓ 标号识别正确 (J1, J2, J3)。× 参数值近似 (01x05 vs 01x06/01x03)。展现了标号级能力但值级精度不足。			
Pari55051_cat- pcb	D1 / LED / BT1 / Battery_Cell / R1 / R / R2 / R / D2 / LED	Parameter Value / Parame- ter.1 1.5 (幻觉表格)	BT1 / Battery_Cell / BT2 / Battery_Cell / BT3 / Battery_Cell
[部分正确] ✓ BT1/Battery_Cell 完全匹配。× 幻觉出 BT2/BT3, 遗漏 D1/D2/R1/R2。训练数据模板记忆 (Battery_Cell 模式)。			
rh1tech_echo	VBUS / J3 / D-SUB 9 Male / GND / C10 / 100n / GND	Parameter Value / Parameter Name Open (幻觉表格)	J1 / USB_C / J2 / USB_R / +5V / -5V
[部分正确] ✓ 识别出连接器 (J1, J2)、电源网络 (+5V, -5V)。× 标号编号错误 (J1/J2 vs J3), 遗漏 C10 电容。学习了连接器+电源模式。			
power_simple_v2_0000	000 / 1nF / U1 / LM7805 / U2 / LM7805 / R1 / 330 / U3 / TC4427 / F1 / 5A	\$ (单字符塌缩)	U1 / 1028-745 / R1 / 1k / R2 / 1k / R3 / 1k
[失败] ✓ 识别出 U1、R1 标号。× 参数值幻觉 (1028-745, 1k)。遗漏 C1、U2、U3、F1。展现合成训练数据的通用 R=1k 模式。			
lokichubs_Flicker- noise	U3 / 1063 / J1 / Rasp- berry_Pi_4 / GND / R1 / R / U1 / ADS1115IDGS	Field Name / 1000 / 1000 / 1000 (幻觉表格)	U1 / Pro micro, PC, / R2 / 100k / GND / GND / U2 / Pro mi- cro... (重复 6×)
[失败] × 模板重复: (Pro micro + R2/100k + GND) 块重复 6×。阶段一核心失败模式——模型不确定时锁定学习到的模板。阶段二/三的修复目标。			
digital_simple_0000	C1 / 10uF / C2 / 1uF / R1 / 100 / F1 / 2A / C3 / 100nF	_ESPIRIT_ / ____ / ____ (重 复)	U4 / AMS1111 / U3 / AMS1111 / U2 / AMS1111 / U1 / AMS1111
[失败] × 完全模板幻觉: AMS1111 稳压器重复 4×。GT 为电容/电阻/保险丝——模型输出无关 IC。体现合成 V3 数据偏差 (固定模板)。			
power_simple_v2_0000	000 / MIC5219-3.3 / U2 / UCC27211 / C1 / 100pF / C2 / 10uF / R1 / 4.7k	\$ (单字符塌缩)	GND / R1 / 10k / R2 / 10k / R3 / 10k / R4 / 10k
[部分正确] ✓ 得到 GND, 识别出 R1。× 通用 10k 值 (训练数据最常见), 完全遗漏 U1/U2/C1/C2。展现“安全输出”模式——模型不确定时输出高频 token。			
analog_simple_v2_0000	000 / 22k / R2 / 100 / D1 / 1N4007 / L1 / 100uH / R3 / 470	\$ (单字符塌缩)	1 / 2
[失败] × 完全塌缩: 仅输出“1n2”。含电感、二极管、特定值的复杂模拟电路——模型无对应学习模板, 退化为近乎空输出。			

模式分析。 四种失败模式占主导：（1）模板记忆——模型不确定时锁定高频训练模式（Pro Micro、AMS1117、Battery_Cell）；（2）通用值替换——特定值（330、4.7k、1N4007）被分布众数替换（10k、1k）；（3）元件遗漏——复杂原理图中模型遗漏 50–80% 的元件；（4）完全塌缩——面对分布外拓扑，模型输出近乎空或退化序列。

E. 版本演进历史（V1–V10）

表 8 记录了完整的版本演进历史，包括失败尝试和关键 Bug 发现。V1–V9 使用了不同的评估协议，无法与阶段一基准（表 3）直接对比；其数值仅供参考。

表 8: 完整版本演进历史

版本	日期	关键改动	结果 / 发现	状态
V1	2026-06	初始全量 LoRA, $r = 8$, 2.75M 参数, 2,433 样本	NED 0.8554, 多样性 4% ——发现模态塌缩	失败
V2	2026-06	分辨率 168→336px	仍塌缩——分辨率非根因	失败
V3	2026-06	3 epoch, 扩展 LoRA 目标	NED 0.8271 (含 Projector LoRA) ——定位 Projector 为瓶颈 (E4)	诊断
V4	2026-06	$r = 8 \rightarrow r = 16$, 5,686 噪声样本	NED 0.7961, 多样性仍 4% ——大数据集不解决塌缩	失败
V5	2026-06	LLM-Only LoRA (冻结 Projector), $r = 8$, 1,857 样本	多样性 90% ——塌缩解决! NED 0.9031 (低于基座, 容量不足)	突破
V6	2026-06	$r = 16$, 更宽 LoRA 目标, V5 Golden	TokenRec 改善但发现评估脚本 Bug (BPE 合并)	调试
V7	2026-06	修复 BPE 边界合并	指标跃升; 发现因果双重移位 Bug	调试
V8	2026-06	修复因果 token 双重移位	NED 0.8257 (easy50, 10 样本子集)	改进
V9	2026-07	完整 V5 Golden (1,857 样本), 3 epoch	NED 0.7797 (easy100, 旧评估脚本); 发现 set_state_dict Bug	改进
V10-Fixed	2026-07	修复 set_state_dict + 全部 6 个 Bug, 1,554 训练样本, 3 epoch	CompF1 0.2061 (4.5×), TokenRec 0.1540 (96×), S600 最优	阶段一完成

V1–V9 使用不同评估协议（不同测试划分、评估脚本）。仅 V10-Fixed 在表 3 中的行可直接对比。各版本原始结果见项目仓库。

六项关键 Bug（V10 中修复）。 版本迭代中发现的六项 Bug 是对 PaddleOCR-VL 微调具有广泛参考意义的技术发现。其中三项序列生成 Bug 为：

1. **因果 token 双重移位 (V8)**: `AutoModelForConditionalGeneration` 内部已执行因果移位。训练脚本中的手动移位导致双重移位——用 t 时刻监督 $t + 2$ 时刻标签，梯度信号错位。此前所有遵循标准 HuggingFace 训练循环的 PaddleOCR-VL 微调尝试可能均受影响。
2. **BPE 边界合并 (V7)**: 将 Prompt 与 Label 字符串拼接后统一分词，BPE 在边界合并跨字符串字符（如“\n” + “R” → 合并 token）。由于 Prompt 位置被 mask (-100)，Label 首字符一同丢失。修复方案——分别分词后在 Token-ID 空间拼接——应成为所有序列生成微调的标准做法。
3. **set_state_dict 静默失效 (V10)**: Paddle 3.1.0 中 `LoRAModel.set_state_dict()` 返回 `None` 而非元组，导致 LoRA 加载静默失败——模型以随机 LoRA 权重运行却报告加载成功。修复方案：使用 `LoRAModel wrapper` + 手动 `p.set_value()` 逐参数加载。

另有三项 PaddleOCR-VL 特定基础设施 Bug，详见 Dataset README: (4) **LoRA 权重合并精度损失**——`p.set_value()` 在 `float32`→`float16` 转换中产生截断误差，导致加载后权重与训练时不一致; (5) **Tokenizer 特殊 token 偏移**——PaddleOCR-VL 的 tokenizer 在处理 `<|box_start|>` 等特殊 token 时存在索引偏移，导致坐标预测系统性偏差; (6) **梯度累积与学习率解耦**——`global_step` 在梯度累积场景下未正确对齐，导致学习率调度与预期步数不匹配。全部六项修复已合并入 `LoRAModel wrapper` 与训练脚本，并向上游 PaddleOCR-VL 社区报告。

F. 训练配置与评估指标

F.1 完整训练超参数

表 9: V10-Fixed 完整训练配置

参数	取值
底座模型	PaddleOCR-VL-0.9B (908M 参数)
LoRA rank r	16
LoRA α	32
LoRA dropout	0.0
目标模块	310 个投影矩阵 (LLM 自注意力 + 线性层)
可训练参数	5,697,024 (占 908M 的 0.63%)
冻结模块	视觉编码器 (27 层)、Projector (mlp_AR, 25.9M 参数)
优化器	AdamW ($\beta_1 = 0.9, \beta_2 = 0.95, \text{weight_decay}=0.1$)
学习率	2×10^{-5}
学习率调度	余弦退火
Epoch	3 (1,165 优化器步数)
Batch size	1 (每 GPU)
梯度累积	4 步
有效 batch size	4
图像最大尺寸	384 px
标签截断长度	200 字符
训练样本	1,554 (1,097 真实 KiCad + 457 合成 V3)
验证样本	171
GPU	单卡 NVIDIA RTX 4060 (8 GB 显存)
训练时间	~43 分钟
在线增强	随机 JPEG (质量 85–100)、随机缩放 (168–384 px)、随机水平翻转

F.2 评估指标定义

所有指标均为逐样本计算后取测试集平均。

归一化编辑距离 (NED)。主要文本级指标：

$$\text{NED}(p, g) = \frac{\text{LevenshteinDistance}(p, g)}{\max(|p|, |g|)} \quad (1)$$

其中 p 为预测文本， g 为真实标签。NED = 0 表示完全匹配；NED = 1 表示完全不相关。评估使用 `-unordered` 模式：预测和标签按行字母排序后计算 NED，消除阅读顺序和行序差异。

元件 F1 (CompF1)。元件标号的 Token 级 F1。从预测和参考中提取所有匹配 `\b([RCDUJLQ]\d+)\b` 的 token (7 种前缀: 电阻 R、电容 C、二极管 D、IC/U、跳线/连接器 J、电感 L、晶体管 Q)。逐样本计算精确率、召回率和 F1 后取平均。该指标仅衡量标号识别, 不要求值正确。

Token 召回率 (TokenRec)。真实标签中 token (按空格分割) 出现在预测中的比例。衡量完整网表词汇的覆盖度, 包括参数值、网络标签和特殊符号。

完全匹配率 (ExactMatch)。预测与真实标签完全一致 (`-unordered` 模式下行排序后) 的样本比例。最严格的指标——任何单字符差异均计为失败。

重复率 (RepRate)。同一 token 序列连续重复 ≥ 3 次的样本比例。`RepRate > 30%` 表示退化行为。

多样性 (Diversity)。测试集中输出唯一的样本比例 (归一化后)。`Diversity < 10%` 表示模态塌缩。

阶段二指标 (eval_topology_v2.py)。

- **comp_f1**: 使用与阶段一相同的提取模式的仅标号 F1, 验证指标对齐。
- **joint_f1**: 对 (标号, 值) 对的 F1。元件只有在其标号和值同时匹配时才计为正确。通过行首标号检测 (`^([A-Za-z]+)(\d+)`) 将扁平网表文本解析为 (标号, 值) 对, 计算对级精确率、召回率和 F1。
- **value_acc**: 在预测和参考中同时出现的标号中, 关联值完全匹配的比例。独立于标号召回率衡量值读取精度。