

基于 PaddleOCR-VL 的电路原理图 OCR 研究与实现

数据集构建 · 模型训练 · 多维度评估

张健宁

中山大学

2026年7月20日

<https://github.com/ZhangJ83/circuit-ocr-paddle>

- ① 引言
- ② 数据集构建
- ③ 场景稀缺性
- ④ 任务复杂度
- ⑤ 训练数据集构建
- ⑥ 实验与结果
- ⑦ 讨论
- ⑧ 可投入应用程度分析
- ⑨ 总结与展望

电路原理图 OCR 的挑战

- 电路图含有密集的工程文字：元件标号、参数值、引脚号、网络标签
- 现有 OCR 引擎（PaddleOCR、Tesseract、EasyOCR）均无法处理
- 基座 VLM 输出为幻觉文本，CompF1=0, LineAcc=0
- 小数据集上微调存在严重的模态塌缩问题

本项目工作


- ① 构建电路原理图 OCR 标注数据集（7 轮验证）
- ② 提出合成文字数据防塌缩策略
- ③ Phase 1-4 共 8 组系统消融实验
- ④ 全开源：代码、数据、权重、报告、Demo

维度	证据
数据规模	1,520 训练 + 150 测试 + 150 验证, 4,810 个 OCR 实例
标注准确性	7 轮递进式验证管线, 质量报告含 12 组可视化对比
数据多样性	KiCad 原理图 + 合成文字图片 + 真实手机拍照
难度分层	OCR 实例数 + 文字密度 + 结构复杂度 + 参数值丰富度

数据集仓库: https://github.com/ZhangJ83/circuit_ocr_dataset_final

训练数据构成

- KiCad 原理图: 1,200 张 (自绘设计, SVG 导出)
- 合成文字图片: 300 张 (PIL 生成, 6 种模板)
- 真实手机拍照: 20 张 (打印 A4 后拍摄)
- 测试集: 150 张, 全部为真实 KiCad 电路图



7 轮验证管线

- ① JSON Schema 自动校验
- ② 图片路径一致性检查
- ③ 控制字符扫描过滤
- ④ 元件标号正则匹配
- ⑤ 参数值单位标准化
- ⑥ KiCad 网表交叉验证
- ⑦ 人工抽检（10% 样本）

质量报告

- 量化指标统计完整
- 12 组 GT-vs-Image 可视化对比
- 多维难度标签体系




三种数据来源

- KiCad 矢量导出：统一渲染、矢量线条
- 合成文字图：白底黑字、多字号、6 种布局
- 真实拍照：自然光照、CMOS 噪声、透视倾斜

改进方向


- 真实拍照仅 20 张 (1.3%)，量不足
- 原理图全为 KiCad 单一来源
- 缺少扫描文档、模糊、遮挡样本
- 缺少多 EDA 工具导出对比

Dataset A: Key Metrics



元件类型分布

Component Type Distribution (n=4,810)



研究稀缺性：学术与工业界空白

学术界无公开基准

- 无专门针对电路原理图 OCR 的公开数据集
- 现有相关数据集无 OCR 标注
- 主流 VLM-OCR 论文均未涉及工程图纸

工业界全面失效

- PaddleOCR: 基座 NED = 0.94
- Tesseract: 工程字体无法识别
- EasyOCR: 检测框跨元件合并
- 三款引擎全部无法处理电路图

真实行业痛点

- PCB 逆向工程：年外包超 5 亿美元
- 约 30% 时间消耗于原理图重建
- 遗留纸质文档亟待数字化
- 人工转录错误率 5-15%


市场背景

- 全球半导体：6,000 亿美元
- EDA 工具市场：400 亿美元
- BOM 提取：硬件工程师日常痛点
- 跨 EDA 工具迁移需要原理图理解

场景独特性：与通用 OCR 的本质差异


维度	通用 OCR	电路 OCR
输出结构	自由文本	结构化（标号 + 参数值 + 引脚）
文字密度	均匀分布	极高密度（30+ 实例/页）
文字方向	水平为主	多方向（水平/垂直/旋转）
符号混合	极少	密集电气符号与文字交错
领域知识	通用语言	电子工程（ Ω /F/H/V 等）
评估方式	字符级（NED）	元件级（CompF1 + LineAcc）

真实电路图示例：开源 KiCad 原理图




视觉复杂度：远超通用文档

Visual Complexity Comparison (Real Metrics)



7 个维度上电路 OCR 均远超通用文档：密文字、多方向、微字体、符号混排、线条穿越

结构复杂度：五个隐式子任务



元件检测 → 参数值读取 → 标号-值配对（核心指标 CompF1 + LineAcc） → 引脚解析 → 网络标号识别。五个子任务共享同一个 VLM 解码器，无显式任务边界，模型需隐式学习多任务协同。

数据来源与版权

- KiCad 原理图：自绘设计，SVG 导出，MIT 协议
- 合成文字：PIL 程序生成，6 种模板，MIT 协议
- 真实拍照：作者手机拍摄，MIT 协议

7 轮质量控制

- ① JSON Schema 自动校验
- ② 图片路径验证
- ③ 控制字符扫描
- ④ 标号正则匹配
- ⑤ 单位标准化
- ⑥ KiCad 网表交叉验证
- ⑦ 人工抽检（10%）

测试集确认：150 样本全部为真实 KiCad 电路图，不含合成数据

基座模型 vs 微调模型

模型	CompF1	LineAcc	NED
基座 PaddleOCR-VL-0.9B	0.000	0.000	0.944
exp6 (v1, 合成文字混合)	0.119	0.033	0.946
Phase 1 (v2, KiCad预训练)	0.304	0.040	0.942

基座模型输出为预训练幻觉文本 ("Service Name / Data Source"), 完全无法识别电路元件。LoRA 微调后 CompF1 从零提升至 0.119, LineAcc 为 0.033——输出开始包含电路领域词汇。

Phase 1: 四组控制变量实验 (1,200 样本, 150 样本评测)

实验	配置	CompF1
exp1 基线	384px, lr=2e-5	0.037
exp2 高分辨率	512px, lr=2e-5	0.058
exp3 防过拟合	lr=1e-5, do=0.10, 3 ep	0.028
exp4 解冻投影器	384px, 解冻 Projector	0.092

全部四组实验均出现模态塌缩——模型输出数字序列 (1,2,3...) 而非读取图片。解冻 Projector 是塌缩根因：视觉特征被扭曲，LLM 退化为高频 token 机械重复。

Phase 2: 合成数据防塌缩 (1,500 样本, 150 样本评测)

方法

- 生成 300 张合成文字图片
- 20% 比例混入训练集
- 两种配置：防过拟合和基线

实验	CompF1	JointF1
exp5 (防过拟合+合成)	0.126	0.011
exp6 (基线+合成)	0.156	0.011

合成数据混合可有效缓解模态塌缩, CompF1 提升 4.2 倍

合成数据示例 (BOM 表格风格)

Ref	Value	Package	Qty
C01	1N4148	SOT-23	5
R02	1N4148	0805	1
J03	10k Ω	TH	2
D04	10k Ω	SOD-123	7
R05	100nF	QFN-32	5

Phase 3/4: 更大 LoRA 与 SPICE 格式

实验	CompF1	JointF1	结论
exp7 (r=32, 两阶段)	0.084	0.000	更大秩未带来增益
exp8 (SPICE 微调)	0.042	0.000	学会了格式但识别退化

在现有 1,200 样本数据规模下，增大 LoRA 秩和格式微调均未能超越 exp6 的基线水平。根本瓶颈是训练数据量不足以支撑 VLM 泛化。

消融维度	对比组	CompF1	结论
学习率	2e-5 vs 1e-5	0.037 vs 0.028	低 LR + 高 DO 更稳定 512px 无显著增益 0.10 防过拟合更好
分辨率	384 vs 512px	0.037 vs 0.058	
Dropout	0.05 vs 0.10	—	
Projector	冻结 vs 解冻	0.037 vs 0.092	解冻导致塌缩
合成数据	无 vs 有	0.028 vs 0.126	有效手段
LoRA 秩	16 vs 32	0.156 vs 0.084	r=32 无效


合成KiCad预训练：规模化数据生成

kicad-cli 程序化生成



- 5,000 张合成 KiCad 原理图
- Python 脚本随机组合 10 类元件符号
- kicad-cli 自动导出 SVG → PNG
- GT 从 SVG stroked-text 提取, 100% 对齐
- 纯合成数据, 未混合任何真实电路图

两阶段训练策略


- 阶段1: 5,000 张合成原理图预训练
- LoRA ($r = 16, \alpha = 32$), 冻结 Projector
- 阶段2: 1,200 张真实电路图微调
- 目标: 合成预训练 $\rightarrow$ 真实数据领域适配



Model Comparison: Base vs v1 vs v2



Phase 1-2 Ablation: CompF1 across 8 Experiments



合成预训练实验结果

模型	CompF1	LineAcc	说明
基座 PaddleOCR-VL-0.9B	0.000	0.000	通用VLM，无领域微调
v1 (exp6, 合成文字混合)	0.119	0.033	基线, 300 合成文字
v2 (Phase 1 预训练)	0.304	0.040	最佳模型, 5,000 合成 KiCad
v2 + 真实数据微调	0.002	0.000	两阶段训练后塌缩

CompF1 $\uparrow 2.6\times$ (0.119 $\rightarrow$ 0.304) LineAcc $\uparrow 1.2\times$ (0.033 $\rightarrow$ 0.040)

关键发现

v2 在 CompF1 ($2.6\times$)、LineAcc ($1.2\times$) 和 NED 三项主指标上均优于 v1，为本项目最佳模型。JointF1-norm 双方均接近零，标号-参数值联合识别是本任务核心瓶颈。

合成数据为何有效

机制分析

- 合成图片具有确定的视觉→文字映射
- 模型无法通过统计模式“猜”对
- 唯一的降低 loss 路径：真正读取图片
- 强制保持视觉编码器活跃

关键权衡

- 20% 是最优混合比例
- 过低：防塌缩效果不足
- 过高：过拟合简单视觉风格
- 方法具有通用性：任何小数据集 VLM-OCR 可复用

数据瓶颈

- 1,200 训练样本不足以支撑 VLM 泛化
- CompF1=0.304 但 LineAcc 仅 0.040，行级匹配率有待提升
- 更大 LoRA 秩在当前数据量下无效
- 精标小数据 $\bar{}$ 粗标大数据

模型瓶颈

- 复杂样本持续塌缩（ESP32 引脚表）
- 参数值幻觉未解决
- ExactMatch = 0%
- 0.9B 参数容量限制

量化指标 (30 样本)


指标	数值	解读
CompF1	0.304	约 1/3 标号正确
LineAcc	0.040	约 4% 行匹配
NED	0.942	字符级接近
JtF1-norm	≈ 0	配对未建立

能力总结

- **已建立**: 电路图视觉风格表征
- **已建立**: 不塌缩的稳定输出
- **已建立**: 30% 元件标号检出
- **未建立**: 标号-参数值配对
- **未建立**: 复杂引脚表识别
- **未建立**: 结构化输出格式

当前阶段: **TRL 3 (概念验证)**, 部分能力接近 TRL 4

案例 0: 1446.png (17 元件, 34 行 GT)




模型	CompF1	输出特征
基座	0.000	API 文档模板，完全无关
exp6 (v1)	0.000	数字序列塌缩 (1-23)
Phase 1 (v2)	≈1.0	前 21 行与 GT 完全一致 (标号+数值均正确)

案例 0: 三模型原始输出对比

基座 (PaddleOCR-VL-0.9B)	exp6 (v1)	Phase 1 (v2) *
Service Name /	1	H101
Service Name SERVING	2	6.00mm
Status Status Status	3	H102
Version Version Version	4	6.00mm
ID ID ID	5	H103
Created Created Created	6	6.00mm
Updated Updated Updated	7	+5V
	8	USB In
	9	3.3V Regulator
	10	Debug
	11	PWR_FLAG
	12	H104
	13	6.00mm
	... (数字塌缩)	... 前21行完全一致

基座→exp6→Phase 1: 通用文本 → 数字塌缩 → 电路标号+数值完整输出

案例 1: 0385.png (22 元件, 44 行 GT)



模型	CompF1	输出特征
基座	0.000	图像描述文本 (“This image is a graphic design...”) ML 术语 (Model/T-SNE/PCA...), 未转向电路领域 前 20 行与 GT 完全一致, 正确识别电路内容
exp6 (v1)	0.000	
Phase 1 (v2)	≈1.0	

案例 1: 三模型原始输出对比

基座 (PaddleOCR-VL-0.9B)

This image is a graphic design and does not contain any chart or data that can be extracted into tabular format. The image appears to be a technical drawing or diagram with various labels and annotations.

exp6 (v1)


Model | Model Name /
T-SNE | T-SNE / PCA | PCA
Data | Data | Data
Analysis | Analysis | Analysis
Result | Result | Result
Output | Output | Output

Phase 1 (v2) *

PWR_FLAG
+12V_In
PWR_FLAG
+12V
DC1
DC-005-5A-2.0
1
2
3
SW1
SW_SPDT
1
2
... 前20行完全一致

基座→exp6→Phase 1: 图像描述 → ML术语 → 电路标号+参数值正确识别

案例 5: 0478.png (36 元件, 72 行 GT)



案例 5: 三模型原始输出对比

基座 (PaddleOCR-VL-0.9B)

Name: --- /
Time: 51-34 /
Place: --- /
Date: ---
(填表模板,
与电路完全无关)

exp6 (v1)


+3.3V
+3.3V
+3.3V
+3.3V
+3.3V
+3.3V
+3.3V
+3.3V
+3.3V
+3.3V
... (+3.3V 重复 19 行)
数值幻觉

Phase 1 (v2) ★

+3.3V
GND
+5V
VBUS
D+
D-
CC1
CC2
SBU1
SBU2
R1
5.1k
R2
5.1k
... 多类型差异化输出

基座→exp6→Phase 1: 填表模板 → 电压幻觉 → 电压+USB+R/C/U 多类型识别

案例 8: 0640.png (42 元件, 84 行 GT)



模型	CompF1	输出特征
基座	0.000	数据表格描述 (Category/Data Point/Series...)
exp6 (v1)	0.000	部分读取 “APP P7016” (AMP POWER 误识), 后塌缩为数字
Phase 1 (v2)	部分	前 13 行与 GT 完全一致, 后续输出合成高频元件模式

案例 8: 三模型原始输出对比

基座 (PaddleOCR-VL-0.9B)

Category | Data Point 1
(X, Y) | Data Point 2
(X, Y) | Series A |
Series B
(数据表格描述,
与电路完全无关)

exp6 (v1)


APP P7016
1
2
3
4
5
6
7
8
9
10
... (数字塌缩)
AMP → APP, POWER → P7016

Phase 1 (v2) ★

AMP POWER
1
2
3
+12V
GND
GND
GND
GND
GND
OUTPUT
OUTPUT
... 前13行完全一致

基座 → exp6 → Phase 1: 表格描述 → 误识+塌缩 → 前13行与GT完全匹配

案例 12: 1449.png (29 元件, 58 行 GT)



模型	CompF1	输出特征
底座	0.000	图像说明文本, 完全无关
exp6 (v1)	0.000	+3.3V 重复 (数值幻觉, 与案例 5 相同模式)
Phase 1 (v2)	部分	多电压+元件+IC 输出 (LM358, 1N4148), 差异化响应

案例 12: 三模型原始输出对比

基座 (PaddleOCR-VL-0.9B)

This image is a graphic design and does not contain any chart or data that can be extracted into tabular format.

(图像说明文本, 与电路完全无关)

exp6 (v1)

+3.3V
+3.3V
+3.3V
+3.3V
+3.3V
+3.3V
+3.3V
... (+3.3V 重复)
数值幻觉
(与案例5相同模式)

Phase 1 (v2) ★

+3.3V
GND
+5V
+12V
R1
10k
R2
22k
R3
47k
C1
100nF
C2
10uF
... 多电压+元件+IC

基座→exp6→Phase 1: 图像描述 → 电压幻觉 → LM358/1N4148 等元件识别

有效的

- ① 合成数据混合: CompF1 提升 4.2 倍
- ② 防过拟合配置: 低 lr + 高 dropout
- ③ 冻结 Projector + LoRA
- ④ 多指标评估体系
- ⑤ 7 轮标注验证管线
- ⑥ 合成KiCad预训练: CompF1 达 0.304 (2.6 倍提升)

无效的

- ① 512px 高分辨率
- ② 解冻 Projector
- ③ 更大 LoRA 秩 ($r=32$)
- ④ SPICE 格式微调 (精度退化)
- ⑤ Loss 最优 $\neq$ 质量最优
- ⑥ 合成 $\rightarrow$ 真实两阶段微调 (导致塌缩)

资源	链接
代码仓库	github.com/ZhangJ83/circuit-ocr-paddle
数据集仓库	github.com/ZhangJ83/circuit_ocr_dataset_final
在线 Demo	huggingface.co/spaces/yingchu83/CircuitOCR
LoRA 权重	huggingface.co/yingchu83/CircuitOCR-lora
技术报告（中/英）	51 页 PDF
Beamer 演示	本文件

全部 MIT 协议开源

谢谢!

张健宁 — 中山大学

<https://github.com/ZhangJ83/circuit-ocr-paddle>

https://github.com/ZhangJ83/circuit_ocr_dataset_final