

基于 PaddleOCR-VL 的电路原理图 OCR 研究与实现

数据集构建·模型训练·多维度评估

张健宁

中山大学

2026 年 7 月 20 日

<https://github.com/ZhangJ83/circuit-ocr-paddle>

- ① 引言
- ② 数据集构建
- ③ 场景稀缺性
- ④ 任务复杂度
- ⑤ 训练数据集构建
- ⑥ 实验与结果
- ⑦ 讨论
- ⑧ 可投入应用程度分析
- ⑨ 总结与展望

电路原理图 OCR 的挑战

- 电路图含有密集的工程文字：元件标号、参数值、引脚号、网络标签
- 现有 OCR 引擎 (PaddleOCR、Tesseract、EasyOCR) 均无法处理
- 基座 VLM 输出为幻觉文本, $\text{CompF1}=0$, $\text{LineAcc}=0$
- 小数据集上微调存在严重的模态塌缩问题

本项目工作


- ① 构建电路原理图 OCR 标注数据集 (7 轮验证)
- ② 提出合成文字数据防塌缩策略
- ③ Phase 1-4 共 8 组系统消融实验
- ④ 全开源：代码、数据、权重、报告、Demo

维度	证据
数据规模	1,520 训练 + 150 测试 + 150 验证, 4,810 个 OCR 实例
标注准确性	7 轮递进式验证管线, 质量报告含 12 组可视化对比
数据多样性	KiCad 原理图 + 合成文字图片 + 真实手机拍照
难度分层	OCR 实例数 + 文字密度 + 结构复杂度 + 参数值丰富度

数据集仓库: https://github.com/ZhangJ83/circuit_ocr_dataset_final

训练数据构成

- KiCad 原理图: 1,200 张 (自绘设计, SVG 导出)
- 合成文字图片: 300 张 (PIL 生成, 6 种模板)
- 真实手机拍照: 20 张 (打印 A4 后拍摄)
- 测试集: 150 张, 全部为真实 KiCad 电路图



7 轮验证管线

- 1 JSON Schema 自动校验
- 2 图片路径一致性检查
- 3 控制字符扫描过滤
- 4 元件标号正则匹配
- 5 参数值单位标准化
- 6 KiCad 网表交叉验证
- 7 人工抽检 (10% 样本)

质量报告

- 量化指标统计完整
- 12 组 GT-vs-Image 可视化对比
- 多维难度标签体系

三种数据来源

- KiCad 矢量导出：统一渲染、矢量线条
- 合成文字图：白底黑字、多字号、6 种布局
- 真实拍照：自然光照、CMOS 噪声、透视倾斜

改进方向

- 真实拍照仅 20 张 (1.3%)，量不足
- 原理图全为 KiCad 单一来源
- 缺少扫描文档、模糊、遮挡样本
- 缺少多 EDA 工具导出对比

OCR 实例数维度




难度	实例数	占比
简单	< 15	20%
中等	15-35	40%
困难	> 35	40%

2:4:4 比例符合真实场景分布

多维视觉标签（新增）


- 文字密度：低 / 中 / 高
- 结构复杂度：简单 / 中等 / 复杂
- 参数值丰富度：稀疏 / 中等 / 密集
- 综合视觉难度评分

Dataset A: Key Metrics



元件类型分布

Component Type Distribution (n=4,810)



研究稀缺性：学术与工业界空白

学术界无公开基准

- 无专门针对电路原理图 OCR 的公开数据集
- 现有相关数据集无 OCR 标注
- 主流 VLM-OCR 论文均未涉及工程图纸

工业界全面失效

- PaddleOCR: 基座 NED = 0.94
- Tesseract: 工程字体无法识别
- EasyOCR: 检测框跨元件合并
- 三款引擎全部无法处理电路图

工业需求：PCB 逆向与 BOM 提取

真实行业痛点

- PCB 逆向工程：年外包超 5 亿美元
- 约 30% 时间消耗于原理图重建
- 遗留纸质文档亟待数字化
- 人工转录错误率 5-15%

市场背景


- 全球半导体：6,000 亿美元
- EDA 工具市场：400 亿美元
- BOM 提取：硬件工程师日常痛点
- 跨 EDA 工具迁移需要原理图理解

场景独特性：与通用 OCR 的本质差异

维度	通用 OCR	电路 OCR
输出结构	自由文本	结构化 (标号 + 参数值 + 引脚)
文字密度	均匀分布	极高密度 (30+ 实例/页)
文字方向	水平为主	多方向 (水平/垂直/旋转)
符号混合	极少	密集电气符号与文字交错
领域知识	通用语言	电子工程 (Ω /F/H/V 等)
评估方式	字符级 (NED)	元件级 (CompF1 + LineAcc)

视觉复杂度：远超通用文档


Visual Complexity Comparison (Real Metrics)



7 个维度上电路 OCR 均远超通用文档：密文字、多方向、微字体、符号混排、线条穿越

结构复杂度：五个隐式子任务

Circuit OCR: 5 Implicit Sub-tasks



元件检测 → 参数值读取 → 标号-值配对（核心指标 CompF1 + LineAcc）→ 引脚解析 → 网络标号识别。五个子任务共享同一个 VLM 解码器，无显式任务边界，模型需隐式学习多任务协同。

数据来源与版权

- KiCad 原理图：自绘设计，SVG 导出，MIT 协议
- 合成文字：PIL 程序生成，6 种模板，MIT 协议
- 真实拍照：作者手机拍摄，MIT 协议

7 轮质量控制

- ① JSON Schema 自动校验
- ② 图片路径验证
- ③ 控制字符扫描
- ④ 标号正则匹配
- ⑤ 单位标准化
- ⑥ KiCad 网表交叉验证
- ⑦ 人工抽检 (10%)

测试集确认：150 样本全部为真实 KiCad 电路图，不含合成数据

基座模型 vs 微调模型

模型	CompF1	LineAcc	NED
基座 PaddleOCR-VL-0.9B	0.000	0.000	0.944
exp6 (v1, 合成文字混合)	0.119	0.033	0.946
Phase 1 (v2, KiCad 预训练)	0.304	0.040	0.942

基座模型输出为预训练幻觉文本 ("Service Name / Data Source"), 完全无法识别电路元件。LoRA 微调后 CompF1 从零提升至 0.119, LineAcc 为 0.033——输出开始包含电路领域词汇。

Phase 1: 四组控制变量实验 (1,200 样本, 150 样本评测)

实验	配置	CompF1
exp1 基线	384px, lr=2e-5	0.037
exp2 高分辨率	512px, lr=2e-5	0.058
exp3 防过拟合	lr=1e-5, do=0.10, 3 ep	0.028
exp4 解冻投影器	384px, 解冻 Projector	0.092

全部四组实验均出现模态塌缩——模型输出数字序列 (1,2,3...) 而非读取图片。解冻 Projector 是塌缩根因：视觉特征被扭曲，LLM 退化为高频 token 机械重复。

Phase 2: 合成数据防塌缩 (1,500 样本, 150 样本评测)

方法

- 生成 300 张合成文字图片
- 20% 比例混入训练集
- 两种配置：防过拟合和基线

实验	CompF1	JointF1
exp5 (防过拟合 + 合成)	0.126	0.011
exp6 (基线 + 合成)	0.156	0.011

合成数据混合可有效缓解模态塌缩, CompF1 提升 4.2 倍

Phase 3/4: 更大 LoRA 与 SPICE 格式

实验	CompF1	JointF1	结论
exp7 (r=32, 两阶段)	0.084	0.000	更大秩未带来增益
exp8 (SPICE 微调)	0.042	0.000	学会了格式但识别退化

在现有 1,200 样本数据规模下，增大 LoRA 秩和格式微调均未能超越 exp6 的基线水平。根本瓶颈是训练数据量不足以支撑 VLM 泛化。

消融维度	对比组	CompF1	结论
学习率	2e-5 vs 1e-5	0.037 vs 0.028	低 LR + 高 DO 更稳定 512px 无显著增益 0.10 防过拟合更好
分辨率	384 vs 512px	0.037 vs 0.058	
Dropout	0.05 vs 0.10	—	
Projector	冻结 vs 解冻	0.037 vs 0.092	解冻导致塌缩
合成数据	无 vs 有	0.028 vs 0.126	有效手段
LoRA 秩	16 vs 32	0.156 vs 0.084	r=32 无效

合成 KiCad 预训练：规模化数据生成



kicad-cli 程序化生成

- 5,000 张合成 KiCad 原理图
- Python 脚本随机组合 10 类元件符号
- kicad-cli 自动导出 SVG $\rightarrow$ PNG
- GT 从 SVG stroked-text 提取, 100% 对齐
- 纯合成数据, 未混合任何真实电路图


两阶段训练策略

- 阶段 1: 5,000 张合成原理图预训练
- LoRA ($r = 16$, $\alpha = 32$), 冻结 Projector
- 阶段 2: 1,200 张真实电路图微调
- 目标: 合成预训练 $\rightarrow$ 真实数据领域适配

Model Comparison: Base vs v1 vs v2



Phase 1-2 Ablation: CompF1 across 8 Experiments



合成预训练实验结果

模型	CompF1	LineAcc	说明
基座 PaddleOCR-VL-0.9B	0.000	0.000	通用 VLM，无领域微调
v1 (exp6, 合成文字混合)	0.119	0.033	基线, 300 合成文字
v2 (Phase 1 预训练)	0.304	0.040	最佳模型, 5,000 合成 KiCad
v2 + 真实数据微调	0.002	0.000	两阶段训练后塌缩

CompF1 $\uparrow 2.6\times$ (0.119 $\rightarrow$ 0.304) LineAcc $\uparrow 1.2\times$ (0.033 $\rightarrow$ 0.040)

关键发现

v2 在 CompF1 ($2.6\times$)、LineAcc ($1.2\times$) 和 NED 三项主指标上均优于 v1，为本项目最佳模型。JointF1-norm 双方均接近零，标号-参数值联合识别是本任务核心瓶颈。

合成数据为何有效

机制分析

- 合成图片具有确定的视觉 → 文字映射
- 模型无法通过统计模式“猜”对
- 唯一的降低 loss 路径：真正读取图片
- 强制保持视觉编码器活跃

关键权衡

- 20% 是最优混合比例
- 过低：防塌缩效果不足
- 过高：过拟合简单视觉风格
- 方法具有通用性：任何小数据集 VLM-OCR 可复用

数据瓶颈

- 1,200 训练样本不足以支撑 VLM 泛化
- CompF1=0.304 但 LineAcc 仅 0.040, 行级匹配率有待提升
- 更大 LoRA 秩在当前数据量下无效
- 精标小数据 > 粗标大数据

模型瓶颈

- 复杂样本持续塌缩 (ESP32 引脚表)
- 参数值幻觉未解决
- ExactMatch = 0%
- 0.9B 参数容量限制

量化指标 (30 样本)

指标	数值	解读
CompF1	0.304	约 1/3 标号正确
LineAcc	0.040	约 4% 行匹配
NED	0.942	字符级接近
JtF1-norm	≈0	配对未建立

能力总结

- **已建立**: 电路图视觉风格表征
- **已建立**: 不塌缩的稳定输出
- **已建立**: 30% 元件标号检出
- **未建立**: 标号-参数值配对
- **未建立**: 复杂引脚表识别
- **未建立**: 结构化输出格式

当前阶段: **TRL 3 (概念验证)**, 部分能力接近 TRL 4

按应用场景的可投入程度

应用场景	当前可行性	主要障碍	预期时间
元件标号粗筛（人机协作）	部分可行	CompF1 需 $\rightarrow$ 0.5	3-6 月
辅助人工标注（预标注 + 确认）	当前可行	需标注平台接口	1-3 月
BOM 自动提取（无人值守）	不可行	JointF1 $\approx$ 0	2-3 年
SPICE 网表生成	不可行（长期）	需拓扑理解 + GNN	5+ 年

最近可交付成果

辅助标注工具：模型预标注 $\rightarrow$ 人工逐行确认/修改 $\rightarrow$ 导出 JSONL。预期节省 20-30% 标注时间，无需 CompF1 达到生产级别即可产生正向效率增益。

分阶段路线图

近期 (1-3 月)

- 辅助标注工具原型
- VSCode/Web 插件
- API 部署 (HF Spaces)
- **标注效率 +20-30%**

中期 (3-6 月)

- 合成数据 KIE 改进
- 5k → 50k 规模化
- CompF1 → 0.5
- JointF1-norm → 0.05

远期 (6-12 月)

- 多 CAD 来源泛化
- 真实扫描图适配
- 探索更大基座模型
- BOM 提取 α 版本

核心策略: **辅助标注落地** → 收集更多高质量数据 → 训练更好模型 → 更高效标注 (正反馈循环)

有效的

- ① 合成数据混合: CompF1 提升 4.2 倍
- ② 防过拟合配置: 低 lr + 高 dropout
- ③ 冻结 Projector + LoRA
- ④ 多指标评估体系
- ⑤ 7 轮标注验证管线
- ⑥ 合成 KiCad 预训练: CompF1 达 0.304 (2.6 倍提升)

无效的

- ① 512px 高分辨率
- ② 解冻 Projector
- ③ 更大 LoRA 秩 ($r=32$)
- ④ SPICE 格式微调 (精度退化)
- ⑤ Loss 最优 质量最优
- ⑥ 合成 → 真实两阶段微调 (导致塌缩)

当前局限

- LineAcc = 0.040, v2 较 v1 提升 $1.2\times$ 但仍需提高
- 最优 CompF1 = 0.304, 但 ExactMatch = 0%
- 仅 1,200 真实训练样本 (单 CAD 来源)
- 合成 $\rightarrow$ 真实两阶段微调塌缩 (性能下降)
- 复杂样本持续塌缩 (ESP32 引脚表等)

未来方向

- 扩大合成数据规模 (5k $\rightarrow$ 50k+)
- 渐进式领域适配: 合成 $\rightarrow$ 真实
- 改进标号-参数值配对机制
- 探索更大基座模型容量
- 多 CAD 来源数据增强

资源	链接
代码仓库	github.com/ZhangJ83/circuit-ocr-paddle
数据集仓库	github.com/ZhangJ83/circuit_ocr_dataset_final
在线 Demo	huggingface.co/spaces/yingchu83/CircuitOCR
LoRA 权重	huggingface.co/yingchu83/CircuitOCR-lora
技术报告 (中/英)	51 页 PDF
Beamer 演示	本文件

全部 MIT 协议开源

谢谢！

张健宁 | 中山大学

<https://github.com/ZhangJ83/circuit-ocr-paddle>

https://github.com/ZhangJ83/circuit_ocr_dataset_final